### Лекция по эконометрике № 2

# Линейная регрессионная модель для случая одной объясняющей переменной

Демидова
Ольга Анатольевна
https://www.hse.ru/staff/demidova\_olga
E-mail:demidova@hse.ru
14.09.2020

## План лекции № 2

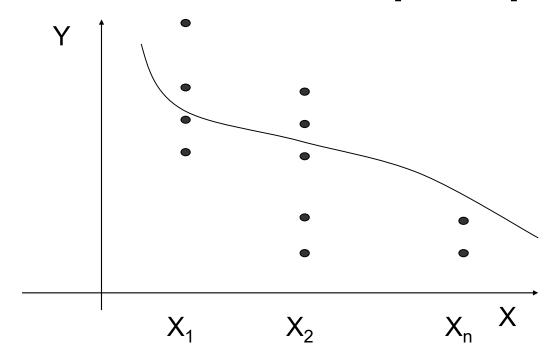
- Возникновение термина «регрессия»
- Теоретическая и выборочная регрессии
- Линейность регрессии по переменным и параметрам.
- Задача оценивания параметров
- Метод наименьших квадратов (МНК)
- Система нормальных уравнений и ее решение
- Интерпретация оценок МНК на примере

Dictionary definition: "Regression is a backward movement, a retreat, a return to an earlier stage of development".

Sir Francis Galton (1822-1911) ввел термин «регрессия», изучая зависимость роста детей от роста родителей.

"A regression of children's height towards the average".

- Линейный регрессионный анализ объединяет широкий круг задач, связанных с построением зависимостей между двумя переменными: X и Y.
- X независимая, объясняющая, экзогенная переменная, регрессор
- Y- зависимая, объясняемая, эндогенная переменная, regressand.
- На практике исследователь работает с данными  $(X_i, Y_i)$ , i = 1,...,n.



Уравнение теоретической регрессии  $Y_i = f(X_i) + \epsilon_{i,}$ , i = 1,...,n т.к. при одном и том же X,Y могут быть разные.

Из случайной величины Y выделяем некоторую часть, которая детерминирована иксом,

ε<sub>i</sub> - случайная составляющая, добавка.

$$f(X_i) = E(Y|X = X_i), i = 1,...,n$$

 $Y_i = E(Y|X=X_i) + \epsilon_i, i = 1,...,n$  — уравнение теоретической регрессии

Какова причина появления случайной составляющей ε<sub>i</sub> (возмущения)?

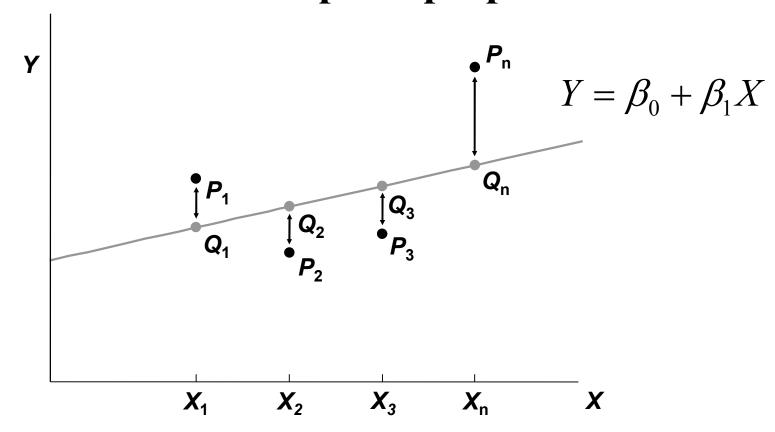
- •В модели участвуют не все переменные, влияющие на поведение Ү.
- •Врожденная неопределенность поведения экономических агентов.
- •Мы используем те величины, которые можем измерить, а не те, которые хотелось бы.
- •Ошибки измерения.

Уравнение теоретической регрессии

$$\mathbf{Y}_{i} = \mathbf{f}(\mathbf{X}_{i}) + \boldsymbol{\varepsilon}_{i}$$

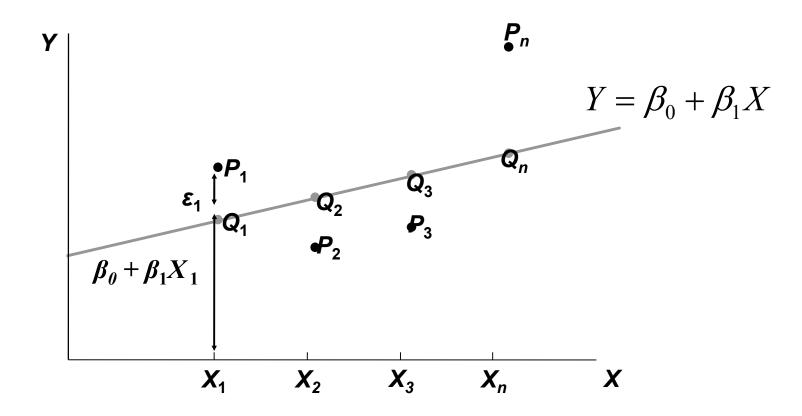
в зависимости от  $f(X_i)$  может быть линейным, квадратичным, логарифмическим и т.д.

Рассмотрим линейный случай:  $f(x) = \beta_0 + \beta_1 X$  — линейно по X и по параметрам.

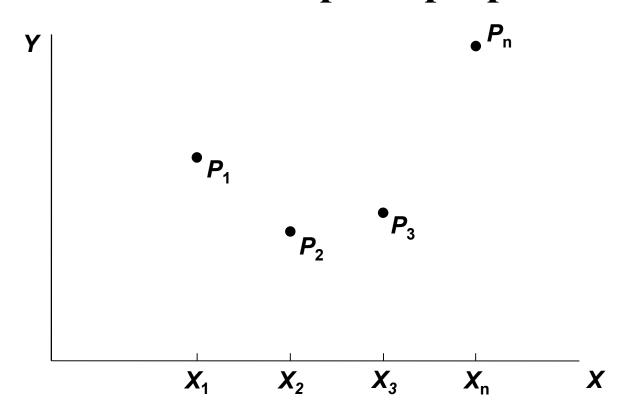


#### Специфицируем модель следующим образом:

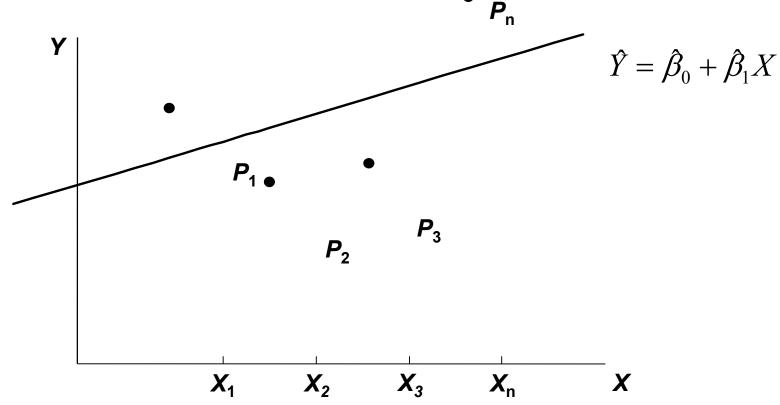
$$Y = \beta_0 + \beta_1 X + \varepsilon$$
, где  $\varepsilon$  — возмущение.



Таким образом, каждое значение переменной Y можно разделить на две части: детерминированную,  $\beta_0 + \beta_1 X$ , и случайную  $\varepsilon$ .



Но на практике мы не имеем линии  $Y = \beta_0 + \beta_1 X$  , а имеем только п пар наблюдений.

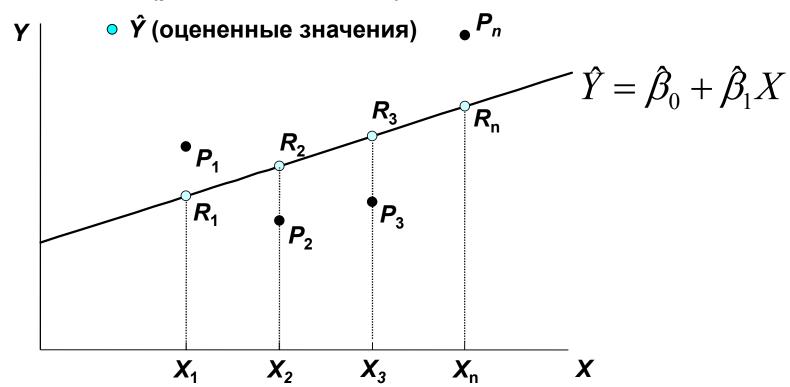


По п парам наблюдений мы должны построить оценки параметров  $\beta_0$  и  $\beta_1$  (соответственно  $\hat{\beta}_0$ ,  $\hat{\beta}_1$ ).

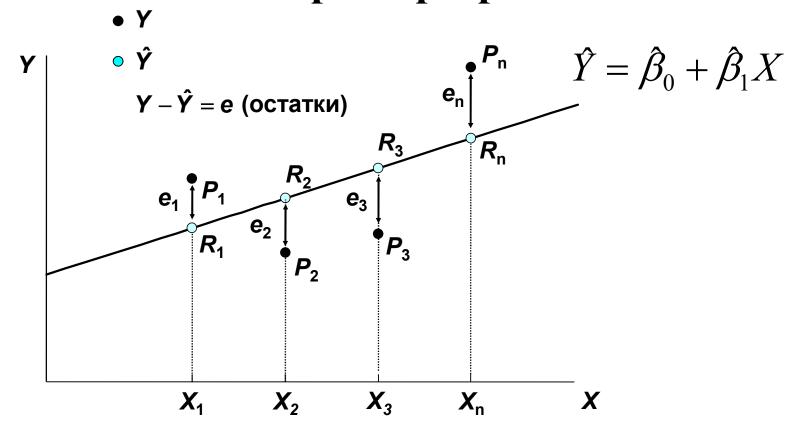
**То**гда линия  $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ 

будет являться аппроксимацией линии  $Y = \beta_0 + \beta_1 X$ .

• У (реальные значения)

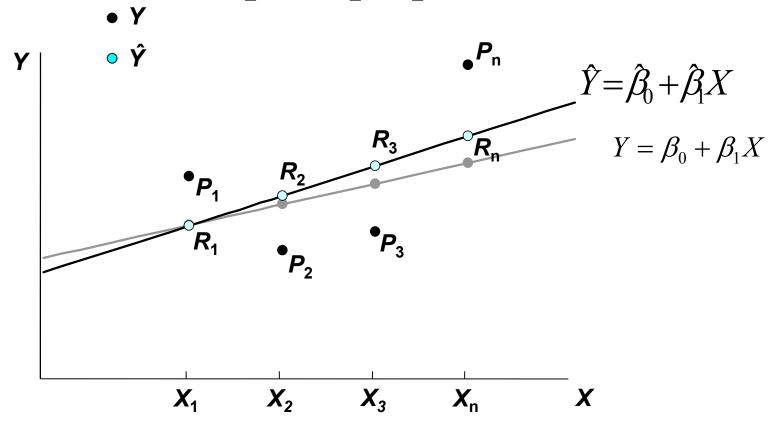


На рисунке проведена линия выборочной регрессии, лежащие на ней точки  $R_i$  называются оцененными значениями переменной Y.

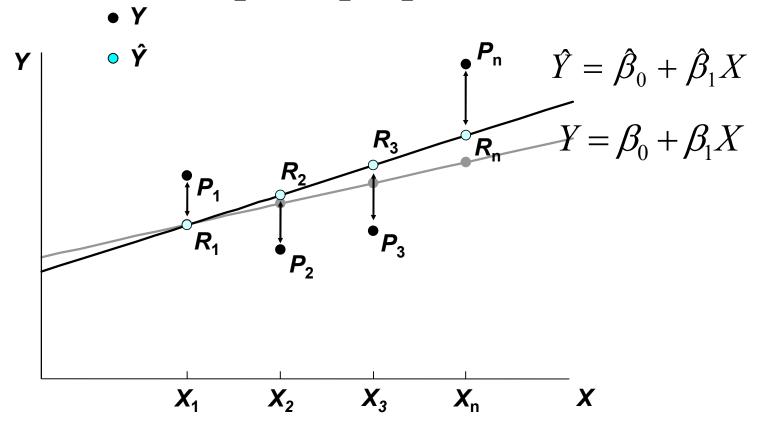


13

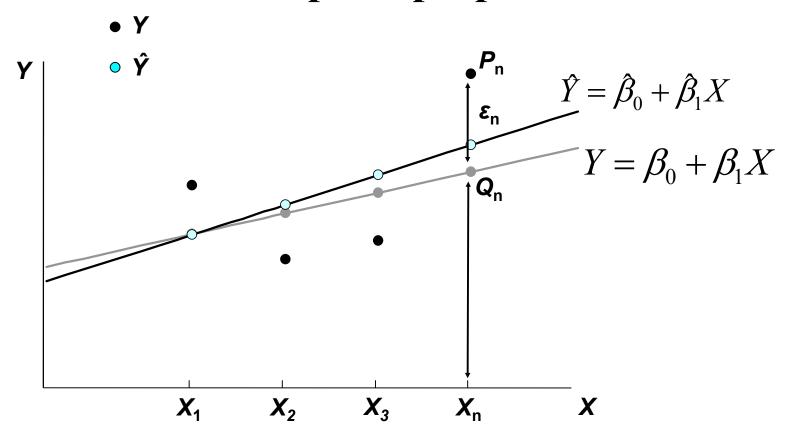
Разности между действительными и оцененными значениями переменной Y называются остатками регрессии.



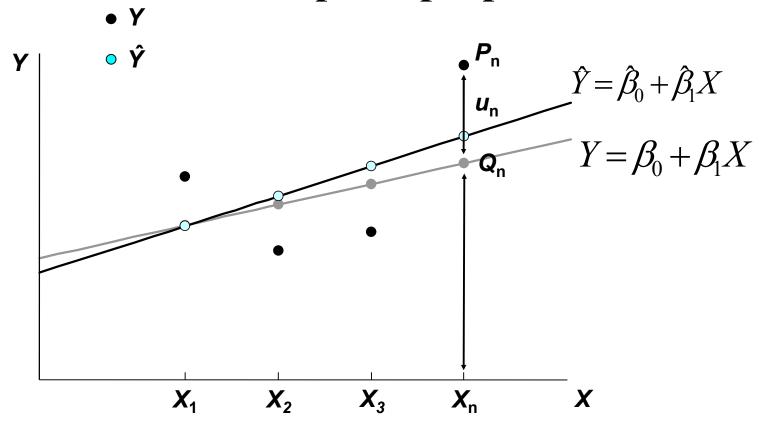
Серым цветом проведена линия теоретической регрессии, а черным – выборочной регрессии. 14



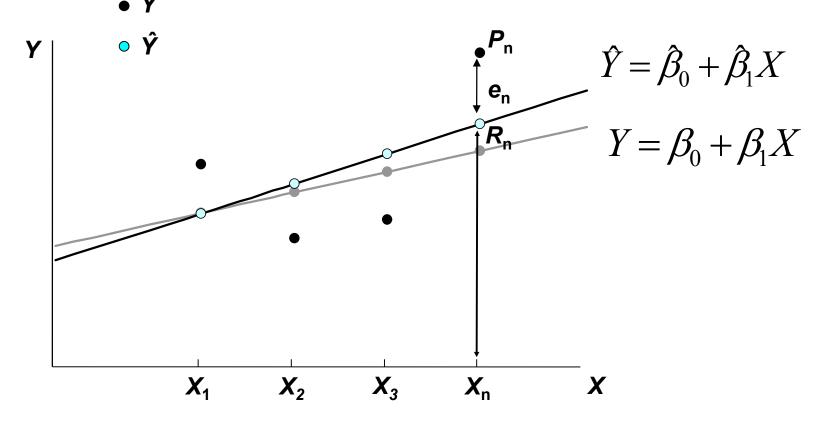
На рисунке изображены остатки e<sub>i</sub> (отклонения от линии выборочной регрессии).



При использовании теоретической регрессии Y разлагается на детерминированную ( $\beta_0 + \beta_1 X$ ) и случайную( $\varepsilon$ ) части.



Это разложение является чисто теоретическим (т.к. параметров  $\beta_0$  и  $\beta_1$  мы не знаем) и будет использовано при анализе свойств оценок коэффициентов регрессии.



Другая декомпозиция легко выполнима на практике при известных  $\hat{\beta}_0, \hat{\beta}_1$ 

# Оценка коэффициентов выборочной регрессии

Метод наименьших квадратов (МНК) нахождения оценок коэффициентов регрессии состоит в минимизации суммы квадратов остатков регрессии RSS (residual sum of squares).

$$RSS = \sum_{i=1}^{n} e_i^2 = e_1^2 + ... + e_n^2$$

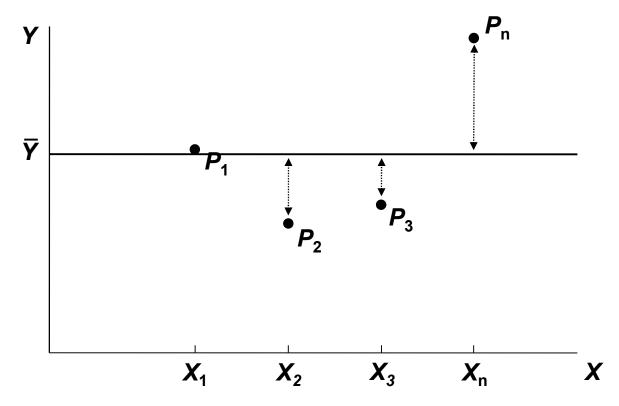
#### МНК

Минимизация RSS (residual sum of squares),

$$RSS = \sum_{i=1}^{n} e_i^2 = e_1^2 + ... + e_n^2$$

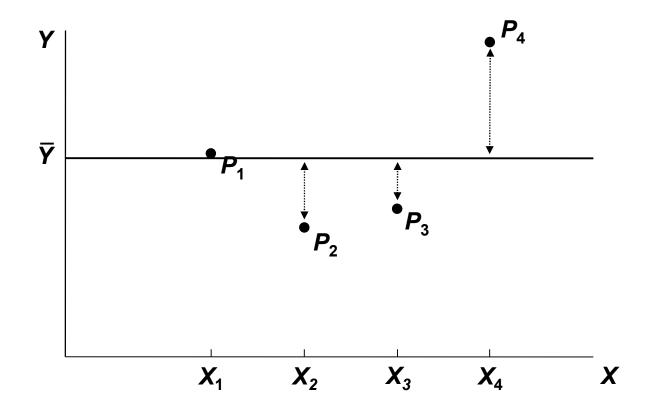
А не суммы остатков

$$\sum_{i=1}^{n} e_{i} = e_{1} + ... + e_{n}$$



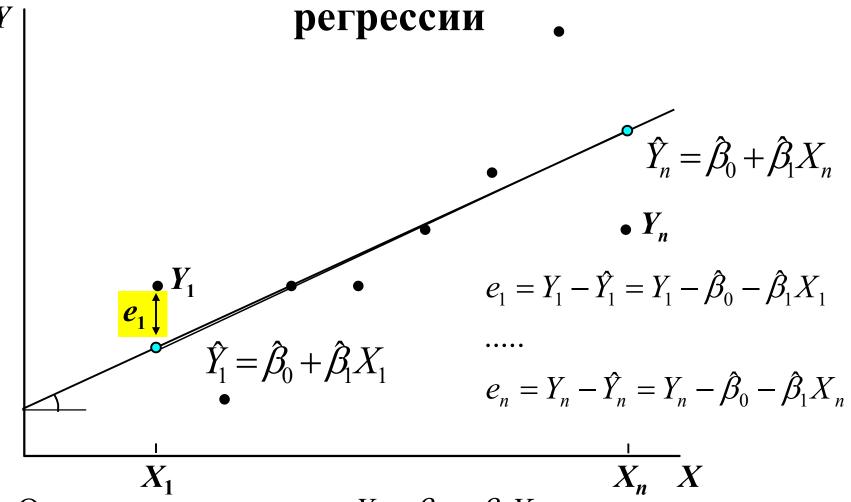
На примере горизонтальной линии легко увидеть, что сумма остатков равна 0, остатки разных знаков компенсируют друг друга, хотя и могут быть велики по абсолютной величине. Это будет иметь место и в общем случае.

21



МНК является не единственным возможным критерием, но очень удобен для практического применения (обладая и другими замечательными свойствами).

# Нахождение оценок коэффициентов парной



Оцениваема я модель :  $Y = \beta_0 + \beta_1 X + u$ 

Оцененная модель :  $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ 

Выразим остатки регрессии через наблюдения.

#### Выражение для RSS

$$RSS = e_1^2 + \dots + e_n^2 = (Y_1 - \hat{\beta}_0 - \hat{\beta}_1 X_1)^2 + \dots + (Y_n - \hat{\beta}_0 - \hat{\beta}_1 X_n)^2$$

$$= Y_1^2 + \hat{\beta}_0^2 + \hat{\beta}_1^2 X_1^2 - 2\hat{\beta}_0 Y_1 - 2\hat{\beta}_1 X_1 Y_1 + 2\hat{\beta}_0 \hat{\beta}_1 X_1$$

$$+ \dots$$

$$+ Y_n^2 + \hat{\beta}_0^2 + \hat{\beta}_1^2 X_n^2 - 2\hat{\beta}_0 Y_n - 2\hat{\beta}_0 X_n Y_n + 2\hat{\beta}_0 \hat{\beta}_1 X_n$$

$$= \sum Y_i^2 + n\hat{\beta}_0^2 + \hat{\beta}_1^2 \sum X_i^2 - 2\hat{\beta}_0 \sum Y_i - 2\hat{\beta}_1 \sum X_i Y_i + 2\hat{\beta}_0 \hat{\beta}_1 \sum X_i$$

#### Необходимое условие экстремума

$$RSS = \sum Y_i^2 + n\hat{\beta}_0^2 + \hat{\beta}_1^2 \sum X_i^2 - 2\hat{\beta}_0 \sum Y_i - 2\hat{\beta}_1 \sum X_i Y_i + 2\hat{\beta}_0 \hat{\beta}_1 \sum$$

$$\frac{\partial RSS}{\partial \hat{\beta}_0} = 0 \implies 2n\hat{\beta}_0 - 2\sum Y_i + 2\hat{\beta}_1 \sum X_i = 0$$

$$n\hat{\beta}_0 = \sum Y_i - \hat{\beta}_1 \sum X_i \quad (1)$$

$$\hat{\beta}_0 = \overline{Y} - \hat{\beta}_1 \overline{X}$$

Приравниваем к 0 частную производную по первой переменной.

#### Необходимое условие экстремума

$$RSS = \sum Y_i^2 + n\hat{\beta}_0^2 + \hat{\beta}_1^2 \sum X_i^2 - 2\hat{\beta}_0 \sum Y_i - 2\hat{\beta}_1 \sum X_i Y_i + 2\hat{\beta}_0 \hat{\beta}_1 \sum$$

$$\frac{\partial RSS}{\partial \hat{\beta}_1} = 0 \implies 2\hat{\beta}_1 \sum X_i^2 - 2\sum X_i Y_i + 2\hat{\beta}_0 \sum X_i = 0$$

Приравниваем к 0 частную производную по второй переменной.

$$\frac{\partial RSS}{\partial \hat{\beta}_{1}} = 0 \implies 2\hat{\beta}_{1} \sum X_{i}^{2} - 2\sum X_{i}Y_{i} + 2\hat{\beta}_{0} \sum X_{i} = 0$$

$$\hat{\beta}_{1} \sum X_{i}^{2} - \sum X_{i}Y_{i} + \hat{\beta}_{0} \sum X_{i} = 0 \quad (2)$$

$$\hat{\beta}_{0} = \bar{Y} - \hat{\beta}_{1}\bar{X}$$

$$\hat{\beta}_{1} \sum X_{i}^{2} - \sum X_{i}Y_{i} + (\bar{Y} - \hat{\beta}_{1}\bar{X}) \sum X_{i} = 0$$

Уравнения (1) и (2) образуют систему нормальных уравнений.

Делим на 2 и подставляем выражение для  $\hat{eta}_0$  через  $\hat{eta}_1$  .

### **Выражение** для $\hat{\beta}_1$

$$\hat{\beta}_1 \sum X_i^2 - \sum X_i Y_i + (\overline{Y} - \hat{\beta}_1 \overline{X}) \sum X_i = 0$$

$$\hat{\beta}_1 \left( \sum X_i^2 - n \overline{X}^2 \right) = \sum X_i Y_i - n \overline{X} \overline{Y}$$

$$\hat{\beta}_1 = \frac{\sum X_i Y_i - n \overline{XY}}{\sum (X_i - \overline{X})^2}$$

$$\hat{\beta}_1 = \frac{\sum X_i Y_i - n \overline{XY}}{\sum X_i^2 - n \overline{X}^2}$$

### Альтернативное выражение для $\hat{eta}_{\scriptscriptstyle 1}$

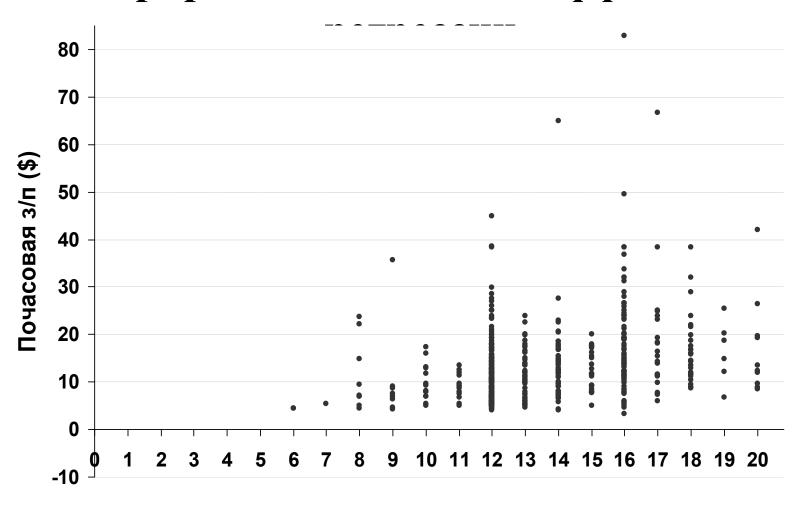
$$\hat{\beta}_1 = \frac{\sum X_i Y_i - n \overline{X} \overline{Y}}{\sum (X_i - \overline{X})^2}$$

$$\hat{\beta}_1 = \frac{\sum (X_i - \overline{X})(Y_i - \overline{Y})}{\sum (X_i - \overline{X})^2},$$

$$\hat{\beta}_1 = \frac{\sum x_i y_i}{\sum x_i^2}, x_i = X_i - \overline{X}, \quad y_i = Y_i - \overline{Y}$$

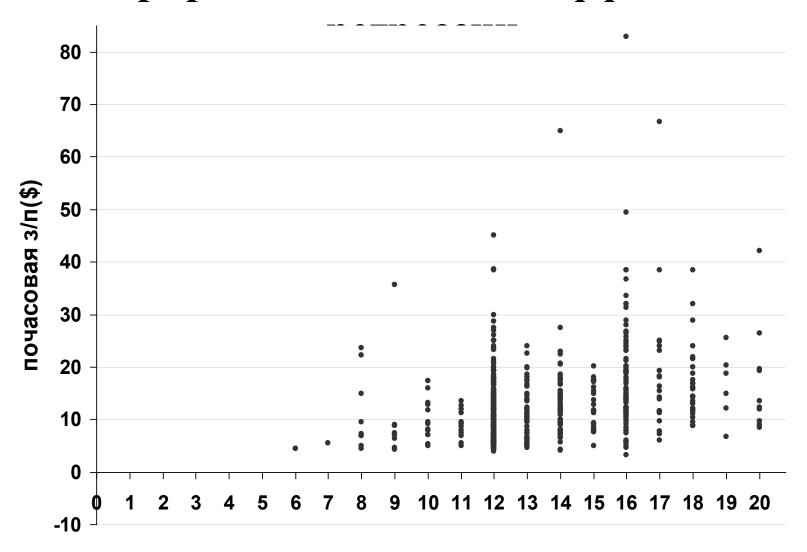
#### Разделим числитель и знаменатель на n-1

$$\hat{\beta}_1 = \frac{\hat{\text{Cov}}(X, Y)}{\hat{\text{Var}}(X)}$$



Количество лет обучения

Диаграмма рассеяния отражает зависимость почасовой 3/п в 1994 г. от длительности обучения для 570 индивидов из National Longitudinal  $_{30}$  Survey of Youth.



6 – 12 лет обучения – школьное образование (неполное или полное), 13 – 15 лет обучения – колледж, 16 – 18 лет – магистратура, 18 – 20 лет – докторантура.

# Интерпретация оценок коэффициентов регрессии

#### 

Для оценки регрессии используется статистический пакет Stata.

# Интерпретация оценок коэффициентов регрессии

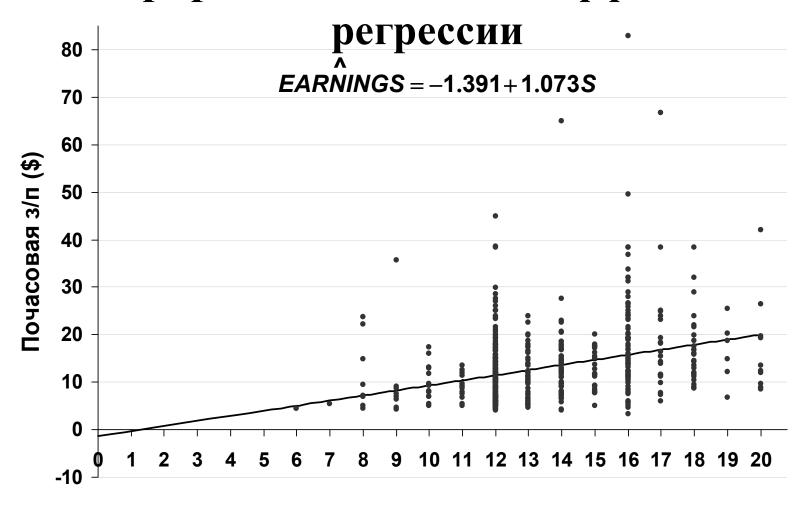
#### 

В первой колонке – названия переменных, во второй колонке – оценки коэффициентов регрессии.

# Интерпретация оценок коэффициентов регрессии

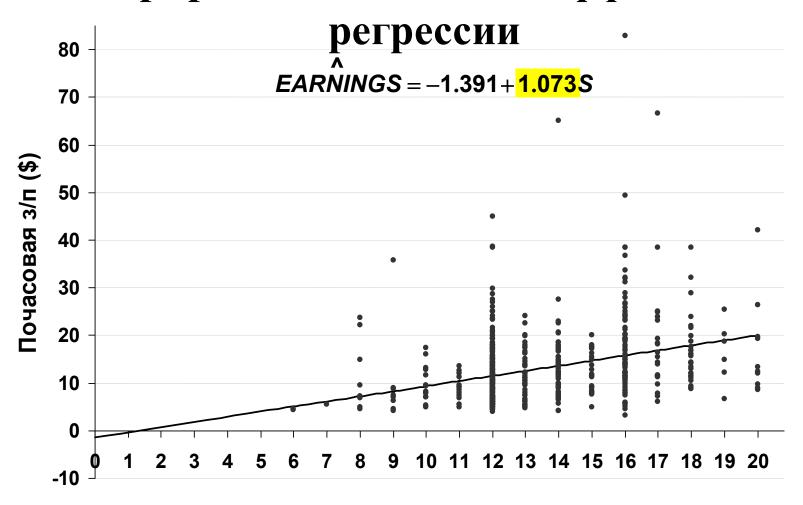
#### 

Оценка коэффициента перед переменной *S* равна 1.073, а оценка свободного члена (перед cons) равна -1.391.



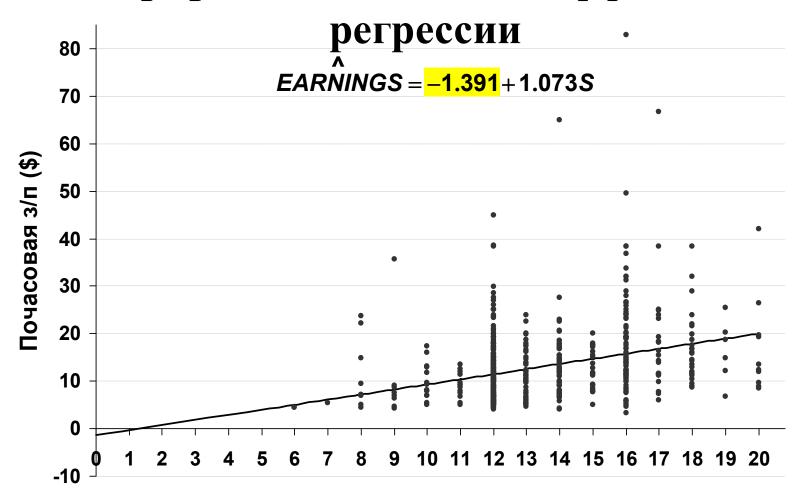
Количество лет обучения

На рисунке изображена линия выборочной регрессии.



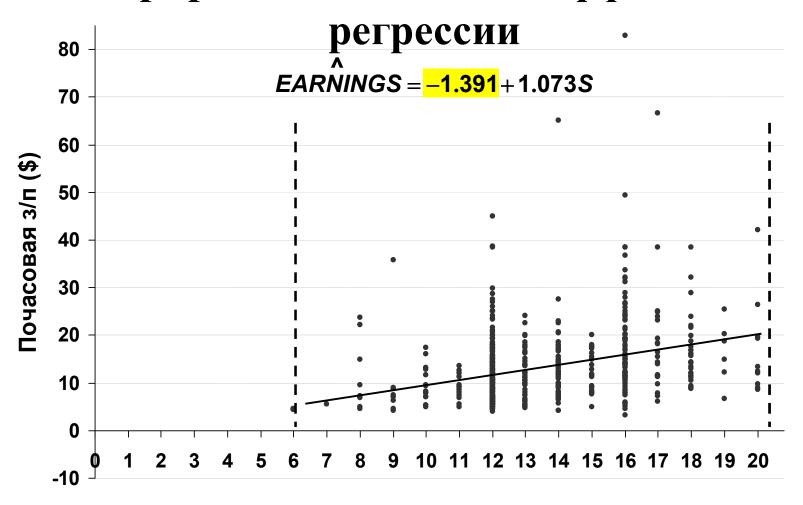
Количество лет обучения

S измеряется в годах, EARNINGS в долларах в час. Интерпретация оценки коэффициента наклона: каждый дополнительный год обучения увеличивает почасовую 3/n на \$1.07.



Количество лет обучения

Интерпретация константы, состоящая в том, что индивидуум, не имеющий образования, должен доплачивать за возможность работать, не имеет смысла.



Количество лет обучения

Однако экстраполяция проведена только для проучившихся более 6 лет, свободный член в данном примере не имеет содержательной 38 экономической интерпретации.