Лекция по эконометрике № 5, 2 модуль

Мультиколлинеарность

Демидова
Ольга Анатольевна
https://www.hse.ru/staff/demidova_olga
E-mail:demidova@hse.ru
23.11.2020

План лекции № 5, 2 модуль

- •Идеальная и практическая мультиколлинеарность (квазимультиколлинеарность).
- •Последствия мультиколлинеарности
- •Признаки наличия мультиколлинеарности
- •Показатели степени мультиколлинеарности
- •Методы борьбы с мультиколлинеарностью

Мультиколлинеарность

Теоретическая мультиколлинеарность данных – явление, наблюдаемое при нарушении условий теоремы Гаусса – Маркова об отсутствии точной линейной связи между регрессорами. При наличии теоретической мультиколлинеарности однозначное нахождение оценов МНК коэффициентов регрессии невозможно.

Теоретическая мультиколлинеарность

$$Y = \beta_0 + \beta_1 X_1 + ... + \beta_K X_K + \varepsilon,$$

Теоретическая мультиколлинеарность: Rank(X) < k + 1 Ex.1.

$$\ln wage = \beta_1 + \beta_2 S + \beta_3 MALE + \beta_4 FEMALE + \dots + \varepsilon,$$
$$FEMALE + MALE = i$$

Ex.2.

$$\begin{split} &\ln \ price = \beta_1 + \beta_2 livsq + \beta_3 non livsq + \beta_4 totsq + \ldots + \varepsilon, \\ &livsq + non livsq = totsq \end{split}$$

Пример теоретической мультиколлинеарности

Ex.3.

$$Price = \beta_1 + \beta_2 D_I + \beta_3 D_{II} + \beta_4 D_{III} + \beta_5 D_{IV} + \dots + \varepsilon,$$

$$D_I + D_{II} + D_{III} + D_{IV} = i$$

Dummy trap

Квазимультиколлинеарность

При работе с реальными данными часто имеет место квазимультиколлинеарность, когда между регрессорами существует почти линейная зависимость.

$$Y = X\beta + \varepsilon$$

теоретическая мультиколлинеарность:

$$rangX < k+1$$

$$\Rightarrow$$
 rang(X'X) < k + 1 \Rightarrow det(X'X) = 0

кваимультиколлинеарность:

$$det(X'X) \approx 0$$

Последствия мультиколлинеарности

$$\hat{\beta} = (X'X)^{-1} X'Y,$$

$$Var(\hat{\beta}) = \sigma_{\varepsilon}^{2} (X'X)^{-1},$$

$$A^{-1} = \frac{1}{\det A} A^{*}$$

Нестабильность оценок параметров регрессии и их дисперсий при малых изменениях исходных данных в случае мультиколлинеарности

Мультиколлинеарность, пример

$$Ex. y = \beta_{1}x_{1} + \beta_{2}x_{2} + \varepsilon,$$

$$x_{1}'x_{1} = x_{2}'x_{2} = 1, \sigma_{\varepsilon}^{2} = 1,$$

$$x_{1}'x_{2} = x_{2}'x_{1} = r,$$

$$var(\hat{\beta}) = \sigma_{\varepsilon}^{2}(x'x)^{-1},$$

$$x'x = \begin{pmatrix} x_{1}'x_{1} & x_{1}'x_{2} \\ x_{2}'x_{1} & x_{2}'x_{2} \end{pmatrix} = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix},$$

$$var(\hat{\beta}_{1}) = var(\hat{\beta}_{2}) = \frac{1}{1 - r^{2}}.$$

Признаки мультиколлинеарности

- •Небольшие изменения в данных приводят к значительным изменениям в оценках коэффициентов регрессии.
- •Многие коэффициенты по-отдельности не значимы, хотя в целом регрессия адекватная, R² может быть достаточно высоким.
- •Оценки коэффициентов регрессии (обычно незначимых) могут иметь "неправильный" знак (с экономической точки зрения).

Индикаторы мультиколлинеарности

- •В корреляционной матрице факторов встречаются элементы, по модулю близкие к 1.
- Достаточно большое значение VIF variance inflation factor хотя бы для одного фактора

$$VIF(X_j) = \frac{1}{1 - R^2},$$

где R_j^2 – коэффициент множественной детерминации регрессора X_j на все остальные регрессоры.

$$(Var(\hat{\beta}_j) = \frac{\sigma_{\varepsilon}^2}{TSS_j(1 - R_j^2)}, TSS_j = (X_j - \overline{X}_j \overline{i})'(X_j - \overline{X}_j \overline{i})).$$

Индикаторы мультиколлинеарности

CN (conditional number)

$$CN(X'X) = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}}$$

CN – число обусловленности матрицы X'X.

Если этот показатель > 30, то это может свидетельствовать о мультиколлинеарности.

Пример мультиколлинеарности данных

```
EARNINGS = \beta_0 + \beta_1 S + \beta_2 SVABC_1 + \beta_3 ASVABC_2 + \beta_4 ASVABC_3 + \beta_5 ASVABC_4 + \varepsilon
```

reg EARNINGS S ASVAB01 ASVAB02 ASVAB03 ASVAB04

```
Source SS df MS Number of obs = 540 F( 5, 534) = 30.60 Model 24945.2724 5 4989.05448 Prob > F = 0.0000 Residual 87064.9587 534 163.042994 R-squared = 0.2227 Adj R-squared = 0.2154 Total 112010.231 539 207.811189 Root MSE = 12.769
```

```
EARNINGS Coef. Std. Err. t P>t [95% Conf.Interval]

S 1.700556 .2781761 6.11 0.000 1.154102 2.247009

ASVAB01 .0640055 .0997875 0.64 0.522 -.1320188 .2600297

ASVAB02 .4385383 .091164 4.81 0.000 .2594542 .6176223

ASVAB03 -.1433842 .1202383 -1.19 0.234 -.3795824 .0928139

ASVAB04 -.0265344 .0985583 -0.27 0.788 -.2201438 .1670751

cons -20.48614 3.600184 -5.69 0.000 -27.5584 -13.41388
```

Много незначимых коэффициентов

Пример мультиколлинеарности данных

vif

Variable	VIF 1/VIF			
ASVAB03	4.20	0.238017		
ASVAB04	3.01	0.332532		
ASVAB01	3.00	0.333805		
ASVAB02	2.64	0.378371		
S	1.52	0.657411		
Mean VIF	2.87			

Методы борьбы с мультиколлинеарностью

- •Переспецификация модели (функциональные преобразования переменных)
- •Исключение одной или нескольких объясняющих переменных
- •Метод главных компонент
- •Использование ridge (гребневых), LASSO и т.п. оценок параметров

Метод главных компонент

$$X = [X_{1}, \dots, X_{k}], Var[X] = V, -$$

$$Z_{1} = \alpha_{11}X_{1} + \dots + \alpha_{1k}X_{k} = \alpha_{1} X_{1}, \quad \alpha_{11}^{2} + \dots + \alpha_{1k}^{2} = 1,$$

$$V \operatorname{ar}(Z_{1}) \to \operatorname{max}, \alpha_{1} \alpha_{1} = 1,$$

$$Var(Z_{1}) = \alpha_{1} V\alpha_{1},$$

$$L(\alpha_{1}) = \alpha_{1} V\alpha_{1} - \lambda_{1}(\alpha_{1} \alpha_{1} - 1) \to \operatorname{max},$$

$$V\alpha_{1} = \lambda_{1}\alpha_{1},$$

$$\lambda_{1} \text{ is the max characteristic root of } V,$$

$$\alpha_{1} \text{ is the corresponding characteristic vector.}$$

Метод главных компонент

Let $\lambda_1, ..., \lambda_k$ are the characteristic root of V (in decreasin g order), $\alpha_1, ..., \alpha_k$ are the corresponding characteristic vectors.

Linear functions:
$$Z_1 = \alpha_1' X, ..., Z_k = \alpha_k' X$$
.

Then
$$Var(Z_1) = \alpha_1' V \alpha_1 = \lambda_1, ..., Var(Z_k) = \alpha_k' V \alpha_k = \lambda_k.$$

 $Z_1,...,Z_k$ are called the principal components of $X_1,...,X_k$.

Properties of principal components:

1)
$$Var(Z_1) + ... + Var(Z_k) = \lambda_1 + ... + \lambda_k =$$

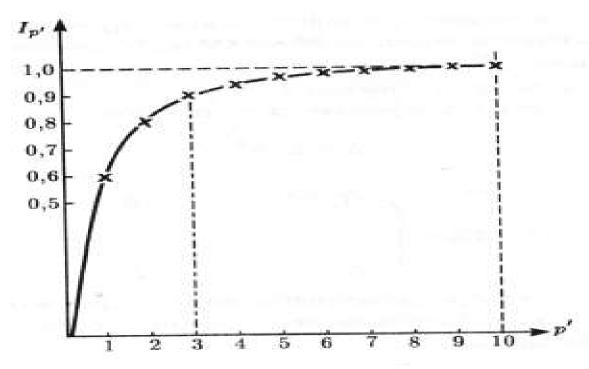
$$= trace(V) = Var(X_1) + ... + Var(X_k)$$

$$2)\alpha_1,...,\alpha_k$$
 are orthogonal vectors \Rightarrow

 $Z_1,...,Z_k$ are orthogonal or uncorrelated.

Пример

Доля общей дисперсии признаков, объясняемая одной, двумя, тремя и тд главными компотентами



Изменение относительной доли суммарной дисперсии исследуемых признаков, обусловленной первыми p' главными компонентами, в зависимости от p' (случай p=10)

Примеры

1) См. примеры 4.1, 4.2 из книги «Прикладная статистика в задачах и упражнениях», авторы С.А.Айвазян, В.С.Мхитарян

2) См. кластеризацию регионов в пространстве двух главных компонент в статье «Метод кластеризации регионов РФ с учетом отраслевой структуры ВРП», авторы С. А. Айвазян, М. Ю. Афанасьев, А. В. Кудров

4.Б. Примеры решения типовых задач и упражнений

Пример 4.1 (задача). При формировании типообразующих признаков предприятий отрасли были обследованы 24 предприятия (n=24) по трем технико-экономическим показателям: объему выпускаемой продукции $x^{(1)}$ (тыс.условных денежных единиц), основным фон-

Глава 4. СНИЖЕНИЕ РАЗМЕРНОСТИ

157

дам $x^{(2)}$ (тыс.у.д.е.) и фонду оплаты труда $x^{(3)}$ (тыс.у.д.е.). По полученным в результате обследования исходным статистическим данным $(x_i^{(1)}, x_i^{(2)}, x_i^{(3)}), \dots$ $i = 1, 2, \dots, 24, \dots$ были получены оценки вектора средних значений $\hat{a} = (\hat{a}^{(1)}, \hat{a}^{(2)}, \hat{a}^{(3)})^{\top} = (420; 240; 85)^{\top}$ и ковариационной матрицы

$$\widehat{\Sigma} = \begin{pmatrix} 451,39 & 271,17 & 168,70 \\ 271,17 & 171,73 & 103,29 \\ 168,70 & 103,29 & 66,65 \end{pmatrix}$$

Требуется:

- 1) вывести уравнения для вычисления главных компонент $z^{(1)}, z^{(2)}$ и $z^{(3)}$ по заданным значениям исходных технико-экономических показателей $x^{(1)}, x^{(2)}$ и $x^{(3)}$;
- определить относительные доли суммарной дисперсии, обусловленные одной и двумя главными компонентами;

Решение

1) Для определения коэффициентов линейного преобразования (4.5), с помощью которого осуществляется переход к главным компонентам, необходимо решить вначале характеристическое уравнение (4.8), а затем использовать найденные собственные значения $\lambda_1, \lambda_2, \ldots, \lambda_p$ для подстановки в системы уравнений (4.7), решения которых и дают коэффициенты $l_j = (l_{j1}, l_{j2}, \ldots, l_{jp})$. В данной задаче

$$|\widehat{\Sigma} - \lambda I| = \begin{vmatrix} 451,39 - \lambda & 217,17 & 168,70 \\ 271,17 & 171,73 - \lambda & 103,29 \\ 168,70 & 101,29 & 66,65 - \lambda \end{vmatrix} = 0,$$

158 ІІ. ПРИКЛАДНОЙ МНОГОМЕРНЫЙ СТАТИСТИЧЕСКИЙ АНАЛИЗ

откуда находим $\lambda_1=680,40,\,\lambda_2=6,50,\,\lambda_3=2,86.$

Последовательно подставляя эти значения в систему (4.7) и решая эти системы относительно $l_j=(l_{j1},l_{j2},l_{j3}), -j=1,2,3,$ — получаем: $l_1=(0.813;0.496;0.307);\ l_2=(-0.545;0.832;0.101),\ l_3=(-0.205;-0.249;0.947),$ так что уравнения для вычисления главных компонент $z^{(j)}$ (j=1,2,3) будут иметь вид:

$$z^{(1)} = 0.81(x^{(1)} - 420) + 0.50(x^{(2)} - 240) + 0.31(x^{(3)} - 85),$$

$$z^{(2)} = -0.55(x^{(1)} - 420) + 0.83(x^{(2)} - 240) + 0.10(x^{(3)} - 85),$$

$$z^{(3)} = -0.21(x^{(1)} - 420) - 0.25(x^{(2)} - 240) + 0.95(x^{(3)} - 85).$$

$$(4.20)$$

2) В соответствии с равенствами (4.10) и (4.10') и вытекающим из них представлением $I_{p'}(Z)$ в виде (4.4') имеем:

$$I_1(Z(X)) = \frac{\lambda_1}{\lambda_1 + \lambda_2 + \lambda_3} = 0,9864;$$

 $I_2(Z(X)) = \frac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2 + \lambda_3} = 0,9958;$

что свидетельствует о том, что почти вся информация (а именно, 98,64%) о специфике предприятия данного типа, описанной с помощью переменных $x^{(1)}, x^{(2)}$ и $x^{(3)}$, содержится в одной лишь первой главной компоненте $z^{(1)}$.

FES FAS FAS

Пример 4.2 (упражнение). Компонентный анализ проведен по данным двадцати сельскохозяйственных районов (n=20) области, которые содержат результаты измерений следующих показателей: $x^{(1)}$ — число колесных тракторов на 100 га; $x^{(2)}$ — число зерноуборочных комбайнов на 100 га; $x^{(3)}$ — число орудий поверхностной обработки почвы на 100 га; $x^{(4)}$ — количество удобрений, расходуемых на гектар; $x^{(5)}$ — количество средств защиты растений, расходуемых на гектар (исходные статистические данные $x_i^{(1)}, x_i^{(2)}, x_i^{(3)} x_i^{(4)}, x_i^{(5)}, \dots$ $i=1,2,\dots,20,$ — приведены в табл. П2.1 Приложения 2).

Расчеты проводились по нормированным данным вида (4.1') и представлены в следующей таблице:

Главные компоненты z(i)	z ⁽¹⁾	z ⁽²⁾	z ⁽³⁾	z ⁽⁴⁾	z ⁽⁵⁾
Собственные значения λ_i	3,04	1,41	0,43	0,10	0,02
Вклад і-й главной компоненты (%) в суммарную дисперсию	60,8	28,2	8,6	2,0	0,4
Суммарный вклад первых главных компонент (%)	60,8	89,0	97,6	99,6	100,0

При расчете относительного вклада главных компонент учитывалось, что $\sum_{i=1}^{p} \lambda_i = p = 5$. Для анализа были оставлены две первые главные компоненты (p' = 2), на которые приходится 89% суммарной вариации.

Для интерпретации главных компонент построена матрица факторных нагрузок

$$\mathbf{A} = \begin{pmatrix} 0.95^* & 0.97^* & 0.94^* & 0.24 & 0.56 \\ -0.19 & -0.17 & -0.28 & 0.88^* & 0.67^* \end{pmatrix}^{\mathsf{T}}.$$

Звездочкой (*) отмечены элементы, удовлетворяющие условию $|a_{ij}| > 0,6$, т.е. те, которые следует учитывать при интерпретации главных компонент $z^{(1)}$ и $z^{(2)}$.

Требуется:

дать содержательную интерпретацию первых двух главных компонент.

Решение

Из вида матрицы А следует, что первая главная компонента наиболее тесно связана с показателями: $x^{(1)}$ — число колесных тракторов $(a_{11} = r(x^{(1)}, z^{(1)}) = 0.95)$; $x^{(2)}$ — число зерноуборочных комбайнов $(a_{21} = r(x^{(2)}, z^{(1)}) = 0.97)$; $x^{(3)}$ — число орудий поверхностей обработки почвы на 100 га $(a_{31} = r(x^{(3)}, z^{(1)}) = 0.94)$. Поэтому первая главная компонента $z^{(1)}$ интерпретирована как уровень механизации работ.

Вторая главная компонента $z^{(2)}$ тесно связана с количествами удобрения $(x^{(4)})$ и средств защиты растений $(x^{(5)})$, расходуемых на гектар $(a_{42}=r(x^{(4)},z^{(2)})=0.88;\ a_{52}=r(x^{(5)},z^{(2)})=0.67)$. Соответственно $z^{(2)}$ интерпретируется как уровень химизации растениеводства.