

Лекции 7.12.20, 14.12.20

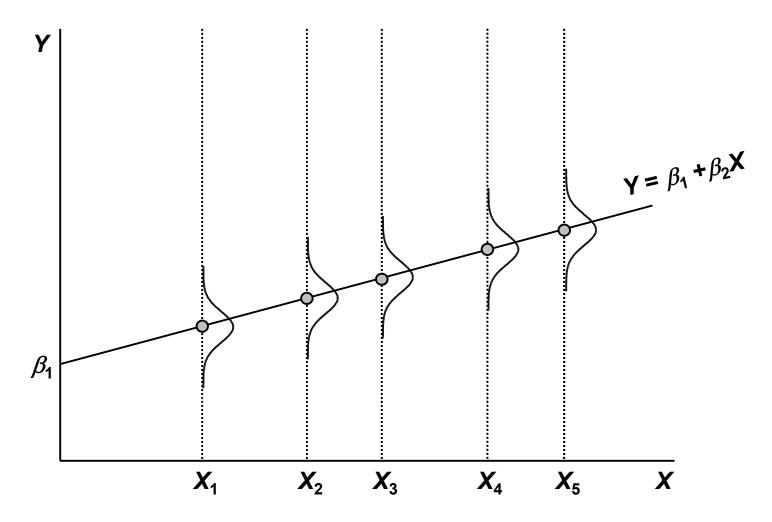
Гетероскедастичность

Демидова О.А. E-mail:demidova@hse.ru

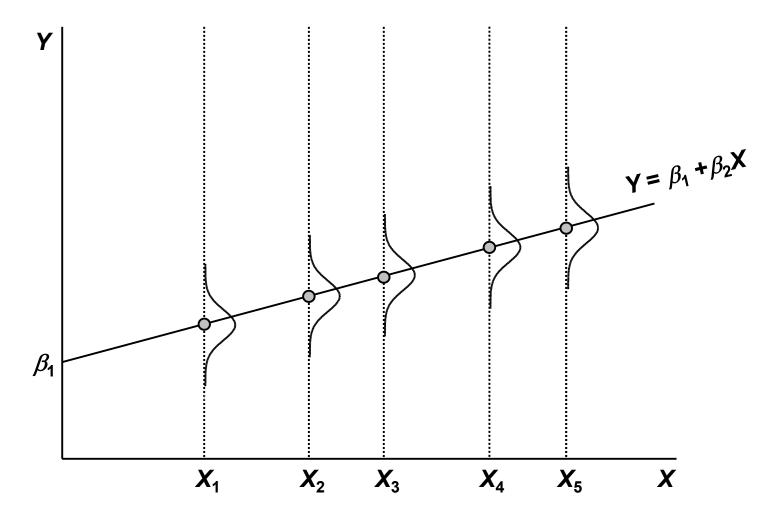


План лекции

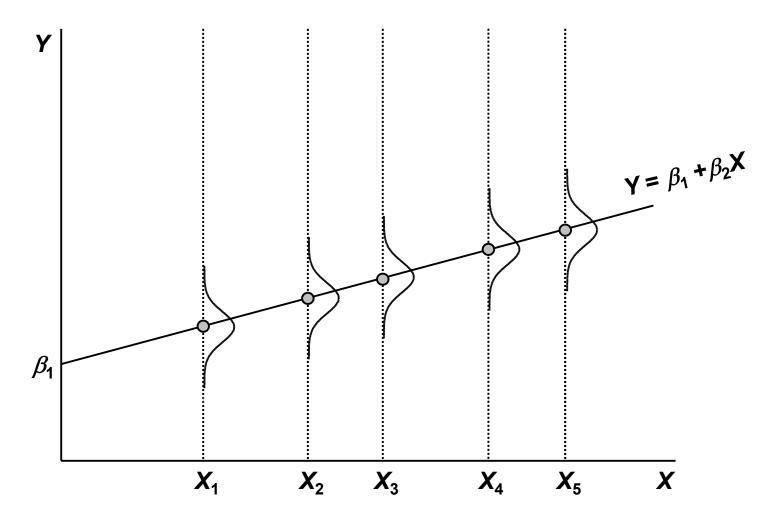
- 1) Нарушение гипотезы о гомоскедастичности ошибок регрессии. Последствия гетероскедастичности для оценок коэффициентов регрессии методом наименьших квадратов и проверки статистических гипотез.
- 2) Тесты на выявление гетероскедастичности.
- 3) Оценивание при наличии гетероскедастичности. Взвешенный метод наименьших квадратов.
- 4) Робастные стандартные ошибки оценок коэффициентов регрессии в форме Уайта (White).
- 5) Обобщенный метод наименьших квадратов



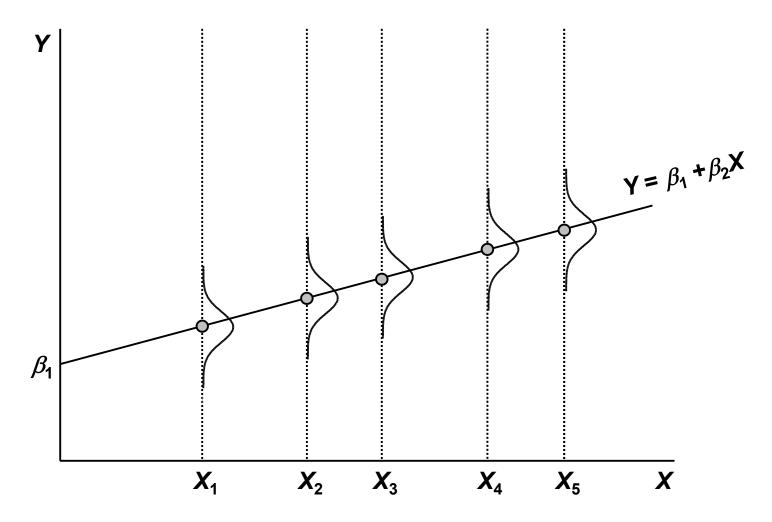
Одно из условий теоремы Гаусса — Маркова состоит в том, что возмущения u имеют нулевое математическое ожидание и одинаковую дисперсию.



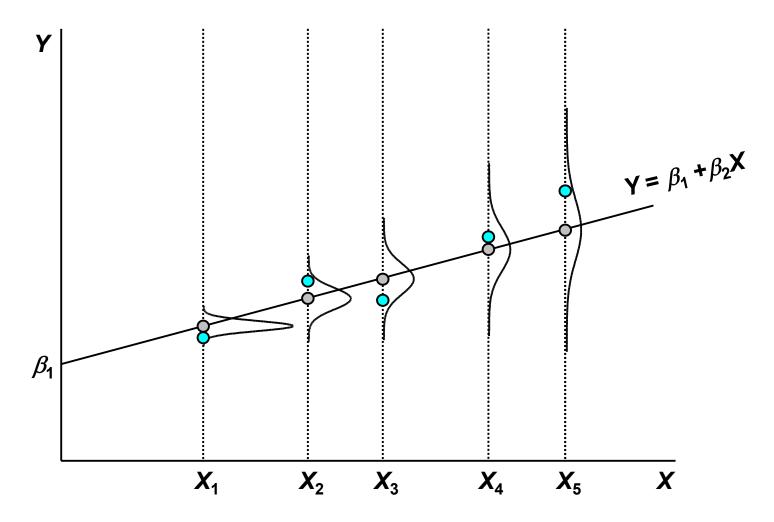
Было сделано также дополнительное предположение о нормальном законе распределения возмущений.



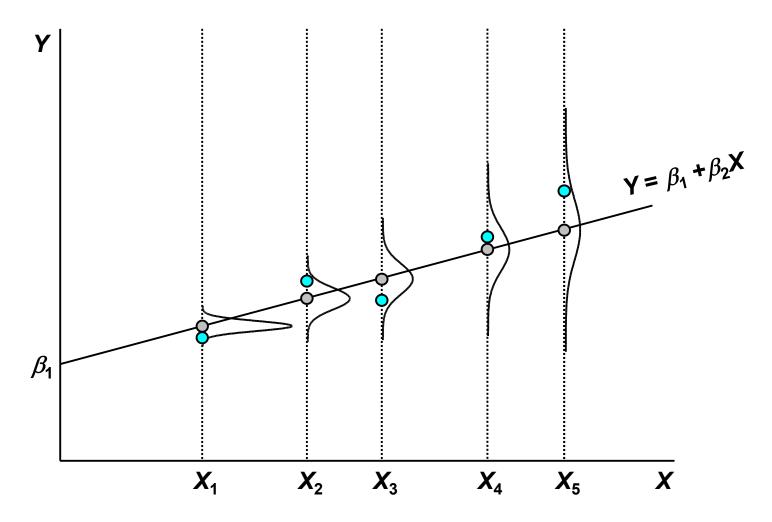
Свойство одинаковой дисперсии возмущений называется гомоскедастичностью.



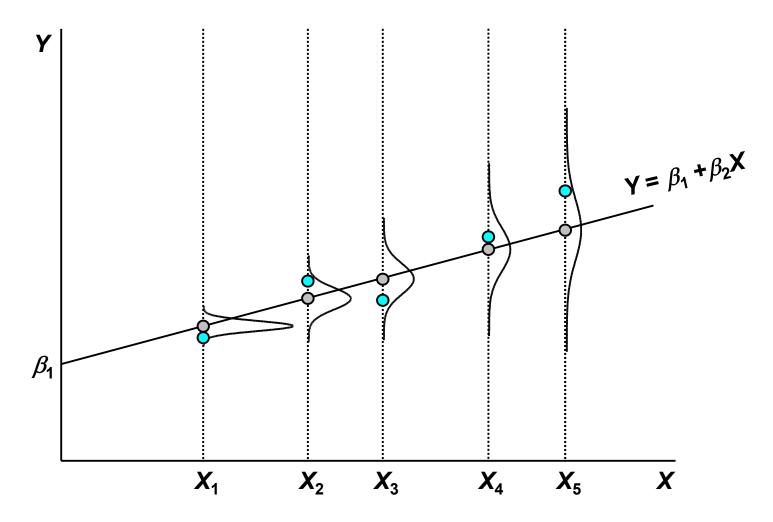
Линия теоретической регрессии $Y = \beta_1 + \beta_2 X$, которую мы не можем провести и проверить, одинаково ли распределены возмущения.



Если дисперсии возмущений различны, то это явление называется гетероскедастичностью.



Наличие гетероскедастичности можно заподозрить, если отклонение наблюдений от линии выборочной регрессии (остатки) достаточно сильно различаются.

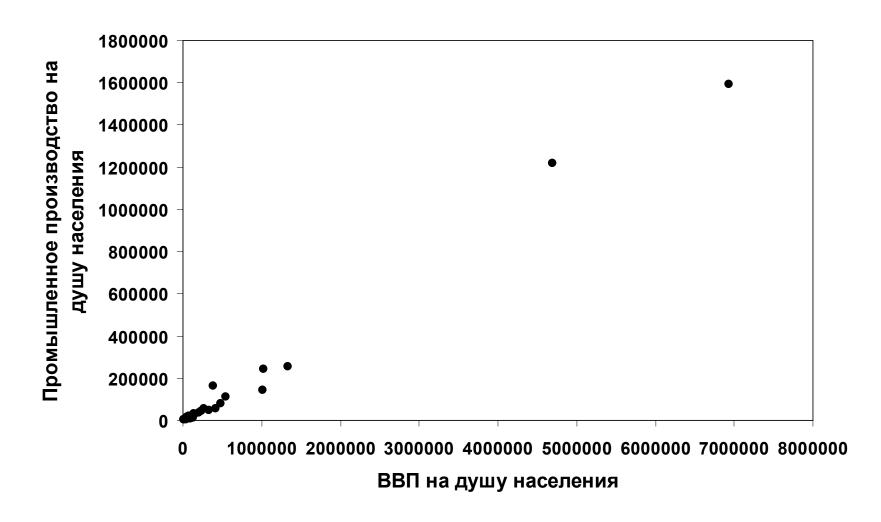


Однако ответ на вопрос, имеет ли место гетероскедастичность, можно получить только с помощью тестов.

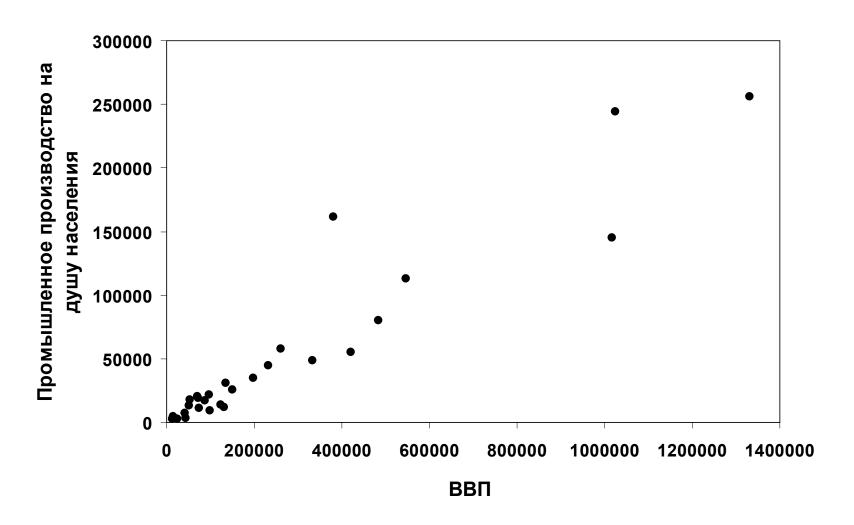
Последствия гетероскедастичности

Если предположение об одинаковых дисперсиях возмущений не выполняется, то

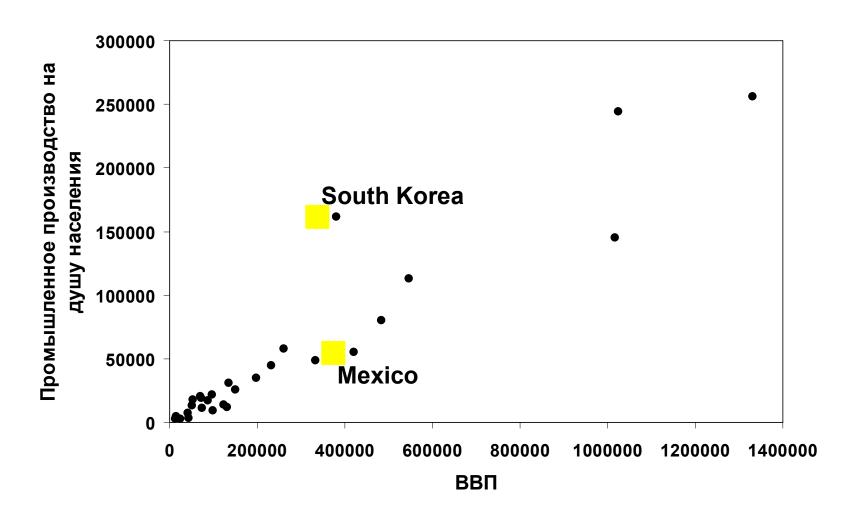
- стандартные ошибки коэффициентов регрессии вычисляются по неверным формулам
- •t тесты для проверки гипотез о конкретных значениях коэффициентов не дают правильных результатов
- •F тесты для проверки гипотез о линейных ограничениях на коэффициенты регрессии не дают правильных результатов
- •Оценки МНК коэффициентов регрессии больще не являются BEST, теряется эффективность оценок.



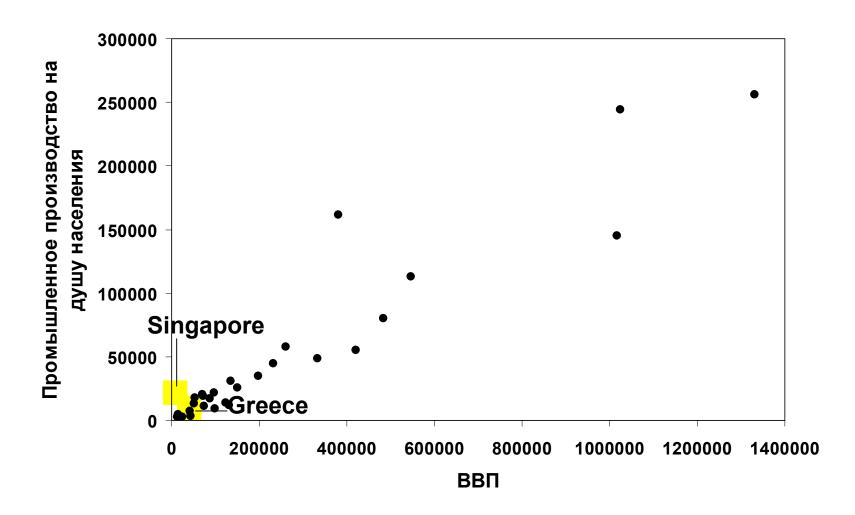
Данные для 30 стран в 1997.



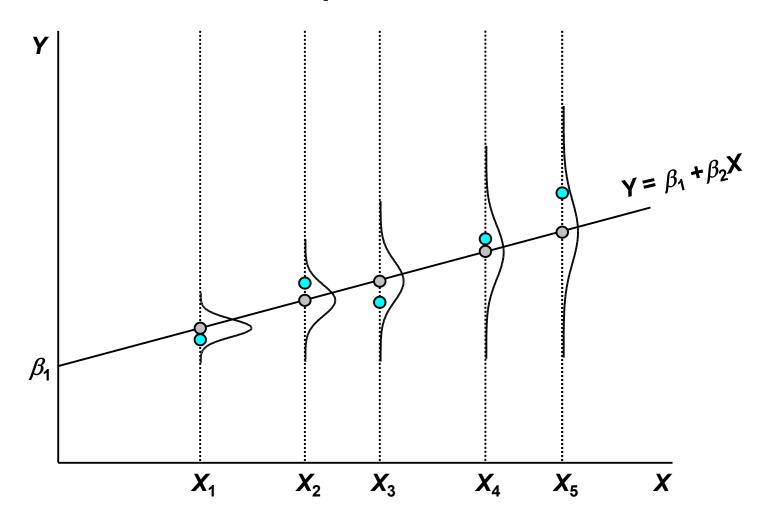
Взглянув на этот рисунок, можно сделать предположение, что с ростом ВВП дисперсия возмущений увеличивается.



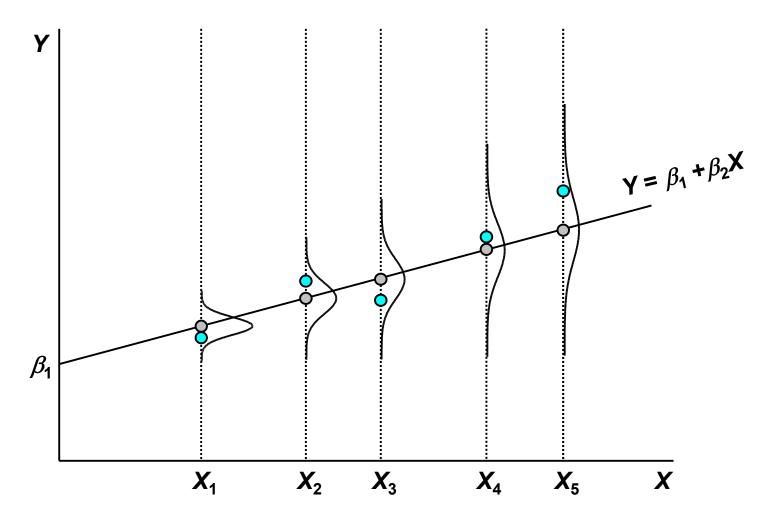
Сравним Южную Корею и Мексику с приблизительно одинаковым уровнем ВВП.



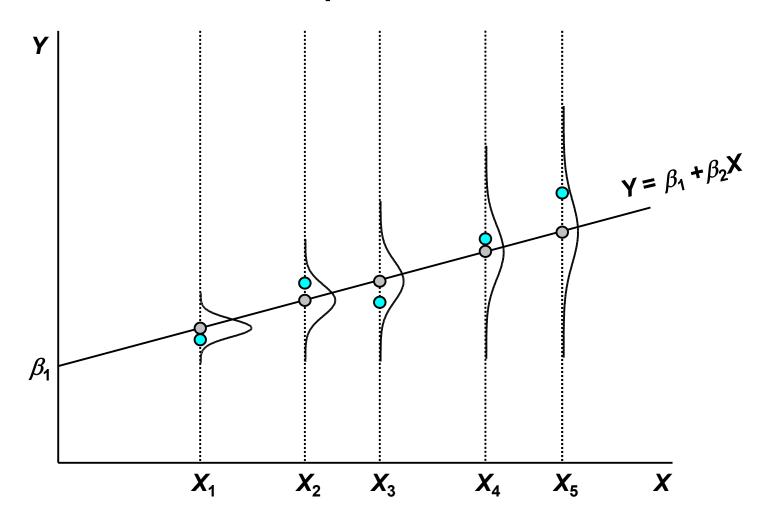
Другая пара для сравнения – Сингапур и Греция, также с почти одинаковым уровнем ВВП. Очевидно, что для первой пары с большим ВВП и разница больше. Можно предположить наличие гетероскедастичности.



Гетероскедастичность – различие дисперсий возмущений для различных наблюдений. Ясно, что видов гетероскедастичности может быть сколь угодно много.



Однако одним из самых распространенных видов гетероскедастичности является пропорциональность стандартного отклонения возмущений одной из объясняющих переменных.



Этот тип гетероскедастичности иллюстрируется на приведенной диаграмме. Дисперсия возмущений пропорциональна переменной X.

Основная и альтернативная гипотезы в тесте Голфелда – Квандта (и во всех остальных тестах, в которых проверяется, имеет ли место гетероскедастичность) формулируются следующим образом:

Н₀: гомоскедастичность

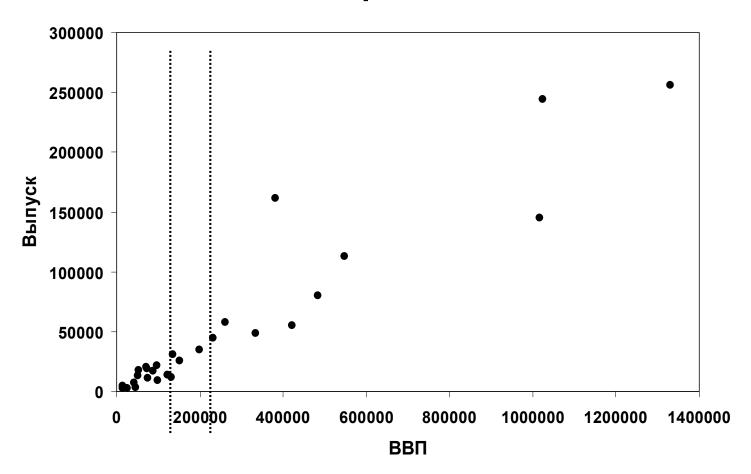
Н₁: гетероскедастичность

Однако сам тест зависит от того, какой вид гетероскедастичности мы предполагаем в альтернативной гипотезе.

$$Y_i = \beta_1 + \beta_2 X_{2i} + ... + \beta_k X_{ki} + u_i, \quad D(u_i) = \sigma_i^2, i = 1,...,n$$

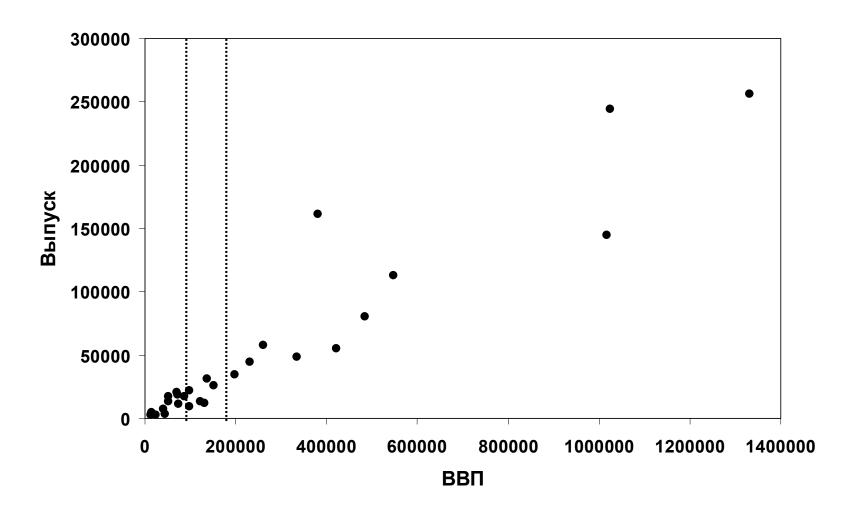
$$\mathbf{H_0:} \quad \boldsymbol{\sigma}_i^2 = \boldsymbol{\sigma}_u^2 \quad \forall i = 1, \dots, n$$

H₁:
$$\sigma_i \sim X_{ji}$$
 для некоторого X_j , $i = 1,...,n$

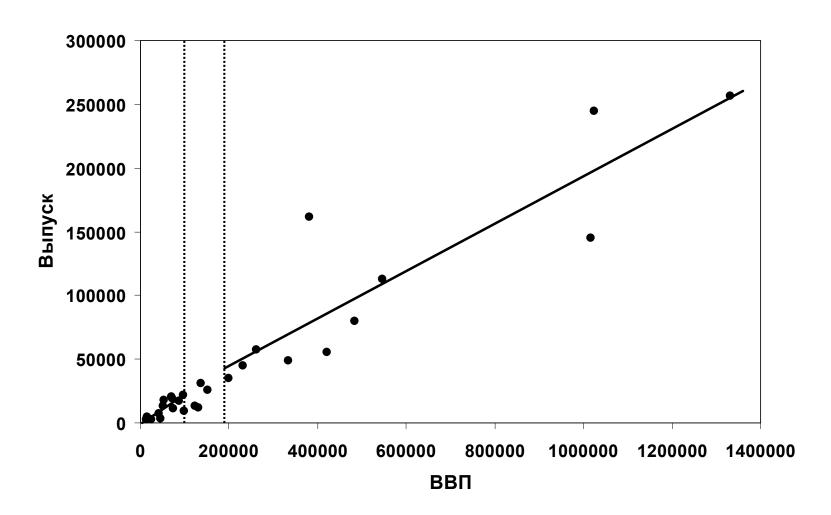


Для проведения теста Голдфелда — Квандта все наблюдения упорядочиваются по Хј и делятся на 3 части. Если выборка небольшая, то выделяют приблизительно 3/8 части всех наблюдений для первой и третьей части и приблизительно 1/4 в середине.

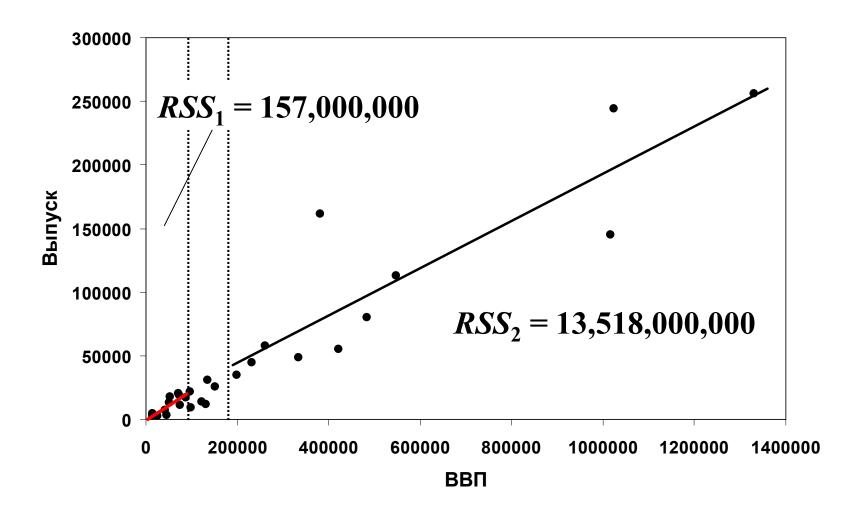
20



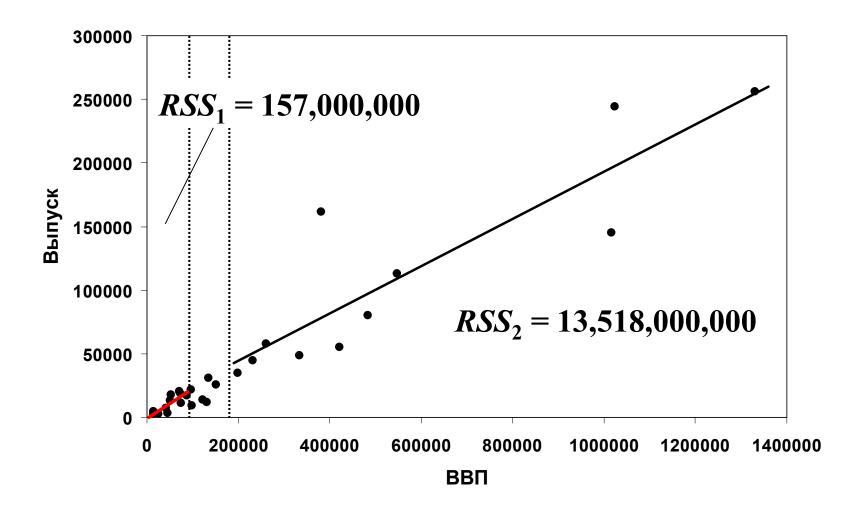
Для 28 стран оценивается зависимость выпуска продукции обрабатывающей промышленности от ВВП. Выделено 11 стран с маленьким ВВП, 6 со средним и 11 с большим.



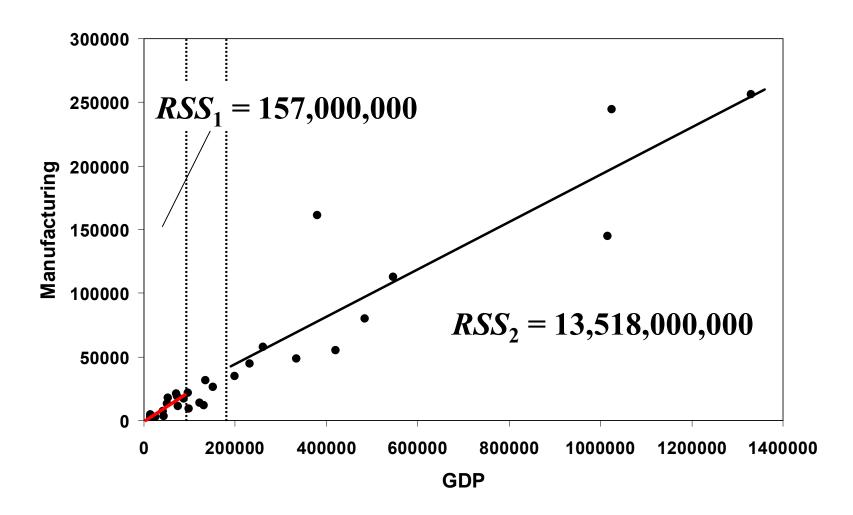
Отдельно оцениваются регрессии для 11 стран с маленьким ВВП и для 11 стран с большим ВВП.



Для каждой регрессии находятся суммы квадратов остатков RSS_1 и RSS_2 .

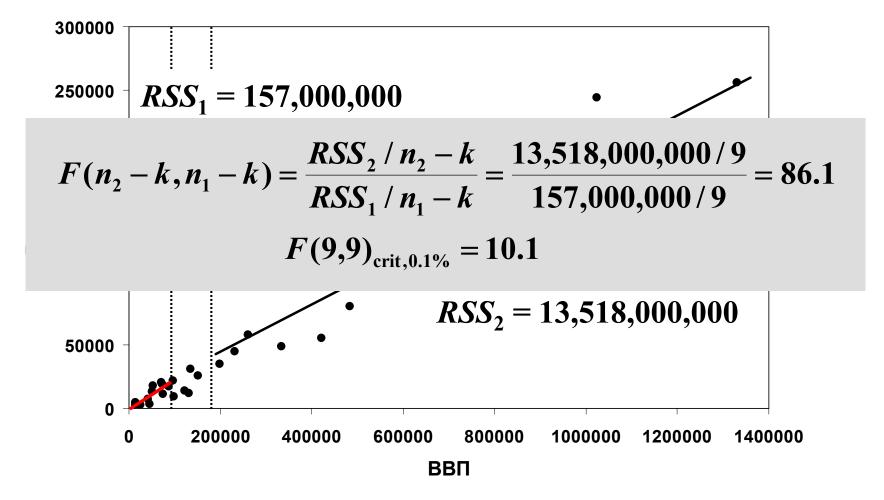


Если имеет место гомоскедастичность, RSS_1 и RSS_2 не должны сильно различаться (если число наблюдений в оцениваемых регрессиях совпадает).



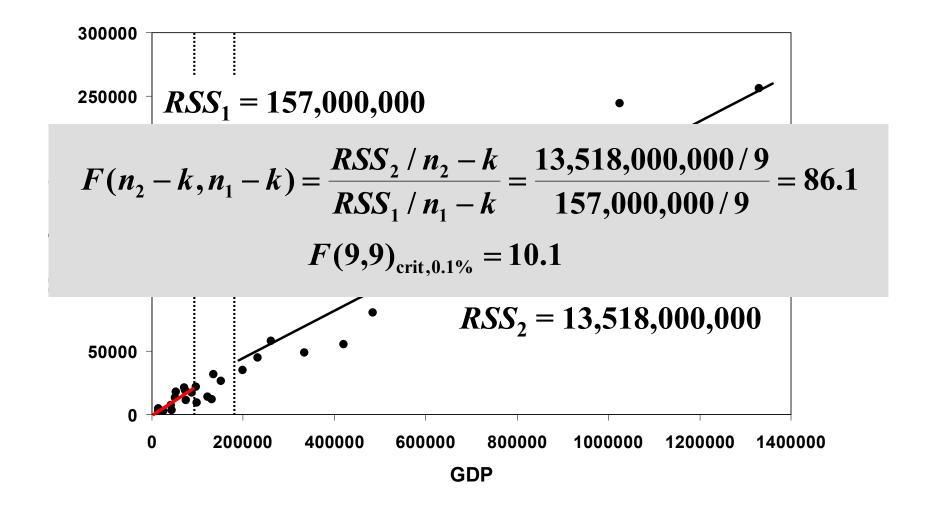
Однако в рассматриваемом примере RSS_2 значительно превышает RSS_1 .

Тестовая статистика в тесте Голдфелда - Квандта



Тестовая статистика F рассчитывается по приведенной выше формуле. В числителе – оценка дисперсии возмущений по последним n_2 наблюдениям, а в знаменателе - оценка дисперсии возмущений по первым n_1 наблюдениям. K – число параметров в модели.

Тестовая статистика в тесте Голдфелда - Квандта



Тестовая F – статистика превышает критическое значение даже при уровне значимости 0.1%. Нулевая гипотеза о гомоскедастичности отвергается.

Формальное описание теста Голфелда - Квандта

- Оценивается регрессия по всем наблюдениям.
- •Полезно взглянуть на график остатков. Может появиться предположение, что дисперсия возмущений увеличивается с ростом некоторой переменной.
- •Упорядочиваем все наблюдения по модулю подозрительной переменной.
- •Делим все наблюдения на три группы (если наблюдений достаточно много, то приблизительно на трети). Удобно, если в первой и третьей группах количество наблюдений одинаково.
- •Наблюдениями средней группы пренебрегаем, а по первым n_1 и последним n_2 наблюдениям оцениваем отдельные регрессии.
- •Используя суммы квадратов остатков (RSS) в оцененных регрессиях, рассчитываем тестовую статистику по формуле

$$F(n_2 - k, n_1 - k) = \frac{RSS_2 / (n_2 - k)}{RSS_1 / (n_1 - k)}$$

- •Сравниваем полученное значение F статистики с критическим (при выбранном уровне значимости).
- •Если значение F статистики превышает критическое, нулевая гипотеза о гомоскедастичности отвергается.

Тест Глейзера

Дисперсия возмущений не обязательно пропорциональна какомулибо фактору, может быть и другой вид зависимости, для определения которой используется тест Глейзера.

Тест Глейзера

$$Y_i = \beta_1 + \beta_2 X_{2i} + ... + \beta_k X_{ki} + u_i, \quad D(u_i) = \sigma_i^2, i = 1,...,n$$

$$\mathbf{H_0:} \quad \boldsymbol{\sigma_i^2} = \boldsymbol{\sigma_u^2} \quad \forall i = 1, \dots, n$$

Формальное описание теста Глейзера

- Оценивается регрессия по всем наблюдениям.
- •Сохраняются остатки регрессии е_і.
- •Оцениваются регрессии

$$|e_i| = \alpha + \beta X_i + u_i, i = 1,...,n$$

$$|e_i| = \alpha + \beta \sqrt{X_i} + u_i, i = 1,...n$$

$$|e_i| = \alpha + \beta \frac{1}{X_i} + u_i, i = 1,...,n$$

•Если коэффициент β значим хотя бы в одной из трех регрессий (значимость коэффициента проверяется как обычно с помощью t – статистики), то имеет место гетероскедастичность (соответствующего вида).

Тест Уайта

Н₀: гомоскедастичность

Н₁: гетероскедастичность

Вид гетероскедастичности не конкретизируется.

Формальное описание теста Уайта

- Оценивается регрессия по всем наблюдениям.
- •Сохраняются остатки регрессии е_і.
- •Оцениваются регрессия квадратов остатков на все регрессоры, их квадраты, попарные произведения и константу.
- •В последней оцененной регрессии находим коэффициент множественной детерминации R²
- •Вычисляем тестовую статистику по формуле nR². Тестовая статистика имеет распределение «хи квадрат» с k-1 степенями свободы, где k число оцениваемых коэффициентов.
- •Сравниваем полученное значение тестовой статистики с критическим при выбранном уровне значимости. Если значение тестовой статистики превышает критическое, то нулевая гипотеза о гомоскедастичности отвергается.

Тест Уайта

Привлекательной чертой теста Уайта является его универсальность. Однако этот тест не является конструктивным. Если гетероскедастичность выявлена, то тест Уайта не дает указания на функциональную форму гетероскедастичности. Единственным способом коррекции является применение стандартных ошибок в форме Уайта.

Пример применения теста Уайта

Оценена регрессия выпуска от ВВП для 28 стран. Остатки регрессии сохранены.

[.] predict EMANU, resid

[.] gen EMANUSQ = EMANU*EMANU

Проведение теста Уайта

- . gen GDPSQ = GDP*GDP
- . reg EMANUSQ GDP GDPSQ

. reg EMANOSQ	GDF GDF5Q					
Source	ss 	df	MS		Number of obs	= 28 = 3.35
Model Residual		2 6. 25 1.	5913e+18 9671e+18		F(2, 25) Prob > F R-squared Adj R-squared	<pre>= 0.0514 = 0.2114</pre>
	6.2361e+19				Root MSE	= 1.4e+09
	Coef.			• •	[95% Conf.	Interval]
GDP GDPSQ _cons	6271.896 0041155	2758.253 .0022626 4.51e+08	2.27 -1.82	0.032	591.1687	11952.62 .0005444 5.08e+08

В качестве зависимой переменной выбраны квадраты остатков, а в качестве независимых переменных – GDP и GDP в квадрате (т.к. переменная одна, то попарных произведений нет). В регрессию включена также константа.

Проведение теста Уайта

- . gen GDPSQ = GDP*GDP
- . reg EMANUSQ GDP GDPSQ

Source	ss				Number of obs	
Model		2 6.59	913e+18		Prob > F R-squared	= 0.0514
	6.2361e+19				Adj R-squared Root MSE	
EMANUSQ	Coef.	Std. Err.	t	P> t	 [95% Conf.	Interval]
GDP GDPSQ _cons	6271.896 0041155		2.27 -1.82 -0.93	0.032	591.1687	11952.62

Вычисляем тестовую статистику по формуле nR^2 , беря R^2 из таблицы.

Проведение теста Уайта

- . gen GDPSQ = GDP*GDP
- . reg EMANUSQ GDP GDPSQ

Source	SS	df	MS		Number of		28
 +-				E	· (2,	25) =	3.35
Model	1.3183e+19	2	6.5913e+18	I	Prob > F	=	0.0514
Residual	4.9179e+19	25	1.9671e+18	F	R-squared	=	0.2114
 +-				F	Adj R-squa	red =	0.1483
Total	6.2361e+19	27	2.3097e+18	F	Root MSE	=	1.4e+09

EMANUSQ	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]
GDP GDPSQ _cons		2758.253 .0022626 4.51e+08	-1.82	0.032 0.081 0.359	591.1687 0087754 -1.35e+09	11952.62 .0005444 5.08e+08

$$nR^2 = 28 \times 0.2114 = 5.92$$
 $\chi^2_{5\%}(2) = 5.99$

*R*² равен 0.2114 и *п* равно 28. Тестовая статистика равна 5.92. Критическое значение статистики «хи –квадрат» с двумя степенями свободы равно 5.99 при 5 % уровне значимости. Полученное значение тестовой статистики не превышает критическое, следовательно, нулевая гипотеза о гомоскедастичности не отвергается.

Тест Бройша - Пагана

$$Y_i = \beta_1 + \beta_2 X_{2i} + ... + \beta_k X_{ki} + u_i, \quad D(u_i) = \sigma_i^2, i = 1,...,n$$

$$\mathbf{H_0}: \quad \boldsymbol{\sigma}_i^2 = \boldsymbol{\sigma}_u^2 \quad \forall i = 1, ..., n$$

$$H_1$$
: $\sigma_i^2 \sim f(\alpha_0 + \alpha_1 Z_{1i} + ... + \alpha_r Z_{ri}),$ $\partial n = n = 1,..., n$ $\partial z = 1,..., n$

Вид функции f может быть любой.

Формальное описание теста Бройша - Пагана

• Оценивается регрессия

$$Y_i = \beta_1 + \beta_2 X_{2i} + ... + \beta_k X_{ki} + u_i, i = 1,...,n$$

по всем наблюдениям. Сохраняются остатки регрессии e_i, i = 1,...,n. Находится RSS.

•Находится оценка дисперсии возмущений по формуле

$$\sigma_u^2 = \frac{RSS}{n}$$

• Оценивается регрессия e^2 на $Z_1,...,Z_r$, находится ESS_0 .

Формальное описание теста Бройша - Пагана

•Тестовая статистика

$$\chi^2 = \frac{ESS_0}{2\hat{\sigma}^4}$$

- •Имеет распределение «хи квадрат» с r степенями свободы.
- •Если $\chi^2 > \chi^2_{cr,\alpha}(r)$ при выбранном уровне значимости,

то гипотеза Н₀ о гомоскедастичности отвергается.

Что делать в случае гетероскедастичности?

$$Y = \beta_1 + \beta_2 X + u$$

Предположим, что нам известны дисперсии возмущений σ_i^2 для всех наблюдений і = 1,...,n.

$$Y = \beta_1 + \beta_2 X + u$$

дисперсия $u_i = \sigma_i^2$

$$\frac{Y_i}{\sigma_i} = \beta_1 \frac{1}{\sigma_i} + \beta_2 \frac{X_i}{\sigma_i} + \frac{u_i}{\sigma_i}$$

Разделим обе части равенства на σ_i для каждого наблюдения.

$$Y = \beta_1 + \beta_2 X + u$$

дисперсия $u_i = \sigma_i^2$

$$\frac{Y_i}{\sigma_i} = \beta_1 \frac{1}{\sigma_i} + \beta_2 \frac{X_i}{\sigma_i} + \frac{u_i}{\sigma_i}$$

дисперсия новых возмущений
$$\left\{ \frac{u_i}{\sigma_i} \right\} = \frac{1}{\sigma_i^2}$$
 дисперсии u_i $= \frac{\sigma_i^2}{\sigma_i^2} = 1$

Тогда дисперсии возмущений в новой регрессии станут одинаковыми и равными 1.

Преобразование переменных

$$Y = eta_1 + eta_2 X + u$$
 дисперсия $u_i = \sigma_i^2$

$$\frac{Y_i}{\sigma_i} = \beta_1 \frac{1}{\sigma_i} + \beta_2 \frac{X_i}{\sigma_i} + \frac{u_i}{\sigma_i}$$

$$Y' = \beta_1 H + \beta_2 X' + u' \quad Y' = \frac{Y_i}{\sigma_i}, \quad H = \frac{1}{\sigma_i}, \quad X' = \frac{X_i}{\sigma_i}, \quad u' = \frac{u_i}{\sigma_i}$$

Все сводится к оценке новой регрессии с преобразованными факторами, оцениваем регрессию Y на X и H, которые определенны выше. Отметим, что в новой регрессии нет константы. β_1 становится коэффициентом наклона перед переменной $1/\sigma_i$.

$$Y=eta_1+eta_2X+u$$
 дисперсия $u_i=\sigma_i^2$
$$rac{Y_i}{\sigma_i}=eta_1rac{1}{\sigma_i}+eta_2rac{X_i}{\sigma_i}+rac{u_i}{\sigma_i}$$
 $Y'=eta_1H+eta_2X'+u'$ $Y'=rac{Y_i}{\sigma_i}, \ H=rac{1}{\sigma_i}, \ X'=rac{X_i}{\sigma_i}, \ u'=rac{u_i}{\sigma_i}$

Указанный метод называется взвешенным методом наименьших квадратов. Наибольший вес $1/\sigma_i$ получают наблюдения с наименьшей дисперсией возмущений σ_i .

$$Y = \beta_1 + \beta_2 X + u$$

variance of $u_i = \sigma_i^2$
 $\sigma_i = \lambda Z_i$

Однако на практике стандартные отклонения возмущений обычно неизвестны. Но, оказывается, достаточно знать эти стандартные отклонения с точностью до постоянного множителя. Предположим, что стандартные отклонения возмущений пропорциональны некоторой известной переменной Z_i .

$$Y=eta_1+eta_2X+u$$

дисперсия $u_i=\sigma_i^2$
 $\sigma_i=\lambda Z_i$
 $rac{Y_i}{Z_i}=eta_1rac{1}{Z_i}+eta_2rac{X_i}{Z_i}+rac{u_i}{Z_i}$

В этом случае мы достигаем гомоскедастичности остатков, разделив все переменные на Z_i .

$$Y=eta_1+eta_2X+u$$

дисперсия $u_i=\sigma_i^2$
 $\sigma_i=\lambda Z_i$
 $rac{Y_i}{Z_i}=eta_1rac{1}{Z_i}+eta_2rac{X_i}{Z_i}+rac{u_i}{Z_i}$

дисперсия
$$\left\{\frac{u_i}{Z_i}\right\} = \frac{1}{Z_i^2}\sigma_i^2 = \frac{\sigma_i^2}{\sigma_i^2/\lambda^2} = \lambda^2$$

$$Y' = \beta_1 H + \beta_2 X' + u'$$
 $Y' = \frac{Y_i}{Z_i}, H = \frac{1}{Z_i}, X' = \frac{X_i}{Z_i}, u' = \frac{u_i}{Z_i}$

Действительно, как показано выше, дисперсии новых остатков одинаковы и равны λ^2 . Нам нет необходимости знать λ^2 . Достаточно того, что это константа (т.е. одинаковые дисперсии для всех возмущений, гомоскедастичность).

$$Y = eta_1 + eta_2 X + m{u}$$
 дисперсия $u_i = \sigma_i^2$ $\sigma_i = \lambda m{Z}_i$ $rac{Y_i}{Z_i} = eta_1 rac{1}{Z_i} + eta_2 rac{X_i}{Z_i} + rac{m{u}_i}{Z_i}$ $Y' = eta_1 H + eta_2 X' + m{u}'$ $Y' = rac{Y_i}{Z_i}, \ H = rac{1}{Z_i}, \ X' = rac{X_i}{Z_i}, \ m{u}' = rac{m{u}_i}{Z_i}$

Если после выполнении теста Голдфелда – Квандта гипотеза о гомоскедастичности отвергается, то в качестве Z может быть использована переменная X_i .

$$Y=eta_1+eta_2X+u$$
 дисперсия $u_i=\sigma_i^2$
$$rac{Y_i}{\sigma_i}=eta_1rac{1}{\sigma_i}+eta_2rac{X_i}{\sigma_i}+rac{u_i}{\sigma_i}$$
 $Y'=eta_1H+eta_2X'+u'$ $Y'=rac{Y_i}{\sigma_i},$ $H=rac{1}{\sigma_i},$ $X'=rac{X_i}{\sigma_i},$ $u'=rac{u_i}{\sigma_i}$

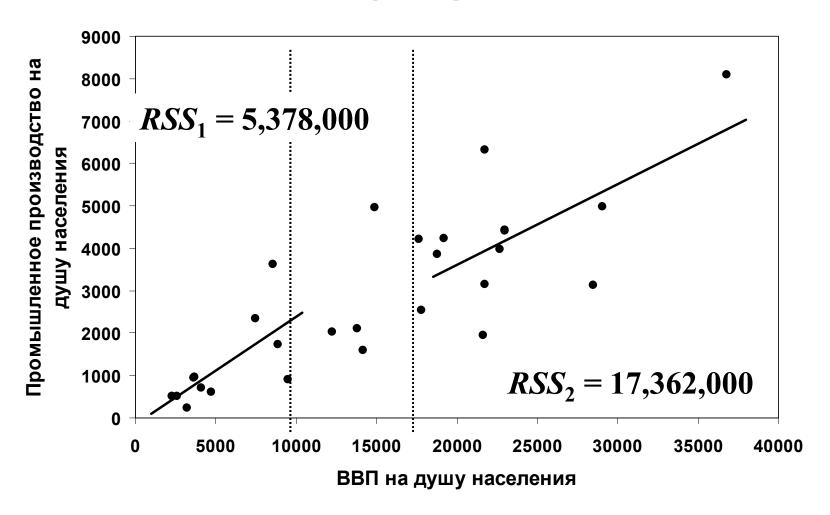
На практике вместо σ_i часто используют их оценки. Например, если после проведения теста Глейзера гипотеза о гомоскедастичности была отвергнута, поскольку в регрессии

$$|e_i| = \alpha + \beta X_i + u_i, i = 1,...,n$$

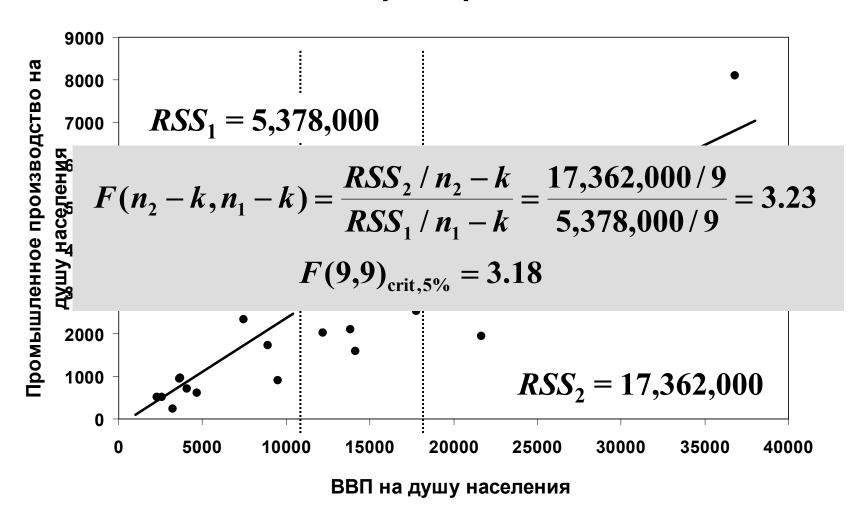
коэффициент β значим, то $\sigma_i = |e_i|$, i = 1,...,n



Пример зависимости производства на душу населения от ВВП на душу населения (диаграмма рассеивания).



Упорядочив страны по возрастанию ВВП на душу населения, разбивает их на три группы, средние наблюдения выкидывает, а для первой и последней группы наблюдений оцениваем регрессии и находим RSS.



Проводим тест Голфелда - Квандта. Поскольку тестовая статистика больше критической при 5% уровне значимости, нулевая гипотеза о гомоскедастичности отвергается.

$$egin{aligned} Y &= eta_1 + eta_2 X + u \ \end{aligned}$$
 дисперсия $u_i = \sigma_i^2 \ \sigma_i = \lambda X_i$

Альтернативная гипотеза в тесте Голфелда – Квандта предполагает пропорциональность стандартного отклонения возмущений объясняющей переменной (в данном примере X = GDP).

$$Y = \beta_1 + \beta_2 X + u$$

$$\partial ucnepcus = \sigma_i^2$$

$$\sigma_i = \lambda X_i$$

$$\frac{Y_i}{X_i} = \beta_1 \frac{1}{X_i} + \beta_2 + \frac{u_i}{X_i}$$

Напомним, что для получения эффективных оценок требуется преобразовать переменные, разделив их на ту переменную, которой пропорционально стандартное отклонение возмущений.

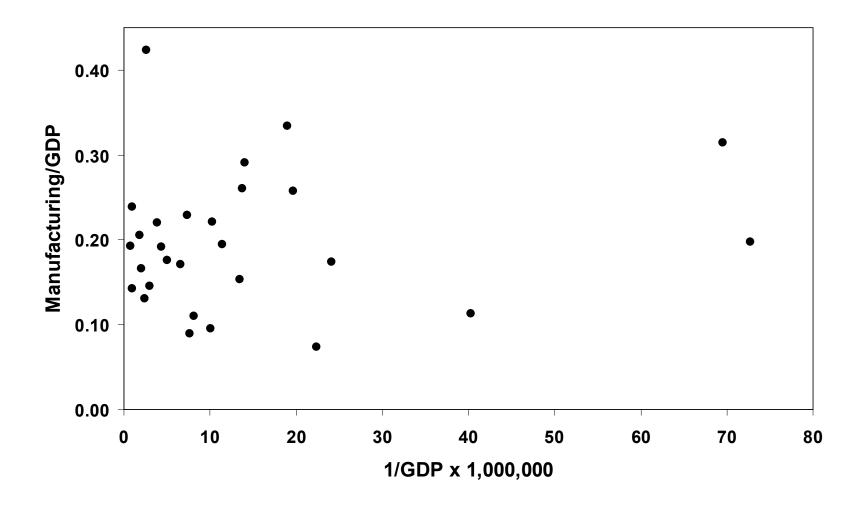
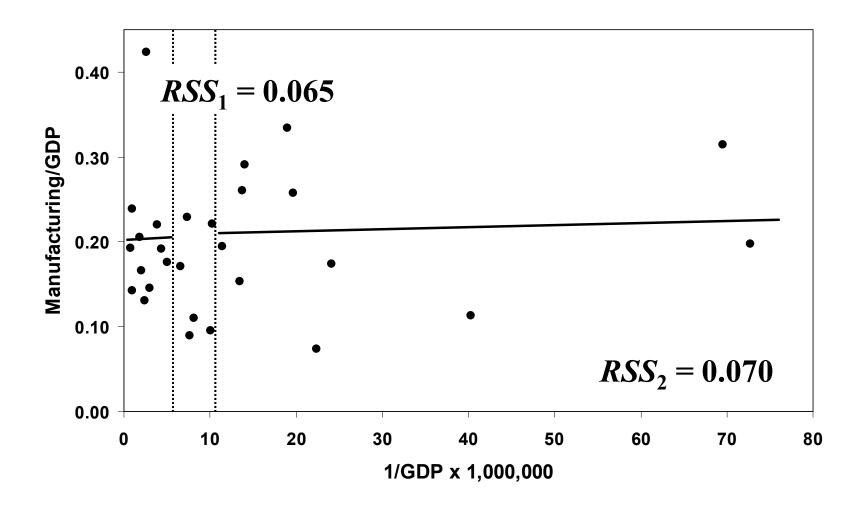
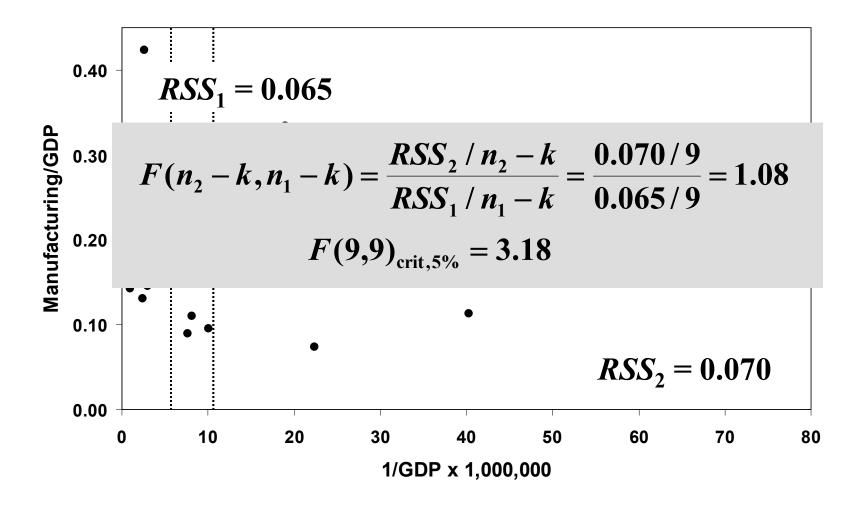


Диаграмма рассеяния в преобразованных переменных.

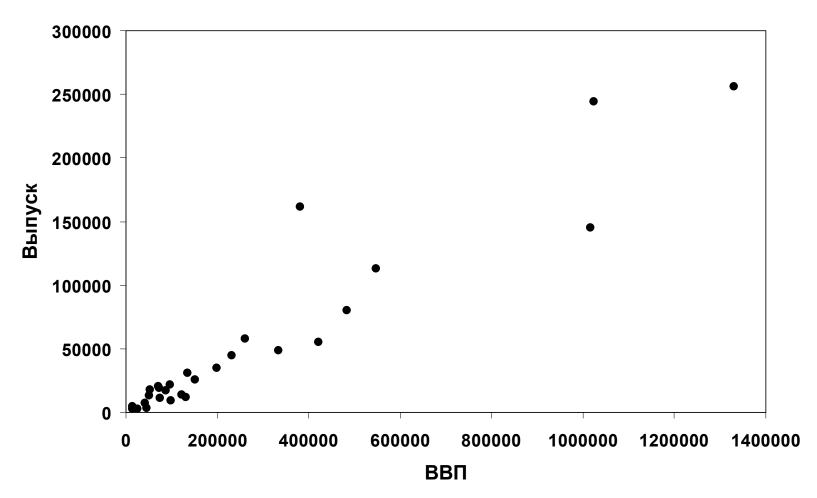


Снова проводим тест Голдфелда - Квандта.



На этот раз гипотеза о гомоскедастичности не отвергается. С помощью преобразования гетероскедастичность была устранена.

Второй способ борьбы с гетероскедастичностью



Существует другой способ борьбы с гетероскедастичностью, связанный с выбором другой функциональной формы модели, а именно, линейной в логарифмах.

Логарифмическое преобразование данных

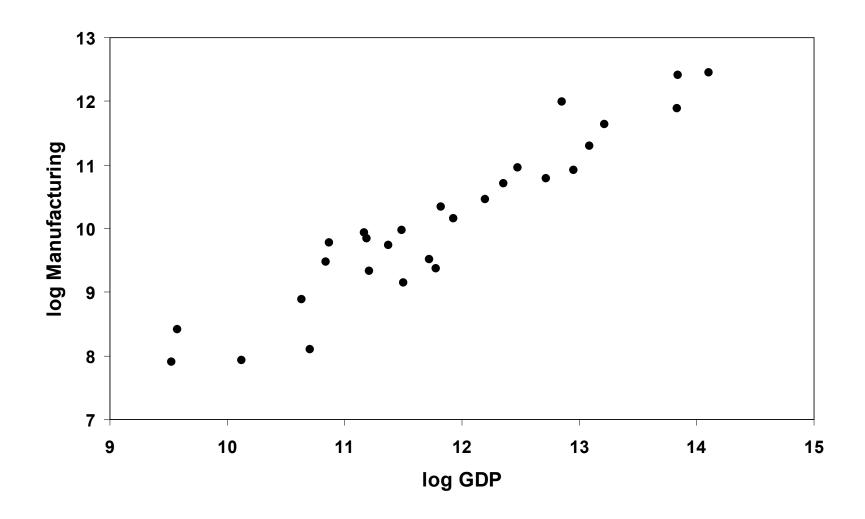
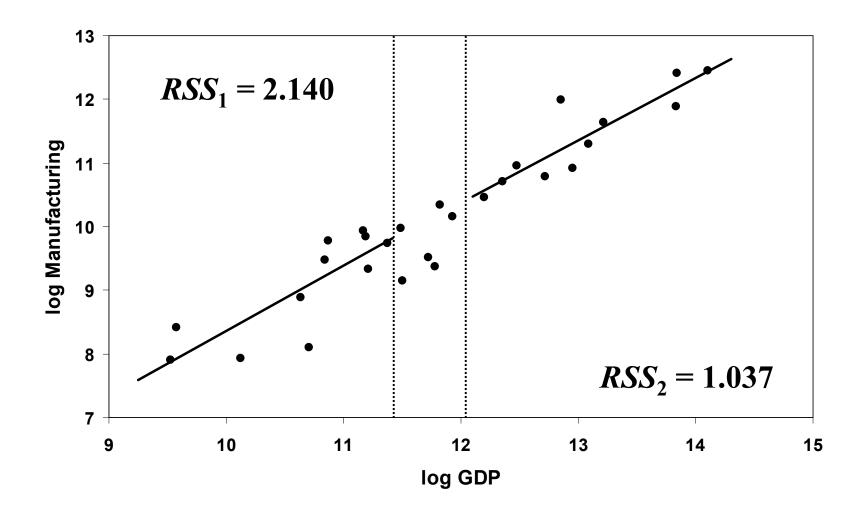


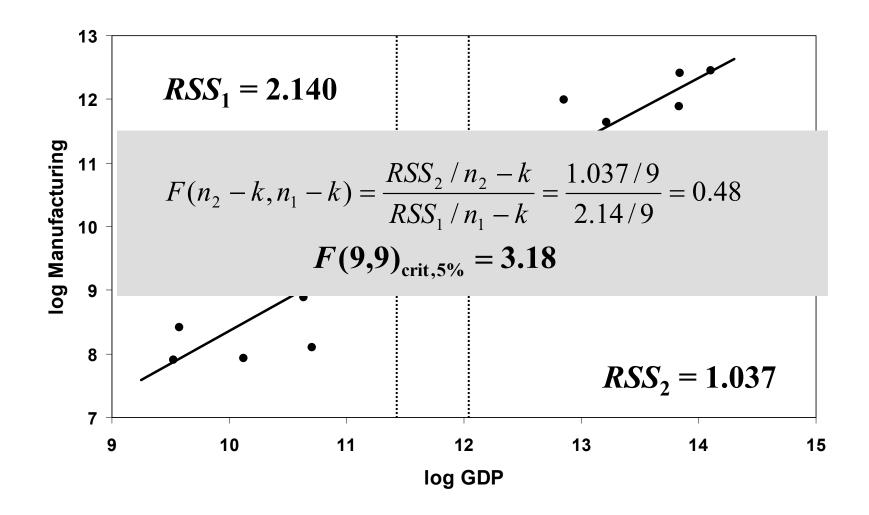
Диаграмма рассеяния для переменных в логарифмическом масштабе.

Линейная в логарифмах модель



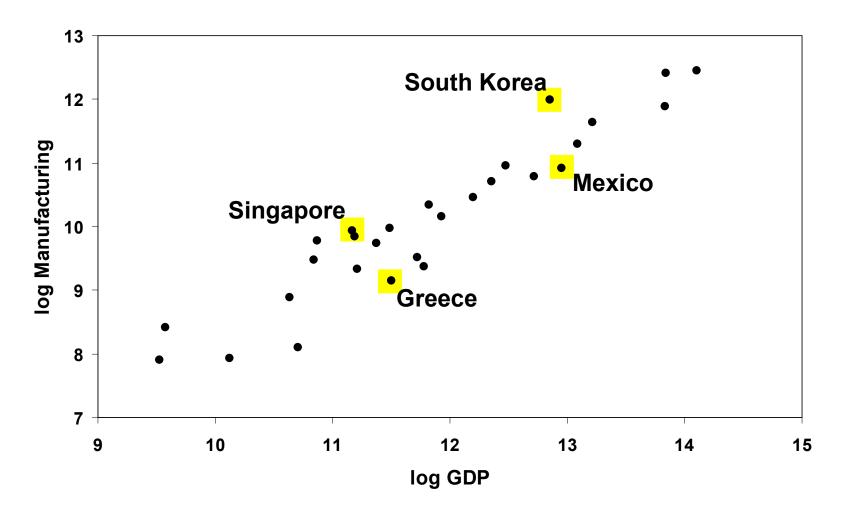
Проведем снова тест Голдфелда – Квандта для линейной в логарифмах модели.

HETEROSCEDASTICITY: WEIGHTED AND LOGARITHMIC REGRESSIONS



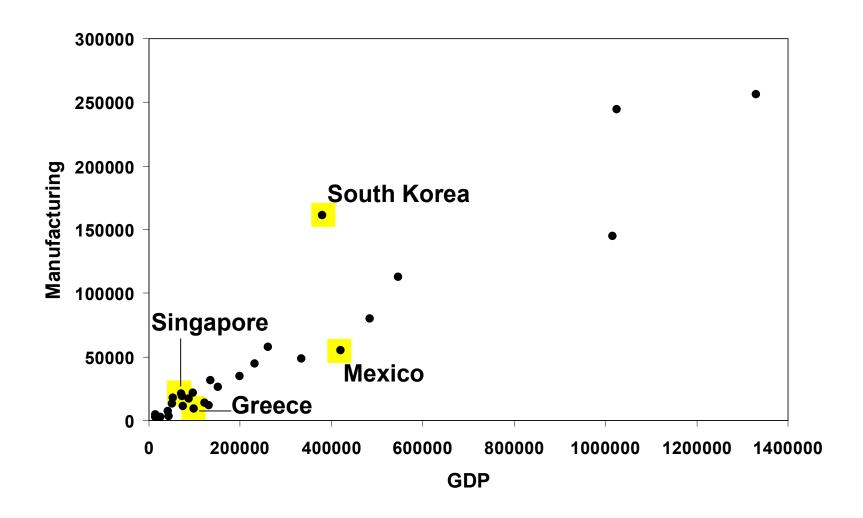
Нулевая гипотеза о гомоскедастичности не отвергается.

Логарифмический масштаб



В логарифмическом масштабе разнице между Южной Кореей и Мексикой не так сильно отличается от разницы для Сингапура и Греции, как при линейном масштабе.

Линейный масштаб



Различные спецификации

$$MA\hat{N}U = 604 + 0.194GDP$$
 $R^2 = 0.89$ $(5700)(0.013)$

$$\frac{MA\hat{N}U}{GDP} = 0.189 + 533 \frac{1}{GDP}$$

$$(0.019)(841)^{GDP}$$

$$\log M\hat{A}NU = -1.694 + 0.999 \log GDP \qquad R^2 = 0.90$$
(0.785) (0.066)

По одним и тем же данным оценено несколько моделей.

Состоятельные при гетероскедастичности стандартные ошибки Уайта

$$Y = X\beta + \varepsilon$$
$$\hat{\beta} = \beta + (X'X)^{-1} X'\varepsilon$$

$$Var[\hat{\beta}] = (X'X)^{-1} X'var[\epsilon]X (X'X)^{-1}$$

$$\widehat{Var}[\widehat{\beta}] = (X'X)^{-1} [X'\widehat{var}[\varepsilon]X] (X'X)^{-1}$$

Оценка Уайта: $n\widehat{Var}[\widehat{\beta}] =$
 $= \left(\frac{1}{n}X'X\right)^{-1} \cdot \left(\frac{1}{n}\sum_{s=1}^{n}e_{s}^{2}(x'_{s}x_{s})\right) \cdot \left(\frac{1}{n}X'X\right)^{-1}$

 x_s - s-ая строка матрицы X.

. reg manu gdp	99	đ£	MC		Number of obs	- 29
					F(1, 26)	
•	1.1600e+11				Prob > F	
Residual	1.4312e+10	26 550	462775		R-squared	= 0.8902
					Adj R-squared	= 0.8859
Total	1.3031e+11	27 4.82	264e+09		Root MSE	
	Coef.			P> t	[95% Conf.	
-					.1662665	.2211195
					-11111.91	
. reg manu gdp,	robust					
Regression with		dard errors	5		Number of obs	= 28
- 3						
					F(1, 26)	
					F(1, 26) Prob > F	= 116.39
						= 116.39 = 0.0000
					Prob > F	= 116.39 = 0.0000 = 0.8902
		 Robust			Prob > F R-squared	= 116.39 = 0.0000 = 0.8902
 manu					Prob > F R-squared	= 116.39 = 0.0000 = 0.8902 = 23462
+	Coef.	Std. Err.			Prob > F R-squared Root MSE	= 116.39 = 0.0000 = 0.8902 = 23462



. reg manu gdp	ss	df		MS		Number of obs	=	28
						F(1, 26)		
Model	1.1600e+11	1	1.16	00e+11		Prob > F		
	1.4312e+10					R-squared		
+-						Adj R-squared	=	0.8859
Total	1.3031e+11	27	4.82	264e+09		Root MSE	=	23462
manu	Coef.	Std.	Err.	t	P> t	[95% Conf.	In	terval]
gdp	.193693	.0133	3428	14.52	0.000	.1662665		2211195
·						-11111.91		
. reg manu gdp,	robust							
Regression with	robust stan	dard e	errors	;		Number of obs	=	28
						F(1, 26)	=	116.39
						Prob > F	=	0.0000
						R-squared	=	0.8902
						Root MSE	=	23462
		Robi	ıst					
manu				t	P> t	[95% Conf.	In	terval]
gdp	.193693	.0179	9 <mark>542</mark>	10.79	0.000	.1567877	•	2305983
_cons	603.9453	3542.	388	0.17	0.866	-6677.538	7	885.429

Пример1. История, произошедшая на Нью-Йорской фондовой бирже

Securities and Exchange Commission vs Antitrust division of the US Department of Justice

Биржевой комитет: Комиссионные брокерам не являются объектом соглашения между брокерами и клиентами, а устанавливаются биржевым комитетом

Подразделение министерства юстиции: Цены комиссионных д.б. либерализованы

История, произошедшая на Нью-йоркской фондовой бирже

Биржевой комитет:

$$\hat{Y}_{t=0mhowehue} = 476000 + 31.348X - 1.083 \times 10^{-6} X^2$$

где Y – доход брокерских компаний, X – количество акций в сделке.

Вывод: естественная монополия, не надо либерализовывать цены.

История, произошедшая на Нью-Йорской фондовой бирже

Подразделение министерства юстиции:

Дисперсия ошибок зависит от объема сделки. Надо поделить все переменные на \sqrt{X} . Новое оцененное уравнение:

$$\hat{Y}_{t=omhowehue} = 342000 + 25.77X + 4.34 \times 10^{-6}X^2$$

Вывод: это не естественная монополия, надо либерализовать цены.

Пример 2. Оценка функции спроса на макаронные изделия в России

База данных: РМЭЗ - Российский мониторинг экономического положения и здоровья населения

Переменные:

buymacar_c – стоимость макаронных изделий, купленных семьей за последние 7 дней (в руб.),

pr_macar - цена 1 кг макаронных изделий,

inc – доход семьи за месяц

Оценка функции спроса на макаронные изделия в России

reg buym	acar_c pr	_macar i	nc		
Source	SS	df MS		er of obs = 753) = 999.	
Model	4914486.12	2457243	.05 Prob >	F = 0.00	00
Residual	4310662.73	1753 2459	9.02038 Adj R-s	R-squared squared =	= 0.5327 0.5322
Total	9225148.83	1755 525	6.49506	Root MSE	= 49.589
buymacar	_c Coef.	Std. Err.	t P>t [95	5% Conf. Int	terval]
pr_macar	.5073996	.01136	44.67 0.000	.4851191	.5296802
inc	.0000559	.0000642	0.87 0.384	00007	.0001818
_cons	19.85896	1.443465	13.76 0.000	17.02786	22.69005

Тест Уайта

estat imtest, white

White's test for Ho: homoskedasticity against Ha:unrestricted heteroskedasticity

chi2(5) = 624.97

Тест Голдфелда – Квандта (упорядочивание по переменной inc)

```
sort inc
. reg buymacar c pr macar inc in 1/585
                 df
         SS
                      MS Number of obs = 295 \text{ F}(2, 292) = 465.68
Source
Model 839154.929
                                        Prob > F = 0.0000
                      2 419577.464
Residual 263093.755 292 901.006012
                                        R-squared = 0.7613
                                   Adj R-squared = 0.7597
Total 1102248.68 294 3749.14518
                                   Root MSE = 30.017
buymacar c Coef.Std. Err. t P>t [95% Conf.
                                                 Intervall
pr macar 2.716744 .0894214 30.38
                                   0.0002.540752 2.892736
inc -.0044199 .0023256 -1.900.058-.0089969 .0001572
cons -11.64927
                 5.555395 -2.10 0.037 -22.58296 -.715578
. reg buymacar_c pr_macar inc in 1172/1756
Source
         SS df MS
                          Number of obs = 293
                          F(2, 290)
                                        = 2564.69
                                   Prob > F = 0.0000
Model 1861980.84 2
                     930990.42
Residual 105270.882 290 363.003043
                                   R-squared = 0.9465
                                   Adj R-squared = 0.9461
Total 1967251.72 292 6737.16343
                                   Root MSE = 19.053
buymacar c
             Coef.Std. Err. t P>t [95% Conf.
                                                 Interval]
pr macar .9843328 .013775 71.46 0.000.9572211 1.011444
inc .0021632 .0013107 1.65 0.100-.0004165 .0047429
cons -6.335153 8.961121 -0.71 0.480-23.97223 11.30193
```

Тест Голдфелда – Квандта (упорядочивание по переменной inc)

$$F = \frac{RSS_2/(n_2 - k)}{RSS_1/(n_1 - k)} < 1 \Longrightarrow F < F^{cr}$$

Вывод: Гипотеза H_0 не отвергается, т.е. нет гетероскедастичности (по переменной inc)

Тест Голдфелда – Квандта (упорядочивание по переменной pr_macar)

```
sort pr_macar
. reg buymacar c pr macar
                           inc in 1/585
           SS
                    df
                         MS
                                    Number of obs = 585
Source
             F(2, 582)
                           = 0.30
Model
        309.359477
                   2
                       154.679738
                                        Prob > F = 0.7404
                                        R-squared = 0.0010
Residual 299328.145 582 514.309528
                                    Adj R-squared = -0.0024
Total 299637.505
                584 513.077919
                                    Root MSE = 22.678
           Coef. Std. Err. t P>t [95% Conf.
buymacar c
                                                 Interval]
pr_macar .3833284
                   .6208139 0.62
                                    0.537-.8359801 1.602637
                            -0.49
inc
         -.0000419
                   .000085
                                    0.622-.000209 .0001251
        21.96761
                   8.479713 2.59
                                    0.0105.313038 38.62217
cons
. reg_buymacar_c pr_macar
                           inc in 1172/1756
           SS
Source
                    df
                         MS
                                    Number of obs = 585
                                    F(2, 582) = 364.75
Model
        4793973.58 2 2396986.79
                                             Prob > F = 0.0000
Residual 3824678.33 582 6571.61226
                                        R-squared = 0.5562
                                    Adj R-squared = 0.5547
Total 8618651.92
                  584 14757.9656
                                    Root MSE = 81.065
buymacar c
             Coef.
                     Std. Err. t
                                      P>t
                                             [95% Conf.
                                                          Interval]
           .5059595 .0187335 27.01 0.000
                                             .469166
                                                      .542753
pr_macar
                               0.14 0.891 -.0002291 .0002636
           .0000173 .0001254
inc
           22.21863 3.995971
                               5.56 0.000
                                            14.37035 30.06691
cons
```

Тест Голдфелда – Квандта (упорядочивание по переменной pr_macar)

$$F = \frac{RSS_2}{RSS_1}^{(*)} = \frac{382467833}{299328.145} = 12.7775 > F_{0.05}^{cr}$$

Вывод: Гипотеза H_0 отвергается, есть гетероскедастичность (по переменной pr_macar)

^{* -} т.к. число наблюдений в выборках совпадает

Преобразование данных и оценивание новой регрессии

gen buymacar_cnew = buymacar_c/ pr_macar
(1579 missing values generated)

. gen consnew =1/ pr_macar(1579 missing values generated)

. gen incnew= inc/ pr_macar(1579 missing values generated)

. reg buymacar_cnew consnew incnew

Source	SS	df	MS		F(Number of 2, 1753)	obs = 1756 = 58.43
Model	241.386174	2	120.69	3087	•	ob > F = 0.0	
Residual	3621.08302	1753	2.065	64918	R-	squared = 0.0)625
					Ad	lj R-squared	= 0.0614
Total	3862.46919	1755	2.2008	33715	Ro	oot MSE = 1.4	1372
buymacaı	r_cnew Coe	f. St	d. Err.	t	P>t	[95% Conf	. Interval]
consnew	20.8184	3 2.0	1338	10.34	0.000	16.86955	24.76731
incnew	.0000831	.00	00388	2.14	0.032	7.05e-06	.0001592
_cons	.3681707	.12	18333	3.02	0.003	.1292168	.6071246

Сравнение результатов начальной и скорректированной регрессий

buymacar_	_c Coef.	Std. Err.	t P>t [95	% Conf.	Interval]
pr_macar	.5073996	.01136	44.670.000		1 .5296802
inc	.0000559	.0000642	0.87 0.384	00007	.0001818
_cons	19.85896	1.443465	13.76 0.000	17.0278	6 22.69005

buymacar_cnew Coef. Std. Err.			t	P>t [95% Conf. Interval]		
consnew	20.81843	2.01338	10.34	0.000	16.86955 24.76731	
incnew	.0000831	.0000388	2.14	0.032	7.05e-06 .0001592	
_cons	.3681707	.1218333	3.02	0.003	.1292168 .6071246	

Обобщенный метод наименьших квадратов

$$Y = X\beta + \varepsilon$$

Выполнены все условия ТГМ, кроме скалярности ковариационной матрицы ошибок регрессии

 $Var[\epsilon] = \Omega$ – известная матрица. Оценка МНК коэффициентов β в этом случае будет несмещенной, но не эффективной.

Ω – положительно определенная симметричная матрица ⇒

 $\Omega = C^{-1}\Lambda C$, Λ - диагональная матрица (на диагонали – собственные числа), $C^{-1} = C'$

Обобщенный метод наименьших квадратов

$$\Omega^{-1/2} = C^{-1} \Lambda^{-1/2} C$$

$$Y = X\beta + \varepsilon$$

$$\Omega^{-1/2}Y = \Omega^{-1/2}X\beta + \Omega^{-1/2}\varepsilon,$$

$$Y^* = X^* \beta + \varepsilon^*$$

Обобщенный метод наименьших квадратов

$$Y^* = X^* \boldsymbol{\beta} + \boldsymbol{\varepsilon}^*,$$

$$\widehat{\beta}_{GLS} = (X^*'X^*)^{-1} (X^*'Y^*) = ... =$$

 $= (X'\Omega^{-1}X)^{-1} (X'\Omega^{-1}Y)$ — эффективная оценка.

Матрицу Ω достаточно знать с точностью до пропорциональности.



Thank you for your attention!

20, Myasnitskaya str., Moscow, Russia, 101000 Tel.: +7 (495) 628-8829, Fax: +7 (495) 628-7931 www.hse.ru