# **ЛЕКЦИЯ 3 3 модуль**

# МОДЕЛИ БИНАРНОГО ВЫБОРА

Демидова О.А.

# План лекции

- 1) Модель линейной вероятности, ее недостатки
- 2) Логит и Пробит модели, их оценивание
- 3) Интерпретация результатов оценивания моделей с бинарными зависимыми переменными
- 4) Показатели качества оценки моделей бинарного выбора

# Модель линейной вероятности

$$Y_i = \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki} + \varepsilon_i$$

$$Y_i = E(Y_i) + \varepsilon_i$$

# Найдем математическое ожидание Үі.

$$p_i = p(Y_i = 1)$$

$$E(Y_i) = 1 \times p_i + 0 \times (1 - p_i) = p_i =$$

$$= \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}$$

$$p_i = p(Y_i = 1) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}$$

# Модель линейной вероятности

$$p_i = p(Y_i = 1) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}$$

Если мы будем оценивать модель с качественной зависимой переменной, как и ранее, с помощью МНК, мы получим указанную выше модель, называемую моделью линейной вероятности.

# Модель линейной вероятности

Однако линейная вероятностная модель имеет ряд серьезных недостатков:

Одним из главных недостатков линейной вероятностной модели является следующий: оцененные значения вероятности могут оказаться больше 1 или меньше 0,

Распределение случайного члена не является нормальным,

Можно показать, что дисперсия случайного члена зависит от X, таким образом, имеет место проблема гетероскедастичности.



Обычным способом решения этой проблемы является предположение о том, что вероятность является S — образной функцией от переменной Z, F(Z) принимает значения на интервале (0,1), где Z является линейной функцией от объясняющих переменных.

Другой способ получения модели:

$$P(Y_i = 1) = F(\beta_0 + \beta_1 X_{1i} + ... + \beta_k X_{ki}) (*)$$

Предположим, что существует латентная переменная  $Y_i^*$ ,

связанная с переменной Х обычным регрессионным уравнением:

$$Y_{i}^{*} = \beta_{0} + \beta_{1}X_{1i} + ... + \beta_{k}X_{ki} + \varepsilon_{i}, i = 1,...,n,$$

где возмущения  $\varepsilon_{i}$  независимы и одинаково распределены,

$$E(\varepsilon_i) = 0$$
,  $D(\varepsilon_i) = \sigma^2$ 

и F – функция распределения нормированных возмущений.

Функция плотности нормированных возмущений симметрична.

Y<sub>i</sub>\* - латентная (ненаблюдаемая переменная)


$$Y_i = 1$$
, если  $Y_i^* \ge 0$ ,  $i = 1,...,n$ ,

$$Y_i = 0$$
, если  $Y_i * < 0$ ,  $i = 1,...,n$ ,

Тогда 
$$P(Y_i = 1) = P(Y_i^* \ge 0) = P(\beta_0 + \beta_1 X_{1i} + ... + \beta_k X_{ki} + \epsilon_i \ge 0) =$$

$$\begin{split} & P(\epsilon_{i} \geq -\beta_{0} - \beta_{1}X_{1i} - ... - \beta_{k}X_{ki}) = P(\epsilon_{i} \leq \beta_{0} + \beta_{1}X_{1i} + ... + \beta_{k}X_{ki}) = \\ & = F((\beta_{0} + \beta_{1}X_{1i} + ... + \beta_{k}X_{ki})/\sigma), \end{split}$$

что с точностью до нормировки совпадает с (\*).




Если функция F является логистической (формула для этой функции приведена выше), то соответствующая модель называется логит - моделью.

$$p = F(Z) = \frac{1}{1 + e^{-Z}}$$

$$\frac{dp}{dZ} = \frac{(1 + e^{-Z}) \times 0 - 1 \times (-e^{-Z})}{(1 + e^{-Z})^2}$$
$$= \frac{e^{-Z}}{(1 + e^{-Z})^2}$$

Производная функции F(Z) называется функцией плотности. Выше вычислена функция плотности для логистической функции.



На рисунке изображен график функции плотности f(Z) для логистической функции.

Для оценки параметров моделей бинарного выбора используется ММП.

Функция правдоподобия в этом случае имеет вид:

$$L(\beta) = \prod_{Y_i=1} F(\beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}) \prod_{Y_i=0} (1 - F(\beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki})) =$$

$$= \prod_{i=1} \left[ F(\beta_0 + \beta_1 X_{1i} + \ldots + \beta_k X_{ki}) \right]^{Y_i} \left[ 1 - F(\beta_0 + \beta_1 X_{1i} + \ldots + \beta_k X_{ki}) \right]^{1-Y_i}$$

Логарифмическая функция правдоподобия:

$$l(\beta) = \ln L(\beta) = \sum_{i=1}^{n} [Y_i \ln F(\beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}) + (1 - Y_i) \ln(1 - F(\beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}))]$$

Необходимые условия экстремума первого порядка:

$$\frac{\partial l(\beta)}{\partial \beta_{j}} = \frac{1}{1 + 1} \left[ \frac{f(\beta_{0} + \beta_{1}X_{1i} + \dots + \beta_{k}X_{ki})}{F(\beta_{0} + \beta_{1}X_{1i} + \dots + \beta_{k}X_{ki})} Y_{i} + \frac{f(\beta_{0} + \beta_{1}X_{1i} + \dots + \beta_{k}X_{ki})}{F(\beta_{0} + \beta_{1}X_{1i} + \dots + \beta_{k}X_{ki})} \right] = 0,$$


$$j = 0, \dots, k$$

Для логит-модели эта система уравнений может быть сведена к виду:

$$\sum_{i=1}^{n} [Y_i - \Lambda (\beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki})] X_{ji} = 0 \quad j = 0, \dots, k$$

Эта система уравнений решается с помощью численных методов.


Матрица Гессе для логит-модели является отрицательно определенной (детали см. Green, издание 7, с.691-692), поэтому найденное решение является максимумом.



Пример использования логит – модели для оценки вероятности окончания средней школы. В качестве объясняющей выбрана переменная *ASVABC*.

### . logit GRAD ASVABC

# Результаты оценивания.



# Оцененная модель.

### . logit GRAD ASVABC

```
Iteration 0: log likelihood = -118.67769
Iteration 1: log likelihood = -104.45292
Iteration 2: log likelihood = -97.135677
Iteration 3: log likelihood = -96.887294
Iteration 4: log likelihood = -96.886017
```

Logit estimates	Number of obs	=	540
	LR chi2(1)	=	43.58
	Prob > chi2	=	0.0000
Log likelihood = $-96.886017$	Pseudo R2	=	0.1836

GRAD		Std. Err.		P> z	[95% Conf.	_
ASVABC	.1313626	.022428	5.86	0.000	.0874045	.1753206
_cons	-3.240218	. 9444844	-3.43	0.001	-5.091373	-1.389063

$$\hat{Z} = -3.240 + 0.131 ASVABC$$

Коэффициент перед переменной ASVABC является значимым.

$$p = F(Z) = \frac{1}{1 + e^{-Z}}$$

$$Z = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

В случае нелинейных моделей говорят о предельном эффекте объясняющего фактора.  $^{21}$ 

$$p = F(Z) = \frac{1}{1 + e^{-Z}}$$

$$Z = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

$$\frac{\partial p}{\partial X_i} = \frac{dp}{dZ} \frac{\partial Z}{\partial X_i} = f(Z)\beta_i = \frac{e^{-Z}}{(1 + e^{-Z})^2} \beta_i$$

Предельный эффект объясняющего фактора X<sub>i</sub> (если X – непрерывная переменная) – это частная производная по этой переменной. Вычисляется эта производная по правилу вычисления производной сложной функции. Предельный эффект i – го объясняющего фактора не является константой, а зависит от других переменных

$$p(X_1, X_2, \ldots, X_j = 1, \ldots, X_k) -$$

$$p(X_1, X_2, \dots, X_j = 0, \dots, X_k)$$

Предельный эффект объясняющего фактора  $X_j$  (если  $X_j$  – dummy переменная).

### . sum GRAD ASVABC

Variable	•	Obs		Std. Dev.	Min	Max
GRAD	T		.9425926		0	1
ASVABC	1	540	51.36271	9.567646	25.45931	66.07963

Logit estimates	3			Number	of obs	; =	540
				LR chi	2 (1)	=	43.58
				Prob >	chi2	=	0.0000
Log likelihood	= -96.88601	7		Pseudo	R2	=	0.1836
GRAD	Coef.	Std. Err.	Z	P>   z	[95%	Conf.	Interval]
ASVABC	.1313626	.022428	5.86	0.000	 .0874	1045	.1753206
•		.9444844	-3.43	0.000	-5.091	_	-1.389063
_cons	-5.240216	. 5444044	-3.43	0.001	-5.091		-1.369063

В рассмотренном примере средний результат ASVABC равен 51.36.

### . sum GRAD ASVABC

Variable	•	Mean	Std. Dev.		Мах 
GRAD			.2328351	0	_
ASVABC	540	51.36271	9.567646	25.45931	66.07963

$$Z = -3.240 + 0.131 \times 51.36 = 3.507$$

Logit estimate	:S			Number	of obs	; =	540
				LR chi	2 (1)	=	43.58
				Prob >	chi2	=	0.0000
Log likelihood	l = -96.88601	7		Pseudo	R2	=	0.1836
GRAD	Coef.	Std. Err.	z	P> z	 [95%	Conf	Interval]
•				• •			
ASVABC	.1313626	.022428	5.86	0.000	.0874	1045	.1753206
_cons	-3.240218	.9444844	-3.43	0.001	-5.091	.373	-1.389063

# В этой точке *Z* равно 3.507.

### . sum GRAD ASVABC

Variable		Obs	Mean	Std. Dev.	Min	Max
GRAD ASVABC	   	540 540	.9425926 51.36271	.2328351 9.567646	0 25.45931	1 66.07963
	$e^{-Z} =$	$e^{-3.5}$	0.030	0		

$$f(Z) = \frac{dp}{dZ} = \frac{e^{-Z}}{(1 + e^{-Z})^2} = \frac{0.030}{(1 + 0.030)^2} = 0.028$$

 $e^{-Z}$  равно 0.030. Следовательно, f(Z) равно 0.028.

### . sum GRAD ASVABC

Variable	1	Obs	Mean	Std. Dev.	Min	Max
	-+-					
GRAD	1	540	. 9425926	.2328351	0	1
ASVABC	1	540	51.36271	9.567646	25.45931	66.07963


$$Z = \beta_0 + \beta_1 \bar{X} = -3.240 + 0.131 \times 51.36 = 3.507$$

$$e^{-Z} = e^{-3.507} = 0.030$$

$$f(Z) = \frac{dp}{dZ} = \frac{e^{-Z}}{(1 + e^{-Z})^2} = \frac{0.030}{(1 + 0.030)^2} = 0.028$$


$$\frac{\partial p}{\partial X_i} = \frac{dp}{dZ} \frac{\partial Z}{\partial X_i} = f(Z)\beta_i = 0.028 \times 0.131 = 0.004$$

Предельный эффект для имеющего средний результат тестирования равен 0.004. Это означает, что при увеличении результата тестирования ASVABC на 1 балл вероятность закончить школу возрастает на 0.4  $_{27}$  процента.




Предельный эффект при среднем результате очень мал. Это связано с тем, что вероятность закончить школу при средних результатах и так очень велика.

В пакете STATA предельные эффекты объясняющих переменных можно получить с помощью команды mfx



Для пробит – модели в качестве S – функции выбирается функция распределения стандартного нормального распределения.



Выше приведена функция плотности. Оценки коэффициентов находятся по методу максимального правдоподобия.

31

# . probit GRAD ASVABC SM SF MALE Iteration 0: log likelihood = -118.67769 Iteration 1: log likelihood = -98.195303 Iteration 2: log likelihood = -96.666096 Iteration 3: log likelihood = -96.624979 Iteration 4: log likelihood = -96.624926 Probit estimates Number of obs = 540 LR chi2(4) = 44.11Prob > chi2 = 0.0000Log likelihood = -96.624926Pseudo R2 = 0.1858GRAD | Coef. Std. Err. z P>|z| [95% Conf. Interval] ASVABC | .0648442 .0120378 5.39 0.000 .0412505 .0884379 SM | -.0081163 .0440399 -0.18 0.854 -.094433 .0782004 SF | .0056041 .0359557 0.16 0.876 -.0648677 .0760759 MALE | .0630588 .1988279 0.32 0.751 -.3266368 .4527544

.5470608 -2.65 0.008

# Результаты оценки пробит- модели.

cons | -1.450787

-.3785673

-2.523006

# Iteration 0: log likelihood = -118.67769 Iteration 1: log likelihood = -98.195303 Iteration 2: log likelihood = -96.666096 Iteration 3: log likelihood = -96.624979 Iteration 4: log likelihood = -96.624926 Probit estimates Number of obs = 540 LR chi2(4) = 44.11 Prob > chi2 = 0.00000 Log likelihood = -96.624926 GRAD | Coef. Std. Err. z P>|z| [95% Conf. Interval] ASVABC | .0648442 .0120378 5.39 0.000 .0412505 .0884379

 SM | -.0081163
 .0440399
 -0.18
 0.854
 -.094433
 .0782004

 SF | .0056041
 .0359557
 0.16
 0.876
 -.0648677
 .0760759

MALE | .0630588 .1988279 0.32 0.751 -.3266368 .4527544

Как и для логит – модели, не существует интерпретации полученных оценок коэффициентов. С их помощью можно рассчитать предельные эффекты.

$$p = F(Z)$$

$$\frac{\partial p}{\partial X_i} = \frac{dp}{dZ} \frac{\partial Z}{\partial X_i} = f(Z)\beta_i = \left(\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}Z^2}\right)\beta_i$$

Напомним, что предельный эффект объясняющего фактора  $X_i$  рассчитывается как частная производная от  $X_i$ . Предельный эффект і – го объясняющего фактора не является константой, а зависит от других переменных

### . sum GRAD ASVABC SM SF MALE

Variable	Obs	Mean	Std. Dev.	Min	Max
GRAD	540	. 9425926	.2328351	0	1
ASVABC	540	51.36271	9.567646	25.45931	66.07963
SM	540	11.57963	2.816456	0	20
SF	540	11.83704	3.53715	0	20
MALE	540	.5	.5004636	0	1

Таблица дескриптивных статистик для переменных.

Пробит - модель

**Probit: Marginal Effects** 

	mean	b	product	f(Z)	f(Z)b
ASVABC	51.36	0.065	3.328	0.068	0.004
SM	11.58	-0.008	-0.094	0.068	-0.001
SF	11.84	0.006	0.066	0.068	0.000
MALE	0.50	0.063	0.032	0.068	0.004
constant	1.00	-1.451	-1.451		
Total			1.881	$\frac{\partial p}{\partial X_i} = \frac{dp}{dZ} \frac{\partial Z}{\partial X_i}$	$=f(Z)\beta_i$

Оцениваем предельные эффекты для объясняющих факторов.

# **Odd Ratio**

# Для логит-модели

$$OR = \frac{\Pr(Y=1)}{\Pr(Y=0)}$$

Отношение вероятности «удачи» и «неудачи»

$$\ln(OR) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

Если  $X_j$  изменится на 1 то OR изменится в  $\exp(\beta_j)$  раз.

 $\mathbb{R}^2$ -Мак $\Phi$ аддена (McFadden) определяется формулой:  $\P$ 

$$R_{M\!F}^2 = 1 - \frac{\hat{l}}{l_0} \ , \cdot \ \text{где} \cdot \hat{l} \ - \cdot \ \text{логарифмическая} \cdot \ \text{функция} \cdot \ \text{правдоподобия} \cdot \ \text{для} \cdot \ \text{модели} \cdot (11.2) \cdot \ \text{в} \cdot \ \text{точке} \cdot \ \text{гочке} \cdot$$

максимума, ·  $l_0$  ·-· максимум· логарифмической · функция· правдоподобия · для · модели, · в ·

которую включена только константа, Ч

псевдо R<sup>2</sup> (Атетуа, 1981):¶

$$PseudoR^2 = 1 - \frac{1}{1 + \frac{2}{n}(\hat{l} - l_0)}.$$

na z

Альтернативный критерий оценки качества модели является сравнение точности прогнозирования по оцененной модели бинарного выбора.

Прогноз по модели бинарного выбора (11.2) обычно строится следующим образом: 

¶

$$\begin{cases} \hat{Y_i} = 1, & ecnu \quad F(\hat{\beta_0} + \hat{\beta_1} X_{1i} + ... + \hat{\beta_k} X_{ki}) > 0.5, \\ \hat{Y_i} = 0, & ecnu \quad F(\hat{\beta_0} + \hat{\beta_1} X_{1i} + ... + \hat{\beta_k} X_{ki}) \leq 0.5 \end{cases}, \rightarrow \P$$

что, ·с·учетом ·симметричности ·функций ·плотности ·относительно ·нуля ·равносильно¶

$$\begin{cases} \hat{Y_i} = 1, & ecnu & \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \ldots + \hat{\beta}_k X_{ki} > 0, \\ \hat{Y_i} = 0, & ecnu & \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \ldots + \hat{\beta}_k X_{ki} \leq 0. \end{cases} \P$$

1

Доля неверных прогнозов вычисляется по формуле:¶

$$wr_1 = \frac{1}{n} \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2. \P$$

Эта · доля · неверных · прогнозов · интересна · в · сравнении · с · долей · неверных · прогнозов · самой · простой · бинарной · модели , · в · которую · включена · только · константа . · Для · этой · просто модели · прогнозы · строятся · совсем · просто : ¶

$$\hat{Y_i}=1,$$
 если  $\hat{p}>0.5,$  где  $\hat{p}-$ доля единиц в выборке,  $\hat{Y_i}=0,$  если  $\hat{p}\leq 0.5.$ 

Доля неверных прогнозов для простой модели вычисляется так:¶


$$\begin{cases} wr_0 = 1 - \hat{p}, & \textit{ecnu} \quad \hat{p} > 0.5, \\ wr_0 = \hat{p}, & \textit{ecnu} \quad \hat{p} \leq 0.5. \end{cases} \P$$

Отметим, ·что·пороговое·значение·0.5·иногда·изменяют, ·чтобы·достичь·более·высоко точности·предсказания.¶

Показатель качества подгонки модели рассчитывается по формуле: ¶

$$R_p^2 = 1 - \frac{wr_1}{wr_0} . \P$$


	——— True —		
Classified	D	~D	Total
+	793	397	1190
i=:	943	1789	2732
Total	1736	2186	3922
	+ if predicted Pr(D ned as male != 0	)) >= .5	
Sensitivity		Pr( +  D)	45.68%
Specificity		Pr( -   ~D)	81.84%
Positive pre	edictive value	Pr( D  +)	66.64%
Negative pro	edictive value	Pr(~D  -)	65.48%
False + rate	e for true ~D	Pr( + ~D)	18.16%
False - rate	e for true D	Pr( -   D)	54.32%
False + rate	e for classified +	Pr(~D  +)	33.36%
False - rate	e for classified -	Pr( D  -)	34.52%
Correctly cl	lassified		65.83%



Sensitivity – доля правильно идентифицированных 1, Specifity – доля правильно идентифицированных 0.

# ROC - кривая

# **ROC** – received operating characteristics



AUC = 0.5 - модель не лучше случайного гадания,

AUC < 0.5 – модель хуже случайного гадания