

Лекции по эконометрике №1, 2, 3 модуль

Метод максимального правдоподобия

Демидова

Ольга Анатольевна

https://www.hse.ru/staff/demidova_olga

E-mail:demidova@hse.ru

11.01.2021, 18.01.2021,



План лекции

- 1) Метод максимального правдоподобия
- 2) Примеры применения метода максимального правдоподобия
- 3) Свойства метода максимального правдоподобия
- 4) Проверка гипотез с помощью теста Вальда, теста отношения правдоподобия, теста множителей Лагранжа
- 5) Выбор моделей с помощью критериев АІС, ВІС



Основное предположение:

Известен закон распределения случайных величин, зависящий от набора параметров.

Оценки этих параметров подбираются таким образом, чтобы вероятность получить имеющийся набор данных была максимальной.

$$L(\theta) = L(x_1, ..., x_n, \theta) = P(X_1 = x_1, ..., X_n = x_n \mid \theta) \rightarrow \max$$

Пример 1. Найти оценку максимального правдоподобия параметра пуассоновского распределения по выборке Решение:

$$L(\lambda) = L(x_1, ..., x_n \mid \lambda) = P(X_1 = x_1 \mid \lambda) \cdot ... \cdot P(X_n = x_n \mid \lambda) =$$

$$= \frac{e^{-\lambda} \cdot \lambda^{x_1}}{x_1!} \cdot ... \cdot \frac{e^{-\lambda} \cdot \lambda^{x_n}}{x_n!} = \frac{e^{-n\lambda} \cdot \lambda^{x_n}}{x_1! ... x_n!}$$

$$l(\lambda) = \ln L(\lambda) = -n\lambda + \sum_{i=1}^{n} x_i \cdot \ln \lambda - \ln(x_1! \dots x_n!)$$



Необходимое условие первого порядка:

$$l_{\lambda}'(\lambda) = -n + \frac{\sum_{i=1}^{n} x_i}{\lambda} = 0$$

$$\lambda = \frac{\sum_{i=1}^{n} x_i}{n} = \overline{X}$$

Достаточное условие:

$$l_{\lambda}^{"}(\lambda) = -\frac{\sum_{i=1}^{n} x_{i}}{\lambda^{2}} < 0$$

$$\hat{\lambda}_{\mathrm{ML}} = \overline{X}$$

Пример 2. Найти оценку максимального правдоподобия математического ожидания μ и дисперсии σ^2 по выборке $x_1,...,x_n$ Решение:

$$L(\mu, \sigma^2) = L(x_1, ..., x_n \mid \mu, \sigma^2) = f_{X_1, ..., X_n}(x_1, ..., x_n \mid \mu, \sigma^2) = f_{X_1}(x_1 \mid \mu, \sigma^2) \cdot ... \cdot f_{X_n}(x_n \mid \mu, \sigma^2) = f_{X_1, ..., X_n}(x_1, ..., x_n \mid \mu, \sigma^2) = f_{X_1, ..., X$$

$$= \frac{1}{\sqrt{2\pi\sigma}} \exp\left\{-\frac{(x_1 - \mu)^2}{2\sigma^2}\right\} \cdot \dots \cdot \frac{1}{\sqrt{2\pi\sigma}} \exp\left\{-\frac{(x_n - \mu)^2}{2\sigma^2}\right\} =$$

$$= \frac{1}{(2\pi)^{n/2} (\sigma^2)^{n/2}} \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\}$$

$$l(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

Пример 2. Необходимое условие первого порядка:

$$\frac{\partial l(\mu, \sigma^2)}{\partial \mu} = \frac{2}{2\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu} = \overline{X}$$

$$\frac{\partial l(\mu,\sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \qquad \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

$$\Rightarrow \hat{\mu}_{ML} = \overline{X}, \quad \hat{\sigma}_{ML}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \overline{X})^2$$

Достаточные

условия:
$$H(\hat{\mu}_{ML}, \hat{\sigma}_{ML}^{2}) = \begin{bmatrix} -\frac{n}{\hat{\sigma}_{ML}^{2}} & 0 \\ 0 & -\frac{n}{2(\hat{\sigma}^{2})^{2}} \end{bmatrix}$$



Метод максимального правдоподобия для регрессионных моделей

$$\begin{split} Y &= X \ \beta + \varepsilon \\ \varepsilon \sim N(0_n, \sigma^2 I_n) \\ L(-\beta, \sigma^2) &= f(\varepsilon | \beta, \sigma^2) = \frac{1}{(2\pi)^{n/2}} \cdot \exp\left\{-\frac{1}{2\sigma^2} \varepsilon' \varepsilon\right\} = \\ &= \frac{1}{(2\pi)^{n/2} \left(\sigma^2\right)^{n/2}} \cdot \exp\left\{-\frac{1}{2\sigma^2} (Y - X\beta)'(Y - X\beta)\right\} \\ l(-\beta, \sigma^2) &= -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (Y - X\beta)'(Y - X\beta) \\ l(-\beta, \sigma^2) &= -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (Y'Y - 2\beta'X'Y + \beta'X'X\beta) \end{split}$$

Метод максимального правдоподобия для регрессионных моделей

Необходимые условия первого порядка:

$$\frac{\partial l(\dot{\beta}, \sigma^{2})}{\partial \beta'} = -\frac{1}{2\sigma^{2}}(-2X'Y + 2X'X\beta) = 0$$

$$\frac{\partial l(\dot{\beta}, \sigma^{2})}{\partial \sigma^{2}} = -\frac{n}{2\sigma^{2}} + \frac{1}{2(\sigma^{2})^{2}}(Y - X\beta)'(Y - X\beta) = 0$$

$$\Rightarrow \hat{\beta} = (X'X)^{-1}X'Y, \quad \hat{\sigma}^{2} = \frac{e'e}{n}, \quad e = Y - X\hat{\beta}$$

Достаточные условия: (см. <u>Магнус</u> и др., 2007, 10.5)



Общие свойства оценок МП

Если функция f(x) плотности распределения случайных величин X1,...Xn удовлетворяет некоторым условиям регулярности, то оценки МП обладают свойствами:

1)→Инвариантность.¶

Если· $\hat{\theta}_{MH}$ ·--оценка·максимального правдоподобия параметра· θ ·и· g(.) ·--непрерывная

функция, то $g(\hat{\theta})$ является оценкой максимального правдоподобия параметра $g(\theta)$. ¶

- 2)→ Состоятельность (определение состоятельной оценки дано в разделе 2.3.1). ¶
- 3)→ Асимптотическая нормальность. ¶

 $\Pi \underline{p}\underline{n} \cdot n \to \infty$ ·оценка · вектора · параметров · имеет · нормальное · распределение ¶

$$\hat{\boldsymbol{\theta}}_{\!M\!H} \overset{a}{\sim} N(\boldsymbol{\theta},\boldsymbol{I}^{\!-\!1}(\boldsymbol{\theta}))\;, \P$$

Где· $I(\theta)$ ·-·информационная·матрица·Фишера,·вычисляемая·по·формуле¶

$$I(\theta) = -E\left[\frac{\partial^2 l}{\partial\theta\partial\theta'}\right]\cdot, \cdot 1\cdot -\cdot \text{функция}\cdot \text{правдоподобия}, \cdot \frac{\partial^2 l}{\partial\theta\partial\theta'}\cdot -\cdot \text{матрица}\cdot \underline{\Gamma\text{ecce.}}\P$$

4)→ Асимптотическая эффективность. ¶

Оценка ·ММП · дисперсии · каждого · параметра · · (один · из · диагональных · элементов ·

ковариационной·матрицы· $I^{-1}(\theta)$)·является·нижней·границей·для·всех·состоятельных асимптотически·нормальных·оценок·этого·параметра. \P



Проверка линейных гипотез с помощью теста Вальда

$$Y = X\beta + \varepsilon$$
, $var[\varepsilon] = \sigma_{\varepsilon}^{2}I$

$$H_0: Q\beta = q, ranqQ = r$$

$$H_1: Q\beta \neq q$$

$$\varepsilon \sim N(0, \sigma_{\varepsilon}^{2} I) \Rightarrow \\ \hat{\beta}_{ML} \sim N(\beta, \sigma_{\varepsilon}^{2} (X'X)^{-1}) \Rightarrow$$

$$Q\hat{\beta}_{ML} \sim N(Q\beta, Q \operatorname{var}[\hat{\beta}_{ML}]Q')$$

$$W = (Q\hat{\beta} - q)'(Q \operatorname{var}[\hat{\beta}_{ML}]Q')^{-1}(Q\hat{\beta} - q) \sim \chi^{2}(r)$$



Проверка нелинейных гипотез с помощью теста Вальда

$$Y = X\beta + \varepsilon$$
, $var[\varepsilon] = \sigma_{\varepsilon}^2 I$

$$H_0: g_j(\beta) = 0, j = 1, ..., r$$

$$H_1$$
: $\exists j$: $g_i(\beta) \neq 0$

$$r = 1$$
, $g(\beta) \approx g(\hat{\beta}) + \frac{\partial g}{\partial \beta}(\hat{\beta})(\beta - \hat{\beta})$

$$W = g'(\hat{\beta}) \left(\frac{\partial g}{\partial \beta}(\hat{\beta}) \operatorname{var}[\hat{\beta}_{ML}] \frac{\partial g'}{\partial \beta}(\hat{\beta}) \right)^{-1} g(\hat{\beta}) \sim \chi^{2}(r) = \chi^{2}(1)$$



Проверка нелинейных гипотез с помощью теста Вальда

$$Y = X\beta + \varepsilon$$
, $var[\varepsilon] = \sigma_{\varepsilon}^2 I$

$$H_0: g_j(\beta) = 0, j = 1, ..., r$$

$$H_1$$
: $\exists j$: $g_i(\beta) \neq 0$

$$r > 1$$
, $g(\beta) \approx g(\hat{\beta}) + \frac{\partial g}{\partial \beta}(\hat{\beta})(\beta - \hat{\beta})$

$$W = g'(\hat{\beta}) \left(\frac{\partial g}{\partial \beta}(\hat{\beta}) \operatorname{var}[\hat{\beta}_{ML}] \frac{\partial g'}{\partial \beta}(\hat{\beta}) \right)^{-1} g(\hat{\beta}) \sim \chi^{2}(r)$$

$$g(\beta) = \begin{pmatrix} g_1(\beta) \\ \vdots \\ g_r(\beta) \end{pmatrix}, \dots, \frac{\partial g}{\partial \beta} = \begin{pmatrix} \frac{\partial g_1}{\partial \beta_0} & \dots & \frac{\partial g_r}{\partial \beta_k} \\ \vdots & & \vdots \\ \frac{\partial g_r}{\partial \beta_0} & \dots & \frac{\partial g_r}{\partial \beta_k} \end{pmatrix}$$



Достоинства и недостатки теста Вальда

Достоинство: используются только оценки модели без ограничений

Недостаток: неинвариантность к способу параметризации



Проверка гипотез с помощью теста отношения правдоподобия

$$Y = X\beta + \varepsilon$$
, $var[\varepsilon] = \sigma_{\varepsilon}^2 I$

$$H_0: g_j(\beta) = 0, \ j = 1, ..., r$$

$$H_1:\exists j:g_j(\beta)\neq 0$$

$$LR = -2(\ln L(\hat{\beta}_{R}) - \ln L(\hat{\beta}_{UR})) \sim \chi^{2}(r)$$

В этом тесте используются оценки модели с ограничениями и без ограничений



Проверка нелинейных гипотез с помощью теста множителей Лагранжа

$$Y = X\beta + \varepsilon, \text{ var}[\varepsilon] = \sigma_{\varepsilon}^{2}I$$

$$H_{0}: g(\beta) = \begin{pmatrix} g_{1}(\beta) \\ \vdots \\ g_{r}(\beta) \end{pmatrix} = 0,$$

$$H_{1}: \exists j: g_{j}(\beta) \neq 0, j = 1, ..., r$$

$$H(\beta, \lambda) = l(\beta) - \lambda' g(\beta) \rightarrow \max$$

$$\frac{\partial H}{\partial \beta_{k}} = \frac{\partial l}{\partial \beta_{k}} - \lambda' \frac{\partial g}{\partial \beta_{k}}$$

$$\frac{\partial l(\hat{\beta}_{R})}{\partial \beta_{k}} - \lambda' \frac{\partial g(\hat{\beta}_{R})}{\partial \beta_{k}} = 0$$

Если ограничения выполняются, то все множители Лагранжа равны 0, поэтому и градиент логарифмической функции правдоподобия близок к 0.



Проверка нелинейных гипотез с помощью теста множителей Лагранжа

$$Y = X\beta + \varepsilon, \text{ var}[\varepsilon] = \sigma_{\varepsilon}^{2}I$$

$$H_{0}: g(\beta) = \begin{pmatrix} g_{1}(\beta) \\ \vdots \\ g_{r}(\beta) \end{pmatrix} = 0,$$

$$H_{1}: \exists j: g_{j}(\beta) \neq 0, j = 1, ..., r$$

$$LM = \left(\frac{\partial l}{\partial \beta}(\hat{\beta}_{R})\right)' I^{-1}(\hat{\beta}_{R}) \left(\frac{\partial l}{\partial \beta}(\hat{\beta}_{R})\right) \sim \chi^{2}(r)$$

В этом тесте используются только оценки модели с ограничениями



Расстояние Кульбака-Лейблера

f(x) — функция плотности истинного распределения, $g(x|\theta)$ — функция плотности оцениваемого распределения.

Расстояние между истинной и оцениваемой моделями Кульбака-Лейблера (Kullback and Leibler, 1951)

$$I(f,g) = \int f(x) \log \left(\frac{f(x)}{g(x|\theta)}\right) dx.$$



Расстояние Кульбака-Лейблера

$$I(f,g) = \int f(x) \log \left(\frac{f(x)}{g(x|\theta)}\right) dx.$$

$$I(f,g) = \int f(x) \log(f(x)) dx - \int f(x) \log(g(x|\theta)) dx$$

$$I(f,g) = E_f[\log(f(x))] - E_f[\log(g(x|\theta))],$$



Расстояние Кульбака-Лейблера

$$I(f,g) = \int f(x) \log(f(x)) dx - \int f(x) \log(g(x|\theta)) dx$$

$$I(f,g) = E_f[\log(f(x))] - E_f[\log(g(x|\theta))],$$

$$I(f,g) = C - E_f[\log(g(x|\theta))],$$

$$C = \int f(x) \log(f(x)) dx$$



Критерий Акаике выбора модели

$$I(f,g) = C - E_f[\log(g(x|\theta))],$$

$$C = \int f(x) \log(f(x)) dx$$

Критерий Акаике основан оценке

$$E_y E_x[\log(g(x|\hat{\theta}(y)))].$$

где у – это данные.



Критерий Акаике выбора модели

Критерий Акаике основан на оценке

$$E_y E_x[\log(g(x|\hat{\theta}(y)))].$$

где у – это данные.

Основной результат Акаике:

$$\log(\mathcal{L}(\hat{\theta}|\text{data})) - K = C - \hat{E}_{\hat{\theta}}[I(f, \hat{g})]$$



Критерий Акаике выбора модели

Основной результат Акаике:

$$\log(\mathcal{L}(\hat{\theta}|\text{data})) - K = C - \hat{E}_{\hat{\theta}}[I(f, \hat{g})]$$

relative
$$\hat{E}(K-L) = \log(\mathcal{L}(\hat{\theta}|\text{data})) - K$$
.

$$AIC = -2\log(\mathcal{L}(\hat{\theta}|\text{data})) + 2K.$$

Чем меньше AIC, тем лучше модель.

Для линейной регрессионной модели с нормально распределенными ошибками:

$$AIC = n \log(\hat{\sigma}^2) + 2K$$

Критерий Байеса (Шварца) выбора модели

Schwarz (1978) derived the Bayesian information criterion as

$$BIC = -2\ln(\mathcal{L}) + K\log(n).$$

Чем меньше ВІС, тем лучше модель.



Thank you for your attention!

20, Myasnitskaya str., Moscow, Russia, 101000 Tel.: +7 (495) 628-8829, Fax: +7 (495) 628-7931 www.hse.ru