Эконометрика, 2020-2021, 3 модуль

Семинары 5-6

8, 15.02.21

Для Группы Э_Б2018_Э_3

Семинарист О.А.Демидова

Модели бинарного выбора

Демидова, Малахов, 11.5

Задание 11.5.

База данных rlms14 (файл rlms14.dta)

В файле rlms14.dta приведены данные о заработной плате, возрасте, образовании, профессиональной принадлежности россиян из базы данных RLMS, 14 раунд опроса, проводившийся в 2005 г.

Переменные:

income – ответ на вопрос: «Сколько денег в течение последних 30 дней Вы получили по основному месту работы после вычета налогов и отчислений?»

wage - ответ на вопрос: «Ваша среднемесячная зарплата за последние 12 месяцев?»

psu – первичная единица отбора (1 – Санкт – Петербург, ..., 38 – Амурская обл.),

marst — семейное положение (1 — никогда в браке не состояли, 2- состоите в зарегистрированном браке, 3 — живете вместе, но не зарегистрированы, 4 — разведены и в браке не состоитн, 5 — вдовец/вдова),

оссир — профессиональная группа (1- военнослужащие, 2 — законодатели, крупые чиновники, управленцы, 3 — профессионалы с высшим образованием, 4 — конторские служащие, 5 — занятые в сфере обслуживания, 6 — квалифицированные с/х работники, 7 — ремесленники, 8 — промышленные рабочие),

educ — образование (1 - 0 классов школы, 23 - аспирантура и т.п. с дипломом),

diplom — законченное образование (1 - 0.6) классов, 1.2 — незаконченное среднее образование, 3 - законченное среднее образование, 4 - законченное среднее образование, 5 - законченное среднее специальное образование, 6 - законченное высшее образование и выше),

gender – пол респондента (1 – мужской, 2 – женский),

birth year – год рождения,

industry – ответ на вопрос: «в какой отрасли Вы работаете?» (1 – легкая и пищевая промышленность, ...),

beginning — ответ на вопрос: «с какого года Вы работаете на этом предприятии?»

boss – ответ на вопрос: «У Вас есть подчиненные на этой работе?» (1 –да, 2 – нет),

subordinates – ответ на вопрос: «Сколько у Вас подчиненных?»

duration_weekh - ответ на вопрос: «Сколько часов в среднем продолжается Ваша обычная рабочая неделя?»

life_sat - ответ на вопрос: «Насколько Вы удовлетворены или не удовлетворены Вашей жизнью в целом?» (1 - «Полностью удовлетворены», ..., 5 - «Совсем не удовлетворены»),

job_sat - ответ на вопрос: «Насколько Вы удовлетворены или не удовлетворены Вашей работой в целом?» (1 - «Полностью удовлетворены», 2 - «Скорее удовлетворены», 3 - «И да, и нет», 4 - «Не очень удовлетворены», 5 - «Совсем не удовлетворены»),

јов_сагеет - ответ на вопрос: «Насколько Вы удовлетворены или не удовлетворены возможностями Вашего профессионального роста?» (1 - «Полностью удовлетворены», ...,5 – «Совсем не удовлетворены»),

```
children - ответ на вопрос: «Сколько у Вас детей?»,
```

child_less18 - ответ на вопрос: «Сколько у Вас детей моложе 18 лет?»,

По данным файла rlms14.dta с помощью статистического пакета STATA попытайтесь выявить факторы, влияющие на удовлетворенность россиян жизнью в целом, работой, возможностями профессионального роста.

Например, для выявления факторов, влияющих на удовлетворенность россиян жизнью в целом

- 1) Создайте зависимую переменную life, равную 1 для тех, кто на вопрос «Насколько Вы удовлетворены или не удовлетворены Вашей жизнью в целом?» ответили «Полностью удовлетворены» или «Скорее удовлетворены» (т.е. для кого значения переменной life sat равно 1 или 2).
- 2) Оцените логит и пробит модели с зависимой переменной life, объясняющие переменные выберите самостоятельно (при необходимости создайте новые, например возраст age = 2005 – birth_year и т.п.), Вычислите предельные эффекты объясняющих факторов в выбранной Вами точке. Дайте интерпретацию полученным результатам. Используйте статистический пакет STATA.

Методические указания.

```
Полезные команды:
set more off
gen life = 0
replace life =1 if job_sat <3
gen age = 2005- birth_year
tab educ
tab diplom
logit life gender income children age i.diplom
label list psu
logit life gender income children age i.diplom if psu==2
gen higheduc=0
replace higheduc=1 if diplom==6
```

probit life gender income children age higheduc if psu==2 mfx

sum gender income children age higheduc

mfx, at (1 5000 0 25 1)

probit life income children age higheduc if psu==2 & gender ==2

Дополнительные задания.

3) Оцените качество оценки моделей

Полезные команды:

estat classification

estat gof

estat classification, cutoff(0.4)

4) Постройте график кривых чувствительности и специфичности

Полезная команда:

1sens

5) Постройте график ROC – кривой и вычислите площадь под ней

Полезная команда:

lroc

Демидова, Малахов, задачи 11.1-11.4, задание 11.3

Задача 11.1.

Исследователя интересует зависимость вероятности найти работу от уровня образования индивидуума. Введя в качестве зависимой переменную ЕМР, равную 1 для работающих и 0 для неработающих и S – количество лет обучения в качестве объясняющей, он оценил логит – модель:

$$P\{EMP_i = 1\} = \frac{1}{1 + \exp\{-Z_i\}}, Z_i = -1.006 + 0.148S$$

Оцените предельный эффект объясняющего фактора для среднего значения переменной $S=13.5\,.$

Решение:

$$Z(\overline{s}) = -1.006 + 0.148 \cdot 13.5 = 0.992$$

$$\exp(-z(\overline{s})) = \exp(-0.992) = 0.371$$

$$f(z) = \frac{e^{-z}}{(1 + e^{-z})^2}$$

$$f(z(\overline{s})) = \frac{0.371}{(1 + 0.371)^2} = 0.1973$$

$$\frac{\partial p(\bar{s})}{\partial s} = \frac{\partial p}{\partial z} \cdot \frac{\partial z}{\partial s} = f(z(\bar{s})) \cdot \hat{\beta}_j = 0.148 \cdot 0.1973 = 0.029$$

Интерпретация: при увеличении длительности обучения (S) на 1 год для индивида со «средними» способностями вероятность найти работу увеличивается на 2.9%.

Задача 11.2.

По наблюдениям для 570 индивидуумов оценена зависимость получения школьником аттестата от обобщенной оценки результатов тестов X. Переменная Y принимает значение 1, если аттестат был получен и 0 в противном случае.

Оцененные модели имеют следующий вид:

Логит:
$$P\{Y_i = 1\} = \frac{1}{1 + \exp\{-Z_i\}}, \ Z_i = -5.004 + 0.1666 X,$$

Пробит:
$$P\{Y_i=1\}=F(Z_i)$$
, $F(z)=\frac{1}{\sqrt{2\pi}}\int\limits_{-\infty}^z e^{-t^2/2}dt$, $Z=-\underbrace{2.7}_{(0.083)}+\underbrace{0.53}_{(0.0117)}X$

Дайте экономическую интерпретацию полученным результатам для логит и пробит моделей. Найдите предельный эффект объясняющего фактора в точке $\overline{X}=50.15$.

Решение:

Найдем предельный эффект в логит модели:

$$z(\overline{x}) = -5,004 + 0,1666 \cdot 50,15 = 3,351$$

$$\exp(-z(\bar{s})) = \exp(-0.992) = 0.0351$$

$$f(z) = \frac{e^{-z}}{(1 + e^{-z})^2}$$

$$f(z(\bar{x})) = \frac{0.0351}{(1+0.0351)^2} = 0.033$$

$$\frac{\partial p(\bar{x})}{\partial x} = \frac{\partial p}{\partial z} \cdot \frac{\partial z}{\partial x} = f(z(\bar{x})) \cdot \hat{\beta}_j = 0.033 \cdot 0.1666 \approx 0.0055$$

При увеличении обобщенной оценки результатов тестов на 1 балл для индивида с обобщенной оценкой равной 50,15 вероятность получения аттестата увеличивается на 0,55%.

Найдем предельный эффект в пробит модели:

$$z(\bar{x}) = -2.7 + 0.53 \cdot 50.15 = 23.88$$

$$f(z(\bar{x})) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \approx 0$$

$$\frac{\partial p(\bar{x})}{\partial x} = \frac{\partial p}{\partial z} \cdot \frac{\partial z}{\partial x} = f(z(\bar{x})) \cdot \hat{\beta}_j \approx 0.053 \approx 0$$

При увеличении обобщенной оценки результатов тестов на 1 балл для индивида с обобщенной оценкой равной 50,15 вероятность получения аттестата почти не увеличивается.

Задача 11.3.

Из 750 обратившихся за ссудой в банк 250 было в ней отказано. Для оценки вероятности получения ссуды были оценены линейная и пробит модели:

$$Y = 0.5 + 1.5X$$
,

$$P{Y_i = 1} = F(Z_i), F(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{z} e^{-t^2/2} dt$$

$$Z = 0.45 + 3X$$

где $Y_i = 1$ для получивших ссуду и 0 иначе, X — доход просителя.

По пробит модели найти предельный эффект дохода в среднем.

Решение:

Для начала найдем средний доход просителя из линейной модели.

$$\overline{Y} = 0.5 + 1.5\overline{X}$$

Y_i= 1, если ссуда была получена.

 $Y_i = 0$, иначе.

 Y_i = 0 в 250 случаях => Y_i = 1 в 500 случаях.

Отсюда
$$\overline{Y} = \frac{500}{750} = \frac{2}{3}$$
.

Подставим это значение в $\overline{Y} = 0.5 + 1.5\overline{X}$:

$$\frac{2}{3} = \frac{1}{2} + 1.5 \cdot \overline{X} \implies \overline{X} = 0.111$$

Теперь найдем предельный эффект в пробит модели:

$$z(\bar{x}) = 0.45 + 3 \cdot 0.111 = 0.783333$$

$$f(z(\bar{x})) = \frac{1}{\sqrt{2\pi}}e^{-\frac{z^2}{2}} = 0,2935$$

$$\frac{\partial p(\bar{x})}{\partial x} = \frac{\partial p}{\partial z} \cdot \frac{\partial z}{\partial x} = f(z(\bar{x})) \cdot \hat{\beta}_j \approx 0.2935 \cdot 3 \approx 0.88$$

При увеличении дохода просителя на 1 единицу (в данной задаче доход измеряется, скорее всего в крупных единицах, например в млн. руб.) для индивида со средним доходом вероятность получения ссуды увеличивается на 88%.

Задача 11.4.

Для того, чтобы определить, эффективна ли новая методика преподавания микроэкономики, провели следующий эксперимент: протестировали всех студентов по микроэкономике в конце первого и второго семестра. Часть студентов во втором семестре обучали по новой методике, часть по старой. После этого в качестве объясняющей выбрали переменную Y, равную 1, если результат студента улучшился и 0 в противном случае, а в качестве объясняющих переменных X_1 — результаты

теста в первом семестре, X_2 – средний балл по остальным предметам, D – равную 1, если студент обучался по новой методике и 0, если по старой.

По имеющимся данным оценили пробит- модель:

$$P{Y_i = 1} = F(Z_i), F(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{z} e^{-t^2/2} dt$$

$$Z = -7.452 + 0.052X_1 + 1.626X_2 + 1.426D$$
.

Найдите предельный эффект переменной D при средних значениях $\,\overline{\!X}_1=21.938\,,\,$

$$\overline{X}_2 = 3.117$$
 (разность вероятностей улучшения результата при D = 1 и D = 0).

Решение:

Рассчитаем предельный эффект переменной D при средних значениях:

$$p(z(\overline{x}_1, \overline{x}_2; D = 1)) - p(z(\overline{x}_1, \overline{x}_2; D = 0)).$$

$$z(\overline{x}_1, \overline{x}_2; D = 1) = -7,452 + 0,052 \cdot 21,938 + 1,626 \cdot 3,117 + 1,426 \cdot 1 = 0,183$$

$$z(\overline{x}_1, \overline{x}_2; D = 0) = -7,452 + 0,052 \cdot 21,938 + 1,626 \cdot 3,117 + 1,426 \cdot 0 = -1,243$$

$$p(z(\bar{x}_1, \bar{x}_2; D=1)) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{0.183} e^{-\frac{t^2}{2}} dt = \frac{1}{\sqrt{2\pi}} e^{-\frac{0.183^2}{2}} = 0.392$$

$$p(z(\bar{x}_1, \bar{x}_2; D=0)) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{-1,243} e^{-\frac{t^2}{2}} dt = \frac{1}{\sqrt{2\pi}} e^{-\frac{-1,243^2}{2}} = 0.184$$

$$p(z(\bar{x}_1, \bar{x}_2; D=1)) - p(z(\bar{x}_1, \bar{x}_2; D=0)) = 0.392 - 0.184 \approx 0.2$$

Переход на обучение по новой методике увеличивает вероятность улучшения результата студента на 20%.

Задание 11.3.

Для анализа аудитории, использующей Интернет для учебы по данным для 1314 индивидов были оценены линейная и пробит модели (последняя с предельными эффектами), в которых intlear = 1 при использовании индивидом Интернета для учебы и 0 в противном случае, male = 1 для мужчин и 0 для женщин, income — заработная плата индивида по основному месту работы, age — возраст. В скобках указаны соответственно t или z - статистики. В чем состоят недостатки линейной модели? Дайте интерпретацию полученным результатам.

$$INTLEAR = -0.78 - .013 AGE - 4.53 \cdot 10^{-10} INCOME - 0.073 MALE$$

$$P\{INTLEAR_i = 1\} = F(Z_i), F(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{z} e^{-t^2/2} dt$$

$$Z = 1.01 - 0.044 AGE - 1.51 \cdot 10^{-9} INCOME - 0.23 MALE$$
_(7.25) (-10.82)

Marginal effects after probit

- (*) dy/dx is for discrete change of dummy variable from 0 to 1
- 2) Борзых, Демешев, задача 6.12.

Методом максимального правдоподобия оценили логит-модель $\hat{y}_i^* = 2 + 3x_i - 5z_i$

- 1. Оцените вероятность того, что $y_i = 1$ для $\bar{x} = 5, \bar{z} = 3.5.$
- 2. Оцените предельный эффект увеличения x на единицу на вероятность того, что $y_i=1$ для $\bar{x}=5, \bar{z}=3.5$.
- 3. При каком значении x предельный эффект увеличения z на 1 в точке $\bar{z}=3.5$ будет максимальным?
- 4. По 1000 наблюдений Винни-Пух оценил логистическую модель $\mathbb{P}(Y_i=1)=F(\beta_0+\beta_1X_i)$, где X_i количество времени в часах, проведённое в гостях, а Y_i факт застревания при выходе.

Оценки параметров равны $\hat{eta}_0=1,\,\hat{eta}_1=2,\, {\rm c}$ оценкой ковариационной матрицы

$$\begin{pmatrix} 0.25 & 0.1 \\ 0.1 & 0.36 \end{pmatrix}.$$

- а) Проверьте значимость отдельных коэффициентов при уровне значимости 5%;
- б) Найдите предельный эффект времени, проведённого в гостях, на вероятность застрять при выходе для получасового визита;
- в) Найдите максимально возможный предельный эффект.