

# Contents

<b>I</b>	<b>Модуль 3</b>	<b>3</b>
<b>1</b>	<b>Гетероскедастичность</b>	<b>3</b>
1.1	Тест Голдфелда-Квандта . . . . .	3
1.2	Тест Глейзера . . . . .	3
1.3	Тест Уайта . . . . .	3
1.4	Тест Бройша-Пагана . . . . .	4
1.5	Взвешенный метод обобщенных квадратов . . . . .	4
1.6	Стандартные ошибки Уайта . . . . .	4
1.7	Обобщенный метод наименьших квадратов . . . . .	5
<b>2</b>	<b>Метод максимального правдоподобия</b>	<b>5</b>
2.1	Регрессия . . . . .	5
2.2	Тест Вальда . . . . .	5
2.3	Тест отношения правдоподобия . . . . .	6
2.4	Тест множителей Лагранжа . . . . .	6
2.5	Критерий Акаике . . . . .	6
2.6	Критерий Шварца . . . . .	7
<b>3</b>	<b>Модели бинарного выбора</b>	<b>7</b>
3.1	Модель линейной вероятности . . . . .	7
3.2	Логит-модель . . . . .	7
3.3	Пробит-модель . . . . .	7
3.4	Оценка качества бинарных моделей . . . . .	8
3.4.1	Odd Ratio . . . . .	8
3.4.2	$R^2$ -МакФаддена . . . . .	8
3.4.3	Pseudo $R^2$ . . . . .	8
3.4.4	Качество подгонки модели . . . . .	8
3.4.5	Выбор порога отсеечения . . . . .	8
<b>4</b>	<b>Стохастические регрессоры</b>	<b>8</b>
4.1	Эндогенность . . . . .	8
4.2	Инструментальные переменные . . . . .	9
4.2.1	Двухшаговый МНК . . . . .	9
4.3	Тест Хаусманна . . . . .	9
<b>5</b>	<b>Обобщенный метод моментов</b>	<b>10</b>
5.1	Тестирование качества инструментов . . . . .	11
<b>6</b>	<b>Системы одновременных уравнений</b>	<b>11</b>
6.1	Общий случай COU . . . . .	12
6.2	Трехшаговый МНК . . . . .	13
6.3	SUR. Внешне не связанные уравнения . . . . .	14
<b>7</b>	<b>Модели множественного выбора</b>	<b>14</b>
7.1	Модели упорядоченного множественного выбора . . . . .	14
7.1.1	Гипотеза о параллельности . . . . .	15
7.1.2	Отношение шансов . . . . .	15

7.1.3	Предельные эффекты . . . . .	15
7.2	Мультиномиальные модели . . . . .	15
<b>8</b>	<b>Тобит, Sample selection models</b>	<b>15</b>
8.1	Тобит . . . . .	15
8.2	Модель Хекмана . . . . .	16
8.2.1	Оценка . . . . .	16
<b>9</b>	<b>Ядерные методы</b>	<b>16</b>
9.1	Ядерная оценка регрессии . . . . .	17
<b>II</b>	<b>Модуль 4</b>	<b>17</b>
<b>10</b>	<b>Временные ряды</b>	<b>17</b>
10.1	Процессы . . . . .	20
10.2	Диагностика моделей . . . . .	22
10.2.1	ACF, PACF . . . . .	22
10.3	Способы оценки параметров . . . . .	24
10.4	Критерии выбора $p$ и $q$ . . . . .	25
10.5	ARIMA . . . . .	25
10.6	Подход Бокса-Дженкинса . . . . .	25
10.7	Современный подход . . . . .	25
10.8	Автокорреляция случайной составляющей . . . . .	26
10.8.1	Тест серий . . . . .	27
10.8.2	Статистика Дарбина-Уотсона . . . . .	27
10.8.3	Устранение автокорреляции . . . . .	28
10.8.4	Оценка параметра автокорреляции . . . . .	28
10.9	Моделирование сезонности во временных рядах . . . . .	30
10.9.1	Модели ARIMA с сезонностью . . . . .	30
10.9.2	SARIMA . . . . .	30
10.9.3	Процедуры сглаживания ряда . . . . .	31
10.10	Прогнозирование с помощью временных рядов . . . . .	31
10.10.1	Прогнозирование по модели ARMA( $p, q$ ) . . . . .	31
10.10.2	Коинтеграция временных рядов . . . . .	32
10.11	Модели с распределенными лагами . . . . .	33

# Part I

## Модуль 3

### 1 Гетероскедастичность

- Оценки несмещенные
- Несостоятельные
- Неэффективные
- ТГМ не выполняется  $\rightarrow$  МНК-оценки не являются BLUE
- Гипотезы не работают

#### 1.1 Тест Голдфелда-Квандта

$$\begin{cases} H_0 : \text{Гомоскедастичность } (\sigma_i^2 = \sigma_\varepsilon^2) \\ H_1 : \text{Гетероскедастичность } (\sigma_i \sim X_{ji} \cdot X_j) \end{cases}$$

1. Упорядочить наблюдения
2. Разделить наблюдения на 3 части
3. Отдельно оценить регрессии и сохранить RSS
4.  $F(n_2 - k, n_1 - k) = \frac{RSS_2/(n_2 - k)}{RSS_1/(n_1 - k)}$

#### 1.2 Тест Глейзера

$$\begin{cases} H_0 : \sigma_i^2 = \sigma_u^2 \\ H_1 : \sigma_i \sim X^\gamma, \gamma = \{\gamma = 1, \gamma = 1/2, \gamma = -1\} \end{cases}$$

1. Сохраняются остатки
2. Если  $\beta$  значима хотя бы для одной из регрессий, то имеем гетероскедастичность:
  - (a)  $|e_i| = \alpha + \beta X_i + u_i$
  - (b)  $|e_i| = \alpha + \beta \sqrt{X_i} + u_i$
  - (c)  $|e_i| = \alpha + \beta \frac{1}{X_i} + u_i$

#### 1.3 Тест Уайта

$$\begin{cases} H_0 : \text{Гомоскедастичность} \\ H_1 : \text{Гетероскедастичность} \end{cases}$$

*Вид гетероскедастичности не специфицируется*

1. Оценивается регрессия по всем наблюдениям
2. Сохраняются остатки регрессии

3. Оценивается регрессия квадратов остатков на все регрессоры, их квадраты, попарные произведения и константу
4. Находим  $R^2$
5.  $\chi^2_{m-1} = nR^2$ , где  $m$  - число коэффициентов во вспомог. регрессии

## 1.4 Тест Бройша-Пагана

*Доп. факторы влияют на  $\sigma_i$*

$$\begin{cases} H_0 : \sigma_i^2 = \sigma_\varepsilon^2 \\ H_1 : \sigma_i^2 \sim f(\alpha_0 + \alpha_1 Z_1 + \dots + \alpha_r Z_r) \end{cases}$$

1. Сохраняем остатки  $e_i$ , RSS
2. Находится оценка дисперсии возмущений  

$$\hat{\sigma}_u^2 = \frac{RSS}{n}$$
3. Оценивается регрессия  $e^2$  на  $Z_1, \dots, Z_r \rightarrow$  находим ESS
4.  $\frac{ESS}{2\hat{\sigma}^4} \sim \chi_r^2$

## 1.5 Взвешенный метод обобщенных квадратов

1. Если известны дисперсии для каждого наблюдения  

$$\sigma_i \rightarrow \frac{Y_i}{\sigma_i} = \beta_1 \frac{1}{\sigma_i} + \beta_2 \frac{X_i}{\sigma_i} + \frac{u_i}{\sigma_i}$$
2. Обычно стандартные отклонения неизвестны  $\rightarrow$  Достаточно знать что отклонения пропорциональны некоторой известной переменной  $Z_i$   

$$\sigma_i = \lambda Z_i$$

$$\frac{Y_i}{Z_i} = \beta_1 \frac{1}{Z_i} + \beta_2 \frac{X_i}{Z_i} + \frac{u_i}{Z_i}$$
3. Другой способ борьбы - *Логарифмическое преобразование данных*

## 1.6 Стандартные ошибки Уайта

*Устойчивы к гетероскедастичности*

$$\hat{\beta} = \beta + (X'X)^{-1}X'\varepsilon$$

$$n\hat{Var}(\hat{\beta}) = \left(\frac{1}{n}X'X\right)^{-1} \left(\frac{1}{n} \sum_{s=1}^n e_s^2(x'_s x_s)\right) \left(\frac{1}{n}X'X\right)^{-1}$$

## 1.7 Обобщенный метод наименьших квадратов

$$Y = X\beta + \varepsilon$$

Выполнены все условия ТГМ, кроме скалярности ковариационной матрицы ошибок регрессии

$$Var(\varepsilon) = \Omega$$

$\Omega = C^{-1}\Lambda C$ ,  $\Lambda$  - диагональная матрица (на диагонали - собственные числа)

$$\Omega^{-1/2}Y = \Omega^{-1/2}X\beta + \Omega^{-1/2}\varepsilon$$

$$Y^* = X^*\beta + \varepsilon^*$$

$$\hat{\beta}_{GLS} = (X^{*'}X^*)^{-1}(X^{*'}Y^*) = (X'\Omega^{-1}X)^{-1}(X'\Omega^{-1}Y)$$

## 2 Метод максимального правдоподобия

### 2.1 Регрессия

$$\begin{aligned} L(\varepsilon|\beta, \sigma^2) &= \frac{1}{(2\pi)^{n/2}}(\sigma^2)^{n/2} \cdot \exp\left(-\frac{1}{2\sigma^2}\varepsilon'\varepsilon\right) = \\ &= \frac{1}{(2\pi)^{n/2}}(\sigma^2)^{n/2} \cdot \exp\left(-\frac{1}{2\sigma^2}(Y - X\beta)'(Y - X\beta)\right) \\ l(\varepsilon_1, \dots, \varepsilon_n|\beta_0, \beta_1, \sigma^2) &= -\frac{n}{2}\ln 2\pi - \frac{n}{2}\ln \sigma^2 - \frac{1}{2\sigma^2}(Y - \beta X)'(Y - \beta X) \\ \hat{\beta} &= (X'X)^{-1}X'Y, \hat{\sigma}^2 = \frac{e'e}{n} \end{aligned}$$

Общие свойства оценок МП

- Инвариантность
- Состоятельность
- Асимптотическая нормальность
- Асимптотическая эффективность

### 2.2 Тест Вальда

$$\begin{aligned} Var(\varepsilon) &= \sigma_\varepsilon^2 I \\ \begin{cases} H_0 : Q\beta = q, rang Q = r \\ H_1 : Q\beta \neq q \end{cases} \\ Q\beta_{ML} &\sim N(Q\beta, QVar(\hat{\beta}_{ML})Q') \\ W &= (Q\hat{\beta} - q)'(QVar(\hat{\beta}_{ML})Q')^{-1}(Q\hat{\beta} - q) \sim \chi_r^2 \end{aligned}$$

Для функций

$$\begin{cases} H_0 : g_j(\beta) = 0 \\ H_1 : \exists j : g_j(\beta) \neq 0 \end{cases}$$

$$r = 1, g(\beta) \approx g(\hat{\beta}) + \frac{\partial g}{\partial \beta}(\hat{\beta})(\beta - \hat{\beta})$$

$$W = g'(\hat{\beta}) \left( \frac{\partial g}{\partial \beta}(\hat{\beta}) Var[\hat{\beta}_{ML}] \frac{\partial g'}{\partial \beta}(\hat{\beta}) \right) g(\hat{\beta}) \sim \chi_r^2$$

$r > 1 \rightarrow$  То же самое, но в матрицах

Недостаток: Не инвариантен к способу параметризации

## 2.3 Тест отношения правдоподобия

$$\begin{cases} g_j(\beta) = 0, j = 1, \dots, r \\ \exists j : g_j(\beta) \neq 0 \end{cases}$$

$$LR = -2(\ln L(\hat{\beta}_R) - \ln L(\hat{\beta}_{UR})) \sim \chi_r^2$$

## 2.4 Тест множителей Лагранжа

$$\begin{cases} H_0 : g(\beta) = \begin{pmatrix} g_1(\beta) \\ \dots \\ g_r(\beta) \end{pmatrix} = 0, \\ H_1 : \exists j : g_j(\beta) \neq 0 \end{cases}$$

$$H(\beta, \lambda) = l(\beta) - \lambda' g(\beta) \rightarrow \max$$

$$\frac{\partial l(\hat{\beta}_R)}{\partial \beta_k} - \lambda' \frac{\partial g(\hat{\beta}_R)}{\partial \beta_k} = 0$$

$$LM = \left( \frac{\partial l}{\partial \beta}(\hat{\beta}_R) \right)' I^{-1}(\hat{\beta}_R) \left( \frac{\partial l}{\partial \beta}(\hat{\beta}_R) \right) \sim \chi_r^2$$

## 2.5 Критерий Акаике

Расстояние Кульбака-Лейблера

$$I(f, g) = \int f(x) \log \left( \frac{f(x)}{g(x|\theta)} \right) dx$$

$$I(f, g) = \int f(x) \log(f(x)) dx - \int f(x) \log(g(x|\theta)) dx$$

$$I(f, g) = E_f[\log(f(x))] - E_f[\log(g(x|\theta))]$$

$$I(f, g) = C - E_f[\log(g(x|\theta))] \rightarrow C = \int f(x) \log(f(x)) dx$$

Критерий Акаике

$$E_y E_x[(\log(g(x|\theta(y))))]$$

$$\log(L(\hat{\theta}|data)) - K = C - \hat{E}_{\hat{\theta}}[I(f, \hat{g})]$$

$$AIC = -2\log(L(\hat{\theta}|data)) + 2K \rightarrow \min$$

## 2.6 Критерий Шварца

$$BIC = -2\ln(L) + K\log(n)$$

## 3 Модели бинарного выбора

### 3.1 Модель линейной вероятности

$$p(Y_i = 1) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}$$

#### Недостатки

- Оцененные значения не всегда  $\in [0, 1]$
- $\varepsilon \approx N(\dots)$
- Гетероскедастичность

### 3.2 Логит-модель

$$p = F(Z) = \frac{1}{1 + e^{-Z}}$$
$$\frac{dp}{dZ} = \frac{e^{-Z}}{(1 + e^{-Z})^2}$$

Для оценки параметров используется ММП

$$L(\beta) = \prod_{Y_i=1} F(\beta X) \prod_{Y_i=0} (1 - F(\beta X))$$

$$L(\beta) = \prod_{i=1} [F(\beta X)]^{Y_i} [1 - F(\beta X)]^{1-Y_i}$$

$$l(\beta) = \sum_{i=1}^n [Y_i \ln F(\beta X) + (1 - Y_i) \ln F(1 - \beta X)]$$

Условие первого порядка:

$$\sum_{i=1}^n [Y_i - \Lambda(\beta X_i)] X_{ji} = 0, j = 0, \dots, k$$

Предельный эффект фактора:

$$\frac{\partial p}{\partial X_i} = \frac{dp}{dZ} \frac{\partial Z}{\partial X_i} = f(z) \beta_i = \frac{\varepsilon^{-Z}}{(1 + e^{-Z})^2} \beta_i$$

### 3.3 Пробит-модель

$$f(Z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}Z^2}$$

$$\frac{\partial p}{\partial X_i} = \frac{dp}{dZ} \frac{\partial Z}{\partial X_i} = f(z) \beta_i = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}Z^2} \beta_i$$

## 3.4 Оценка качества бинарных моделей

### 3.4.1 Odd Ratio

$$OR = \frac{Pr(Y = 1)}{Pr(Y = 0)}$$

Для логит-модели  $X_j \uparrow \rightarrow \ln(OR) \uparrow$  на  $\beta_j$ ,  $OR \uparrow$  на  $e^{\beta_j}$

### 3.4.2 $R^2$ -МакФаддена

$$R_{MF}^2 = 1 - \frac{\hat{l}}{l_0}$$

- $\hat{l}$  - Лог. функция правдоподобия в максимуме
- $l_0$  - Лог. функция для модели, в которую включена только константа

### 3.4.3 Pseudo $R^2$

$$\text{Pseudo}R^2 = 1 - \frac{1}{1 + \frac{2}{n}(\hat{l} - l_0)}$$

### 3.4.4 Качество подгонки модели

$$wr_1 = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

$$R_p^2 = 1 - \frac{wr_1}{wr_0}$$

### 3.4.5 Выбор порога отсечения

- Sensitivity - Доля правильно идентифицированных 1
- Specificity - Доля правильно идентифицированных 0
- ROC-кривая =  $\frac{\text{Sensitivity}}{1 - \text{Specificity}}$

## 4 Стохастические регрессоры

### 4.1 Эндогенность

В случае стохастических регрессоров ТГМ выполняется если:

- при любой реализации матрица имеет ранг  $k$
- $\exists \text{plim}_{n \rightarrow \infty} \frac{1}{n} (X^T X)$
- $\boxed{\text{plim}_{n \rightarrow \infty} \frac{1}{n} X^T \varepsilon = 0}$ 
  - Если это условие не выполняется  $\rightarrow$  проблема эндогенности
  - Оценки не являются состоятельными и асимптотически несмещенными



## 4.2 Инструментальные переменные

Для переменной  $X$  переменные  $Z_1, \dots, Z_l$  инструментальные:

- $Z$  сильно коррелируют с  $X$
- $Z$  не коррелируют с ошибками
  - Можно заменить более слабым условием  $\text{plim}_{n \rightarrow \infty} \frac{1}{n} Z_i \varepsilon = 0$
- $\hat{\beta}_1^{\text{ИП}} = \frac{\text{Cov}(Z, Y)}{\text{Cov}(Z, X)}$
- $m = k \rightarrow \hat{\beta}^{\text{ИП}} = (Z^T X)^{-1} Z^T Y$
- $m < k \rightarrow$  Двухшаговый МНК

### 4.2.1 Двухшаговый МНК

1. Оцениваем  $X_j = \alpha_0 + \alpha_1 Z_1 + \dots$ 
  - (a) Проекция каждого вектора  $X$  в пространство  $Z$
  - (b)  $\hat{X}_j = Z(Z^T Z)^{-1} Z^T X$
2. Оцениваем  $Y = \beta_0 + \beta_1 \hat{X}_1 + \dots$ 
  - (a) Каждый вектор  $X$  заменяется на свой инструмент  $\hat{X}$
  - (b)  $\hat{\beta} = (X^T Z (Z^T Z)^{-1} Z^T X)^{-1} (X^T Z (Z^T Z)^{-1} Z^T Y)$

## 4.3 Тест Хаусманна

Определяет проблему эндогенности

- $H_0$  : Все регрессоры экзогенны
- $H_1$  : Имеет место проблема экзогенности

$$H = (\hat{\beta}^{\text{ИП}} - \hat{\beta}^{\text{МНК}})^T (\hat{V}(\hat{\beta}^{\text{ИП}}) - \hat{V}(\hat{\beta}^{\text{МНК}}))^{-1} (\hat{\beta}^{\text{ИП}} - \hat{\beta}^{\text{МНК}}) \sim \chi_{k+1}^2$$

### Тест Ву-Хаусманна

- $H_0$  :  $X_1$  и  $\varepsilon$  не коррелируют
  - $H_1$  :  $X_1$  и  $\varepsilon$  коррелируют
1. Регрессия всех переменных из  $X_1$  на  $Z$ , сохраняем остатки  $v_j$
  2. Оцениваем регрессию с учетом остатков  $Y = \beta_0 + \beta_1 X_1 + \dots + \gamma_1 \hat{v}_1 + \dots$ 
    - (a)  $H_0 : \gamma_1 = \dots = \gamma_k = 0$
    - (b)  $H_1 : \exists \gamma_1^2 + \dots > 0$

Оба теста асимптотически дают одинаковые результаты

## 5 Обобщенный метод моментов

Моментных тождеств берется больше по сравнению с обычным методом моментов

- Берем не равенство моментов, а разницу между выборочным и теоретическим  $g_i$
- Минимизируем разности  $\sum_{i=1}^n w_j g_j^2, w_j \propto \frac{1}{\text{var}(g_j)}$
- В общем случае:  $g^T W g \rightarrow \min$ 
  - Лучшая матрица W:  $W_{opt} = (\text{Var}(g(\hat{\theta}_{GMM})))^{-1}$
  - Но  $\theta_{GMM}$  мы не знаем
- Итерационная процедура
  1.  $\sum_{i=1}^n g_j^2 \rightarrow \min$ 
    - (a)  $\text{Var}^{-1}(g) = W$
  2.  $g^T W g \rightarrow \min$ 
    - (a) С помощью параметров находим новую W
  3. Повторяем до сходимости
- Стандартный метод инструментальных переменных является частным случаем ОММ
- Если у нас есть L инструментов:  $g_i(\beta) = Z_i \varepsilon_i$
- Если инструменты экзогенны, то  $E(g_i(\beta)) = 0$  - Теоретическое тождество (условие ортогональности)
- Эмпирическое тождество:  $\bar{g}(\beta) = \frac{1}{N} Z^T \varepsilon$
- Решаем уравнение  $\bar{g}(\beta) = 0$
- Если количество инструментов = количество регрессоров  $\rightarrow$  Оценки однозначны и совпадают с методом инструментальных переменных
- Если инструментов  $>$ , чем регрессоров  $\rightarrow$  в рамках ОММ оптимизируют квадратичную форму  $J(\beta) = N(\bar{g}(\beta))^T W \bar{g}(\beta) \rightarrow \min$ 
  - Из условия первого порядка  $\frac{\partial J(\beta)}{\partial \beta} \rightarrow \hat{\beta}_{OMM} = (X^T Z W Z^T X)^{-1} X^T Z W Z^T Y$
  - В зависимости от весовой матрицы W может быть множество оценок

$$(Z^T \varepsilon)^T W (Z^T \varepsilon) \rightarrow (Z^T (Y - X\beta))^T W (Z^T (Y - X\beta)) \rightarrow$$

$$(Y^T - \beta^T X^T) Z W Z^T (Y - X\beta) =$$

$$Y^T Z W Z^T Y - \beta^T X^T Z W Z^T Y - Y^T Z W Z^T X \beta + \beta^T X^T Z W Z^T X \beta =$$

$$-2\beta^T X^T Z W Z^T Y + \beta^T X^T Z W Z^T X \beta = 0 \rightarrow$$

$$\hat{\beta}_{GMM} = (X^T Z W Z^T X)^{-1} X^T Z W Z^T Y$$

$$- A = (X^T Z W Z^T X)^{-1} X^T Z W Z^T \rightarrow \text{Var}(\hat{\beta}_{OMM}) = A \text{Var}(Y) A^T$$

- Выбор оптимальной весовой матрицы
  - Пусть  $Var(\varepsilon) = \Omega$
  - $S = \frac{1}{N} E(Z^T \varepsilon \varepsilon^T Z) = \frac{1}{N} E(Z^T \Omega Z)$
  - $W_{opt} = S^{-1} \rightarrow$  наиболее эффективные оценки ОММ
  - Оценивание матрицы  $\Omega$ 
    - \* Гомоскедастичность  $\Omega = \sigma^2 I$   $S = \frac{\sigma^2}{N} E(Z^T Z)$
    - \* Гетероскедастичность  $\Omega \neq \sigma^2 I$ 
      - Оцениваем исходное уравнение методом инструментальных переменных
      - На основании остатков  $\hat{\varepsilon} = Y - X\hat{\beta}_{IV} \rightarrow \hat{\Omega}$
      - $\hat{\Omega}$  - матрица квадратов остатков
      - Можно итерационно подбирать  $\beta$
- Достоинства и недостатки ОММ
  - Достоинства
    - \* В отсутствие гетероскедастичности асимптотически не хуже, чем метод инструментальных переменных
    - \* В случае гетероскедастичности лучше, чем метод инструментальных переменных
  - Недостатки
    - \* Неэффективно на маленьких выборках

## 5.1 Тестирование качества инструментов

- Проверка коррелированности эндогенных регрессоров и инструментов
- Если  $Y = X_1\beta_1 + X_2\beta_2 + \varepsilon$ ,  $X_1$  и  $\varepsilon$  коррелируют
  - $Z$  - инструменты
  - Строим регрессию  $X_1$  на  $Z$  и посмотреть на  $R^2$  и F-stat  $> 10$ , иначе инструменты слабые
  - Проверка экзогенности инструментов
    - \* Тест Хансена  $J(\hat{\beta}) = N(\bar{g}(\hat{\beta})^T) \hat{S}^{-1} \bar{g}(\hat{\beta}) \sim \chi^2_{L-K}$
    - \* При гетероскедастичности  $J(\hat{\beta}) = \hat{\varepsilon}^T Z (Z^T \hat{\Omega} Z)^{-1} Z^T \hat{\varepsilon} \sim \chi^2_{L-K}$
    - \* При гомоскедастичности (Тест Саргана)  $J(\hat{\beta}) = \frac{1}{\hat{\sigma}_{\varepsilon}^2} \hat{\varepsilon}^T Z (Z^T Z)^{-1} Z^T \hat{\varepsilon} \sim \chi^2_{L-K}$

## 6 Системы одновременных уравнений

Пример - модель спроса и предложения

$$\begin{cases} q_t^S = \alpha P_t + \varepsilon_t \\ q_t^D = \beta P_t + \gamma I n_t + u_t \end{cases}$$

Подбираем параметры  $\alpha, \beta, \gamma$

Если оценить по отдельности, то получим смещенные оценки коэффициентов

$$q_t^S = q_t^D \rightarrow \alpha P_t + \varepsilon_t = \beta P_t + \gamma In_t + u_t \rightarrow P_t = \frac{\gamma In_t + u_t + \varepsilon_t}{\alpha - \beta}$$

Цена связана с ошибками в обоих уравнениях  $\rightarrow$  эндогенность

Подставляем в (1)

$$\begin{cases} q_t = \frac{\alpha\gamma}{\alpha-\beta} In_t + \frac{\alpha(u_t - \varepsilon_t) + (\alpha-\beta)\varepsilon_t}{\alpha-\beta} \\ P_t = \frac{\gamma In_t + u_t + \varepsilon_t}{\alpha-\beta} \end{cases}$$

В этих уравнениях нет проблем эндогенности:

$$\pi_1 = \frac{\gamma}{\alpha - \beta}, \pi_2 = \frac{\alpha\gamma}{\alpha - \beta}$$

$$\hat{\pi}_1, \hat{\pi}_2 \rightarrow \hat{\alpha} = \frac{\hat{\pi}_1}{\hat{\pi}_2}$$

Альтернатива:

Использовать инструментальную переменную дохода вместо цен в (1)

$$\hat{\alpha}_{IV} = \frac{q^T In}{p^T In}$$

Можем однозначно найти только  $\alpha$

## 6.1 Общий случай СОУ

- Разделяем все переменные на эндогенные  $(Y_1, \dots, Y_m)$ , экзогенные  $(X_1, \dots, X_k)$
- У каждого  $Y$  свое уравнение, у каждого  $X$  свой параметр
- Структурная форма СОУ

$$\begin{cases} \beta_{11}Y_{1t} + \dots + \beta_{1m}Y_{mt} + \gamma_{11}X_{1t} + \dots + \gamma_{1k}X_{kt} = \varepsilon_{1t} \\ \beta_{21}Y_{1t} + \dots + \beta_{2m}Y_{mt} + \gamma_{21}X_{1t} + \dots + \gamma_{2k}X_{kt} = \varepsilon_{2t} \\ \dots \\ \beta_{m1}Y_{1t} + \dots + \beta_{mm}Y_{mt} + \gamma_{m1}X_{1t} + \dots + \gamma_{mk}X_{kt} = \varepsilon_{mt} \end{cases}$$

- В матричной форме

$$Y = \begin{pmatrix} Y_1 \\ \dots \\ Y_m \end{pmatrix}, X = \begin{pmatrix} X_1 \\ \dots \\ X_m \end{pmatrix}, B = \begin{pmatrix} \beta_{11} & \dots & \beta_{1m} \\ \dots & & \\ \beta_{m1} & \dots & \beta_{mm} \end{pmatrix}, \Gamma = \begin{pmatrix} \gamma_{11} & \dots & \gamma_{1k} \\ \dots & & \\ \gamma_{k1} & \dots & \gamma_{kk} \end{pmatrix}$$

$$BY_t + \Gamma X_t = \varepsilon_t$$

$$Y_t = -B^{-1}\Gamma X_t + B^{-1}\varepsilon_t \text{ - приведенная форма } \rightarrow \Pi = -B^{-1}\Gamma$$

$$Y = \Pi X_t + v_t$$

В структурной форме  $m^2 - m + mk \rightarrow$  в общем случае не решается, некоторые коэффициенты могут быть нулевыми и тогда получится

Будем считать, что  $\exists$   $q$   $Y$  и  $p$   $X$  с ненулевыми коэффициентами

$Y_*$  - ненулевые,  $Y_{**}$  - нулевые  
 $X_x$  - ненулевые,  $X_{xx}$  - нулевые

$$\begin{aligned}\beta_*^T Y_{*t} + \gamma_x^T X_{xt} &= \varepsilon_{1t} \\ \begin{pmatrix} Y_{*t} \\ Y_{**t} \end{pmatrix} &= \begin{pmatrix} \Pi_{*x} & \Pi_{*xx} \\ \Pi_{**x} & \Pi_{**xx} \end{pmatrix} \begin{pmatrix} X_{xt} \\ X_{xxt} \end{pmatrix} + v_t \\ B\Pi = -\Gamma &\rightarrow (\beta'_* \ 0) \begin{pmatrix} \Pi_{*x} & \Pi_{*xx} \\ \Pi_{**x} & \Pi_{**xx} \end{pmatrix} = -(\gamma'_x \ 0) \\ \beta'_* \Pi_{*xx} &= 0\end{aligned}$$

Левая часть уравнения размером  $(k - p)$ , правая -  $(q - 1)$

Необходимое условие идентификации

$$\begin{aligned}k - p &\geq (q - 1) \rightarrow \text{можем выразить } \beta \\ (k - p) + (m - q) &\geq m - 1\end{aligned}$$

Число нулевых коэффициентов в уравнении  $\geq$  число уравнений - 1

Необходимое и достаточное условие

$$\text{rank} \Pi_{*xx} = q - 1$$

• *Виды уравнений*

- $k - p = q - 1 \rightarrow$  точно идентифицируемое
  - \* Косвенный метод наименьших квадратов
  - \* Оцениваем уравнения приведенной формы и из них выражаем уравнения структурной формы
- $k - p > q - 1 \rightarrow$  сверх идентифицируемое
  - \* Применяется двухшаговый МНК
  - \* Каждый  $Y$  (кроме  $Y$  с коэффициентом 1) заменяется на оценку  $\hat{Y}$  из уравнения регрессии  $Y$  на все  $X$

## 6.2 Трехшаговый МНК

**Общий вид системы уравнений**

$$\begin{pmatrix} y_1 \\ \dots \\ y_M \end{pmatrix} = \begin{pmatrix} Z_1 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & Z_M \end{pmatrix} \begin{pmatrix} \beta_1 \\ \dots \\ \beta_M \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \dots \\ \varepsilon_M \end{pmatrix}$$

$Z_1, \dots, Z_M$  - включают экзогенные и эндогенные переменные

$$E(\varepsilon) = 0$$

$$E(\varepsilon\varepsilon') = \Sigma$$

В трехшаговом МНК находим оценку  $\Sigma$  и потом применяем обобщенный МНК

1. Инструментирование всех эндогенных переменных всеми экзогенными  

$$\hat{z}_i = X(X'X)^{-1}X'z_i$$
2. Каждый  $Y$  в уравнении, кроме  $Y$  с коэффициентом 1, заменяется на оценку  $\hat{Y}$  из уравнения регрессии на все  $X$  и оценивается каждое уравнение регрессии
3. (a) Сохраняем остатки  
 (b) Составляем из них матрицу  $E$   
 (c)  $\hat{\Sigma} = \frac{E'E}{n}$   
 (d)  $\hat{B} = \left[ \hat{Z}'(\Sigma^{-1} \otimes I) \right]^{-1} \hat{Z}'(\Sigma^{-1} \otimes I)y$   
 (e)  $V_{\hat{B}} = (\hat{Z}'(\Sigma^{-1} \otimes I)\hat{Z})^{-1}$   
 (f) Если известно  $var(\varepsilon) = \Omega$ , то обобщенный метод наименьших квадратов более эффективен  

$$\hat{\beta}_{FGLS} = (X'\hat{\Omega}^{-1}X)^{-1}X'\hat{\Omega}Y$$
  

$$\hat{\Omega} = \hat{\Sigma} \otimes I$$
  

$$Var(\hat{\beta}_{FGLS}) = (X'\hat{\Omega}^{-1}X)^{-1}$$

**Кронекерово произведение (тык)**

$$\bullet \Sigma \otimes I_N = \begin{pmatrix} \Sigma & \dots & \dots \\ \dots & \Sigma & \dots \\ \dots & \dots & \Sigma \end{pmatrix}$$

### 6.3 SUR. Внешне не связанные уравнения

Справа только X → Применить OLS?

Считаем, что эписилоны в разных уравнениях могут быть связаны (внешние шоки для внутренних  $Y$ ) → Трехшаговый МНК без первого шага

Формулы те же, заменяем  $Z$  на  $X$

## 7 Модели множественного выбора

$$\bullet OR = \frac{P(Y=1)}{P(Y=0)} \rightarrow \ln(OR) = \beta_0 + \beta_1 X_1 + \dots$$

### 7.1 Модели упорядоченного множественного выбора

- $Y$  упорядочен по какому-то критерию (согласен, скорее согласен, ...)
- $Y_i = \{1, 2, \dots, m\}$
- $Y_i^* = x_i' \beta + \varepsilon_i$
- $Y_i = j$ , if  $c_{j-1} < Y_i^* < c_j, j = 1, \dots, m$
- $c_0 = -\infty, \dots, c_m = \infty$
- С помощью оценки метода правдоподобия оцениваем  $\beta, c$
- $L = \prod_{j=1}^m \prod_{i: Y_i=j} (F(c_j - x_i' \beta) - F(c_{j-1} - x_i' \beta)) \rightarrow \max_{\beta, c}$

### 7.1.1 Гипотеза о параллельности

- $P(Y_i = j) = F(c_j - x'_i\beta) - F(c_{j-1} - x'_i\beta)$
- Проверить, что  $Y_i$  принимает значение не больше  $k$
- Просуммировать все вероятности  $Y_i \leq k$  по  $k$
- $P(Y_i \leq k|X) = F(c_k - x'_i\beta), k = 1, \dots, m$
- Тест Бранта

### 7.1.2 Отношение шансов

- $\frac{P(Y_i \leq k|X)}{P(Y_i > k|X)} = \exp(c_k - x'_i\beta) \rightarrow \frac{P(Y_i > k|X)(X, x_j+1)}{P(Y_i \leq k|X)(X, x_j+1)} = \exp(\beta_j)$

### 7.1.3 Предельные эффекты

- $\frac{\partial P(Y=j)}{\partial X_k} = -\beta_k f(c_1 - (X\beta))$
- $\frac{\partial P(Y=j)}{\partial X_k} = \beta_k f(c_{m-1} - (X\beta))$

## 7.2 Мультиномиальные модели

- Ответы не упорядочены
- $U_{ij}$  - полезность  $j$ -ой альтернативы для  $i$ -го индивида
- $P\{Y_i = j\} = P\{U_{ij} = \max\{U_{i1}, \dots, U_{im}\}\}$
- $U_{ij} = x'_i\beta_j + \varepsilon_{ij}$
- Для нормального распределения аналитическое решение не находится
- Задача допускает аналитическое решение, если  $\varepsilon_{ij}$  независимы и имеют функцию распределения  $F(x) = \exp\{-\exp(-x)\}$
- $P(Y_i = 1) = \frac{1}{1 + \exp(x_i\beta_2) + \dots + \exp(x_i\beta_m)}$
- $P(Y_i = j) = \frac{\exp(x_i\beta_j)}{1 + \exp(x_i\beta_2) + \dots + \exp(x_i\beta_m)}$
- $\frac{P(Y_i=j)}{P(Y_i=k)} = \frac{\exp(x_i\beta_j)}{\exp(x_i\beta_k)} = \exp(x'_i(\beta_j - \beta_k))$
- Сильно предположение о независимости альтернатив

## 8 Тобит, Sample selection models

### 8.1 Тобит

- $Y_i = \begin{cases} Y_i^*, & \text{if } Y_i^* > 0 \\ 0, & \text{if } Y_i^* \leq 0 \end{cases}$
- $Y_i^* = x_i^*\beta + u_i$

- $P(Y_i = 0) = P(Y_i^* \leq 0) = P(u_i \leq -x'_i\beta) = P\left(\frac{u_i}{\sigma_u} \leq \frac{-x'_i\beta}{\sigma_u}\right) = 1 - \Phi\left(\frac{-x'_i\beta}{\sigma_u}\right)$
- $f(y|Y \geq c) = \frac{f(y)}{P(Y \geq c)}$ , if  $y \geq c$  and 0 otherwise
- $E(Y_i|Y_i > 0) = x'_i\beta + \sigma \frac{\phi(x'_i\beta/\sigma)}{\Phi(x'_i\beta/\sigma)}$
- $\frac{\partial E(Y_i)}{\partial X_j} = \Phi(x'_i\beta/\sigma)\beta_j$
- $L(\beta, \sigma^2) = \prod_{Y_i=0} P(Y_i = 0) \prod_{Y_i>0} \phi(Y_i)$
- Оценивается градиентным спуском

## 8.2 Модель Хекмана

- $Y_i^* = x'_i\beta + \varepsilon_i$
- $g_i^* = z_i\gamma + u_i$  (Модель участия)
- $g_i = \begin{cases} 1, g_i^* \geq 0 \\ 0, g_i^* < 0 \end{cases}$
- General model
 
$$\begin{cases} Y_i = Y_i^*, g = 1 \text{ if } g_i^* \geq 0 \\ Y_i \text{ is not observed, OTW} \end{cases}$$
- $E(Y_i|g_i = 1) = x'_i\beta + E(\varepsilon_i|g_i = 1) = x'_i\beta + E(\varepsilon_i|u_i \geq -z'_i\gamma) = E(Y_i|g_i = 1) = x'_i\beta + \sigma_{\varepsilon u} \lambda(z'_i\gamma)$
- Лямбда Хекмана:  $\lambda(z'_i\gamma) = \frac{\phi(z'_i\gamma)}{\Phi(z'_i\gamma)}$
- Можем использовать разные данные для функций  $\rightarrow$  более гибкая модель, чем модель Тобита

### 8.2.1 Оценка

1. Метод правдоподобия - не всегда сходится
2. Двухшаговая процедура (сначала g, потом Y)

## 9 Ядерные методы

- Ищем оценку  $E(Y|X = x) = m(x)$
- $\int_{-\infty}^{\infty} y \hat{f}(y|x) dy$
- Составляем гистограмму X
- 

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n \frac{1}{2} I\left(\left|\frac{x - X_i}{h}\right| \leq 1\right)$$

- Свойства ядра



- $K(z) \geq 0$
- $\int_{-\infty}^{\infty} K(z) dz = 1$
- $\int_{-\infty}^{\infty} z K(z) dz = 0$
- $\int_{-\infty}^{\infty} z^2 K(z) dz < \infty$

- Обычно ядра имеют выпуклую форму на промежутке  $[-1, 1]$

•

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n \frac{1}{2} I\left(\left|\frac{x - X_i}{h}\right| \leq 1\right) = \frac{1}{n} \sum_{i=1}^n K_h(x - X_i), K_h(\cdot) = \frac{K(\cdot/h)}{h}$$

- Расчет оптимального окна производится через интегрирование MSE по  $h$

- $h_{opt} = \left( \frac{\|K\|_2^2}{\|f^*\|_2^2 (\mu_2(K))^2 n} \right)^{\frac{1}{5}} \sim n^{-\frac{1}{5}}$

- *Rule of Thumb:*

$$\hat{h}_{rot} = 1.06 \hat{\sigma} n^{-\frac{1}{5}}$$

## 9.1 Ядерная оценка регрессии

### Nadaraya-Watson Estimator

$$\hat{m}_k(x) = \frac{n^{-1} \sum_{i=1}^n K_h(x - X_i) Y_i}{n^{-1} \sum_{i=1}^n K_h(x - X_i)}$$

*Среднее по  $Y$  в выбранном окне*

## Part II

# Модуль 4

## 10 Временные ряды

- Данные упорядочены
- Измерения должны быть в каждый момент времени
- Данные могут быть различной частотности

- Временной ряд  $\{X_t\}_{t=-\infty}^{\infty}$  - это последовательность случайных величин, заданных на одной вероятностной основе

- Реализация части этой последовательности тоже называется временным рядом

### Компоненты временного ряда

- *Тренд* – Временной ряд с трендом  $\rightarrow Y$  монотонно изменяется со временем
- *Сезонная компонента* – Повторяющиеся паттерны

- *Циклическая компонента* – Циклы повторяются не через равные промежутки времени
- *Случайная компонента* – Колебания вне циклов

## Виды временных рядов

- *Стационарный ряд* –  $F(X_{t_1}, \dots, X_{t_m}) = F(X_{t_1+k}, \dots, X_{t_m+k})$  для любых моментов  $m$  и для любого сдвига  $k$ 
  - Слишком жесткое требование
- *Стационарный ряд (в широком смысле)*
  - $E(X_t) = \mu, \forall t$
  - $Var(X_t) = \sigma^2, \forall t$
  - $cov(X_t, X_{t+s})$  зависит только от  $s$
  - Пример - белый шум:  $X_t = \varepsilon_t, \varepsilon_t \sim iid(0, \sigma_\varepsilon^2)$
  - *Линейный временной ряд*
    - \*  $X_t = \mu + \sum_{i=0}^{\infty} \alpha_i \varepsilon_{t-i}$
    - \*  $\alpha_0 = 1, \varepsilon_t \sim iid(0, \sigma_\varepsilon^2)$
  - *AR модель*
    - \*  $X_t = \beta_1 X_{t-1} + \varepsilon_t$
    - \*  $X_t = \beta_0 + \beta_1 X_{t-1} + \varepsilon_t$
    - \* Проверка стационарности
      - $E(X_t) = \beta_1^t X_0 \rightarrow 0$
      - $\sigma_{X_t}^2 = \frac{1-\beta_1^{2t}}{1-\beta_1^2} \sigma_\varepsilon^2 \rightarrow \frac{1}{1-\beta_1^2} \sigma_\varepsilon^2, |\beta_1| \leq 1$
      - $cov(X_t, X_{t+s}) = \frac{\beta_1^s}{1-\beta_1^2} \sigma_\varepsilon^2$
  - *Нестационарный временной ряд*
    - \*  $E(\varepsilon_t) = 0, \forall t$
    - \*  $var(\varepsilon_t) = \sigma_\varepsilon^2, \forall t$
    - \*  $cov(\varepsilon_t, \varepsilon_s) = 0, t \neq s$
    - \* Random Walk
      - $X_t = X_{t-1} + \varepsilon_t$
      - $X_t = X_{t-2} + \varepsilon_{t-1} + \varepsilon_t$
      - $X_t = X_0 + \varepsilon_1 + \dots + \varepsilon_t$
      - $var(X_t) = t\sigma_\varepsilon^2$
    - \* Случайное блуждание с дрейфом
      - $X_t = \mu + X_{t-1} + \varepsilon_t$
    - \* Проверка стационарности
      - $\beta_1 > 1 \rightarrow$  большая дисперсия, взрывной процесс
  - Нестационарные временные ряды типа TS
    - \* *TS* - Этот ряд становится стационарным после выделения тренда
      - $X_t = \beta_0 + \beta_1 t + \beta_2 X_{t-1} + \varepsilon_t, -1 < \beta_2 < 1$

- Нестационарные временные ряды типа DS
  - \* Ряд становится стационарным только в разностях
  - \*  $\Delta X_t = X_t - X_{t+1} = \beta_0 + \varepsilon_t \rightarrow E(\Delta X_t) = \beta_0$

### Тесты на стационарность рядов

- Автокорреляционная функция (ACF)

$$\rho_k = \frac{E((X_t - \mu_X)(X_{t+k} - \mu_X))}{\sqrt{E((X_t - \mu_X)^2 E((X_{t+k} - \mu_X)^2))}}$$

$$\rho_k = \frac{\sum((X_t - \bar{X})(X_{t+k} - \bar{X}))}{\sqrt{(\sum(X_t - \bar{X})^2 \sum(X_{t+k} - \bar{X})^2)}}$$

График корреляций по k называется *Коррелограмма* → Для стационарного ряда быстро убывает

- Частная автокорреляционная функция (PACF)

PACF(k) вычисляется как МНК оценка коэффициента  $\beta_k$  в регрессии  $X_t = \beta_0 + \dots + \beta_k X_{t-k} + \varepsilon_t$

Частные автокорреляционные функция для стационарных процессов тоже быстро убывают

- Unit root test

$$\begin{cases} H_0 : \beta_1 = 1 \\ H_1 : \beta_1 < 1 \end{cases}$$

$H_0$  - нестационарность

$$\Delta X_t = \delta X_{t-1} + \varepsilon_t$$

$$\begin{cases} H_0 : \delta = 0 \\ H_1 : \delta < 0 \end{cases}$$

$$t = \frac{\delta}{s.e.(\delta)}$$

Распределение статистики Дики-Фуллера не совпадает со Стьюдентом - нужно тау-распределение

$H_0$  отвергается, если  $t < \tau_0^{cr}$ , без  $\beta_0$

$H_0$  отвергается, если  $t < \tau_\mu^{cr}$ , с  $\beta_0$

$H_0$  отвергается, если  $t < \tau_\tau^{cr}$ , с детрендированием

- Расширенный тест Дики-Фуллера

$$\Delta X_t = \beta_0 + \delta X_{t-1} + \beta_2 t + \sum_{i=1}^m \alpha_i \Delta X_{t-i} + \varepsilon_t$$

$$\begin{cases} H_0 : \delta = 0 \\ H_1 : \delta < 0 \end{cases}$$

Тестовые статистики не изменяются

- KPSS тест

$$y_t = \beta t + r_t + \varepsilon_t$$

$$r_t = r_{t-1} + u_t$$

$$\begin{cases} H_0 : \sigma_u^2 = 0 \text{ (Стационарность)} \\ H_1 : \sigma_u^2 \neq 0 \end{cases}$$

$$S_t = \sum_{s=1}^t e_s$$

$$KPSS = \sum_{s=1}^T S_t^2 / \hat{\sigma}^2$$

$$\hat{\sigma}^2 = \lim_{T \rightarrow \infty} T^{-1} E(S_T^2)$$

## 10.1 Процессы

### Теорема Вольда

Если  $X_t$  - стационарный ряд, то его можно представить в виде:

$$X_t = d_t + \sum_{\tau=0}^{\infty} \alpha_{\tau} \varepsilon_{t-\tau}$$

- $d_t$  - предсказуемый случайный процесс
- $\varepsilon_t$  - белый шум
- $\sum_{\tau=0}^{\infty} \alpha_{\tau}$  - слагаемые не коррелируют

### Процессы AR

$$y_t = Y_t - \mu$$

$$AR(p) : y_t = \theta_1 y_{t-1} + \theta_2 y_{t-2} + \dots + \theta_p y_{t-p}$$

*Лаговый оператор:*

$$L^S(Y_t) = Y_{t-S}$$

$$AR(p) : \theta(L) = 1 - \theta_1 L - \theta_2 L^2 - \dots - \theta_p L^p$$

### МА процессы

$$MA(q) : y_t = \varepsilon_t + \alpha_1 \varepsilon_{t-1} + \dots + \alpha_q \varepsilon_{t-q}$$

Процесс всегда стационарный:

$$(E(\varepsilon_t) = 0)$$

### Стационарность процесса AR(1)

$$AR(1) : y_t = \theta y_{t-1} + \varepsilon_t \rightarrow (1 - \theta L)^{-1}(1 - \theta L)y_t = (1 - \theta L)^{-1}\varepsilon_t$$

$$(1 - \theta L)^{-1} = \sum_{j=0}^{\infty} \theta^j L^j, |\theta| < 1$$

$$|\theta| < 1 - \text{условие стационарности процесса AR(1)}$$

$$y_t = (1 - \theta L)^{-1}\varepsilon_t$$

$$y_t = \sum_{j=0}^{\infty} \theta^j \varepsilon_{t-j} \rightarrow AR(1) \leftrightarrow MA(\infty), |\theta| < 1$$

### Стационарность процесса AR(2)

$$AR(2) : y_t = \theta_1 y_{t-1} + \theta_2 y_{t-2} + \varepsilon_t$$

$$(1 - \theta L - \theta_2 L^2)y_t = \varepsilon_t \rightarrow (1 - \phi_1 L)(1 - \phi_2 L)y_t = \varepsilon_t$$

$$(1 - \phi_1 L), (1 - \phi_2 L) - \text{должны быть обратимы}$$

Условие стационарности:

$$|\phi_1| > 1, |\phi_2| < 1$$

Обратное характеристическое уравнение:

$$(1 - \phi_1 z)(1 - \phi_2 z) = 0 \rightarrow z_1 = \frac{1}{\phi_1}, z_2 = \frac{1}{\phi_2}$$

При обратимости процесса AR(2):

$$|z_i| > 1$$

$$y_t = \theta_1 y_{t-1} + \theta_2 y_{t-2} + \varepsilon_t$$

Прямое уравнение:

$$\lambda^2 - \theta_1 \lambda - \theta_2 = 0$$

При стационарности:

$$|\lambda_i| < 1$$

### **ARMA процессы**

ARMA(p, q):

$$y_t = \theta_1 y_{t-1} + \dots + \theta_p y_{t-p} + \varepsilon_t + \alpha_1 \varepsilon_{t-1} + \dots + \alpha_q \varepsilon_{t-q}$$

$$\theta(L)y_t = \alpha(L)\varepsilon_t$$

Если корни обратного характеристического уравнения  $\theta(z) = 0$  удовлетворяют условию  $|z_j| > 1 \forall j = 1, \dots, p \leftrightarrow$  Корни прямого характеристического уравнения удовлетворяют условию  $|\lambda_i| < 1, i = 1, \dots, p$

Обратимость МА процесса

$$MA(1) : y_t = \varepsilon_t + \alpha \varepsilon_{t-1}$$

$$y_t = (1 - \alpha L)\varepsilon_t$$

$$(1 + \alpha L)^{-1} = \sum_{j=0}^{\infty} (-\alpha)^j L^j$$

$$y_t = \alpha \sum_{j=0}^{\infty} (-\alpha)^j y_{t-j-1} + \varepsilon_t$$

$$MA(q) : y_t = \alpha(L)\varepsilon_t$$

*Необходимое условие  $AR(\infty)$  представления:*

Обратимость  $\alpha(L)$ . Корни прямого характеристического уравнение для МА части должны быть меньше 1 по модулю

## 10.2 Диагностика моделей

### 10.2.1 ACF, PACF

**ACF:**

$$\rho_k = \frac{cov\{Y_t, Y_{t-k}\}}{var\{Y_t\}}$$

**PACF:**

PACF(k) - чистая корреляция между  $Y_t$  и  $Y_{t-k}$ . Вычисляется как оценка МНК параметра

$$\underline{AR(1)}$$

*ACF:*

$$AR(1) : y_t = \theta y_{t-1} + \varepsilon_t$$

$$y_t = \sum_{j=0}^{\infty} \theta^j \varepsilon_{t-j}$$

$$\rho_k = \theta^k$$

*PACF:*

$$AR(1) : y_t = \theta y_{t-1} + \dots + 0y_{t-p} + \varepsilon_t$$

$$PACF = \begin{cases} \theta, k = 1 \\ 0, k > 1 \end{cases}$$

$$\underline{AR(2)}$$

Для стационарного процесса:

$$\mu = \delta / (1 - \theta_1 - \theta_2)$$

$$y_t = Y_t - \mu$$

$$y_t y_t = \theta_1 y_t y_{t-1} + \theta_2 y_t y_{t-2} + y_t \varepsilon_t$$

$$E(y_t y_t) = \theta_1 E(y_t y_{t-1}) + \theta_2 E(y_t y_{t-2}) + E(y_t \varepsilon_t)$$

$$\gamma_0 = \theta_1 \gamma_1 + \theta_2 \gamma_2 + \sigma_\varepsilon^2$$

Аналогично: домножаем на  $t - 1$ ,  $t - 2$ ,  $t - 3$

$$\gamma_1 = \theta_1 \gamma_0 + \theta_2 \gamma_1$$

$$\gamma_2 = \theta_1 \gamma_1 + \theta_2 \gamma_0$$

$$\gamma_3 = \theta_1 \gamma_2 + \theta_2 \gamma_1$$

Решаем систему для гамм:

Условия стационарности

$$\gamma_1 + \gamma_2 < 1$$

$$\gamma_2 - \gamma_1 < 1$$

$$|\gamma_2| < 1$$

Делим на дисперсию ( $\gamma_0$ )

$$\rho_1 = \frac{\theta_1}{1 - \theta_2}$$

$$\rho_2 = \frac{\theta_1^2}{1 - \theta_2} + \theta_2$$

Для остальных порядков необходимо решить разностное уравнение:

$$\rho_k = \theta_1 \rho_{k-1} + \theta_2 \rho_{k-2}$$

Решение:

$$\rho_k = C_1 \lambda_1^k + C_2 \lambda_2^k$$

$$\lambda_1, \lambda_2 : \lambda^2 - \theta_1 \lambda - \theta_2 = 0$$

Для стационарного процесса  $|\lambda_i| < 1$

*ACF для  $AR(p)$  exp убывающая*

**PACF:**

$$PACF = \begin{cases} \theta_1, k = 1 \\ \theta_2, k = 2 \\ 0, k > 2 \end{cases}$$

Для AR(p) аналогично

$$\underline{MA(p)}$$

**ACF:**

$$\begin{aligned} Y_t &= \mu + \varepsilon_t + \alpha \varepsilon_{t-1} \\ \gamma_0 &= \text{var}(Y_t) = (1 - \alpha^2) \sigma_\varepsilon^2 \\ \gamma_1 &= \text{cov}(Y_t, Y_{t-1}) = \text{cov}(\mu + \varepsilon + \alpha \varepsilon_{t-1}, \mu + \varepsilon_{t-1} + \alpha \varepsilon_{t-2}) = \alpha \sigma_\varepsilon^2 \\ \gamma_2 &= \gamma_3 = \dots = 0 \\ \rho_1 &= \frac{\alpha}{1 + \alpha^2} \\ \rho_j &= 0, j > 1 \end{aligned}$$

Аналогично для MA(q):

$$\rho_j = 0, j > q$$

**PACF:**

$$\begin{aligned} MA(1) &\leftrightarrow AR(\infty) \\ y_t &= \alpha \sum_{j=0}^{\infty} (-\alpha)^j y_{t-j-1} + \varepsilon_t \end{aligned}$$

Если  $|\alpha| < 1$ : PACF является exp убывающей, аналогично для MA(q)

Процесс	ACF	PACF
$AR(p)$	Exp убывает	= 0 при $p > k$
$MA(q)$	= 0 при $p > k$	Exp убывает
$ARMA(p, q)$	Exp убывает	Exp убывает

Table 1: Коррелограмма процессов

Если элементы PACF, ACF не превышают  $2/\sqrt{T}$  статистически неотличимы от 0

### 10.3 Способы оценки параметров

1. AR(q) оценивается с помощью МНК
2. MA(q), ARMA(p, q) оцениваются с помощью ММП



## 10.4 Критерии выбора $p$ и $q$

1. Проверка, что ошибки в модели являются белым шумом
2. Информационные критерии выбора количества лагов
  - (a) Критерий Акаике

$$AIC = -2\ln L + 2k \rightarrow \min$$

- (b) Критерий Шварца

$$BIC = -2\ln L + (\ln T)k \rightarrow \min$$

Более сильно штрафует за включение лишних лагов

## 10.5 ARIMA

Процесс, который становится стационарным в разностях

$Y_t$  - нестационарный процесс

$\Delta^d Y_t$  - стационарный процесс ARIMA

## 10.6 Подход Бокса-Дженкинса

1. Проверка ряда на стационарность
2. Если ряд не стационарный - находим разность при которой он является стационарным
3. Для стационарного ряда необходимо выбрать  $p$  и  $q$  с помощью ACF, PACF
4. Оценка параметров
5. Проверка остатков
6. Использование модели для прогнозирования

## 10.7 Современный подход

1. Изучение графика ряда - тренд, сезонность
2. Выделение тренда
3. При наличии сезонности - включение дамми переменных
4. Моделирование оставшейся модели

## 10.8 Автокорреляция случайной составляющей

1. Коррелированность с предыдущими значениями
2. Чаще всего встречается для временных рядов
3. Приводит к нарушению ТГМ
4. Отрицательная автокорреляция -  $\text{corr} < 0$

$$AR(1) : \varepsilon_t = \rho \varepsilon_{t-1} + u_t$$

$$u_t \sim i.i.d$$

$$|\rho| < 1 \rightarrow$$

возмущения удовлетворяют марковской схеме первого порядка

### *Причины автокорреляции*

1. Инертность экономических показателей
2. Ошибки спецификации модели, невключение существенных переменных
3. Сглаживание данных

### *Последствия автокорреляции*

1. Оценки МНК останутся несмещенными, но не будут эффективными
2. Оценки для стандартных ошибок коэффициентов будут заниженными
3. Статистики будут завышенными

### Выявление автокорреляции

Визуальный способ выявления автокорреляции





### 10.8.1 Тест серий

Серия остатков - набор последовательных остатков одного знака

Если есть автокорреляция, то таких серий должно быть немного, но они достаточно длинные

*Формальное описание*

$$\left\{ \begin{array}{l} H_0 : \rho = 0 \\ H_1 : \text{Имеет место автокорреляция первого порядка} \end{array} \right.$$

1. Оцениваются параметры уравнения регрессии
2. Отмечаем знаки остатков
3. (a)  $n$  - число всех наблюдений  
 (b)  $N_1$  - число знаков +  
 (c)  $N_2$  - число знаков -  
 (d)  $K$  - число серий
4. Если  $K \leq K_{min}$ , то имеет место положительная автокорреляция
5. Если  $K \geq K_{max}$ , то имеет место отрицательная автокорреляция
6.  $k \sim N\left(\frac{2N_1N_2}{N_1+N_2} + 1; \frac{2N_1N_2(2N_1N_2 - N_1 - N_2)}{(N_1+N_2)^2(N_1+N_2-1)}\right)$

### 10.8.2 Статистика Дарбина-Уотсона

$$d = \frac{\sum_{t=2}^T (e_t - e_{t-1})^2}{\sum_{t=1}^T e_t^2}$$

$$\left\{ \begin{array}{l} d \rightarrow 2 \Rightarrow \rho \approx 0 \\ d \rightarrow 0 \Rightarrow \rho \approx 1 \\ d \rightarrow 4 \Rightarrow \rho \approx -1 \end{array} \right.$$

Надо проверять с учетом доверительных интервалов - статистики  $d_l$  и  $d_u$  мажорируют статистику  $d$  сверху независимо от параметров  
 Если  $d < d_l \Rightarrow$  положительная автокорреляция  
 Если  $d > d_u \Rightarrow$  нет положительной автокорреляции  
 Если между - неопределенность

### 10.8.3 Устранение автокорреляции

1. Преобразовать исходные данные
2. Использовать стандартные ошибки в форме Ньюи-Веста
3. Использовать ММП

Если мы знаем  $\rho$  - можно произвести сдвиг

$$Y_t - \rho Y_{t-1} = \beta_0(1 - \rho) + \beta_1(X_t - \rho X_{t-1}) + u_t, u_t - \text{некоррелированные ошибки}$$

$$Y^* = \beta_0 + \beta_1 X_t^* + u_t$$

$u_t$  удовлетворяют ТГМ

Теряется первое наблюдение

#### Поправка Прайса-Уинстона

Выражается из обобщенного метода МНК

$$Y_1^* = \sqrt{1 - \rho^2} Y_1$$

$$Y_t^* = Y_t - \rho Y_{t-1}, t = 2, \dots, T$$

### 10.8.4 Оценка параметра автокорреляции

1. Выражение из Дарбина-Уотсона
2. Процедура Кокрена-Уоркута
  - (a) Оцениваем уравнение регрессии и находим остатки
  - (b) Оцениваем регрессию остатков на предыдущие, получаем  $\rho_1$
  - (c) Преобразуем исходные данные
  - (d) Повторяем 1 и 2, получаем  $\rho_2$
  - (e)  $|\rho_1 - \rho_2| < \varepsilon \rightarrow \rho = \rho_2$
  - (f) Если процедура не сходится - могли не угадать порядок автокорреляции
3. Двухшаговая процедура Дарбина

(a)

$$Y_t = \rho Y_{t-1} + \beta_0(1 - \rho) + \dots$$

(b) Оцениваем  $\rho$

4. Метод поиска Хилдрет-Лю на сетке

(a) Подбираем  $\rho$  для которого RSS минимальна

5. Среди регрессоров встречается стохастический  $Y_{t-1}$

- (a)  $\varepsilon$  удовлетворяют Марковской схеме 1-го уровня
- (b) Тогда статистика Дарбина-Уотсона не применима из-за возникновения проблемы эндогенности
- (c) **Используется h-статистика Дарбина**
- (d)

$$\begin{cases} H_0 : \rho = 0 \\ H_1 : \rho \neq 0 \end{cases}$$

(e)  $h = \hat{\rho} \sqrt{\frac{n}{1 - n s_{b_Y(-1)}^2}}$

6. Тест Бройша-Годфри

- (a)  $H_0$  : нет автокорреляции возмущений
- (b)  $H_1$  : имеет место автокорреляция порядка  $p$
- (c)

$$\begin{cases} H_0 : \rho_1 = \rho_2 = \dots = \rho_p = 0 \\ H_1 : \rho_1^2 + \rho_2^2 + \dots + \rho_p^2 \neq 0 \end{cases}$$

(d) Проверяется гипотеза о том, что ошибки являются белым шумом

(e) *Алгоритм*

- i. Оцениваются параметры регрессии

$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$$

- ii. Сохраняются остатки регрессии
- iii. Оцениваются параметры регрессии

$$e_t = \beta_0 + \beta_1 X_t + r_1 e_{t-1} + \dots + r_p e_{t-p} + \varepsilon_t$$

- iv. Сохраняется  $R^2$
- v. Тестовая статистика

$$\chi^2 = TR^2$$

- vi. Если  $\chi^2 > \chi_{cr}^2$ , то гипотеза отвергается

7. Стандартные ошибки в форме Ньюи-Веста

$$var[\varepsilon] \sim \Omega = (w_{ij}), w_{ij} = 0, |i - j| > L$$

$$\hat{var}[\hat{\beta}] = n(X'X)^{-1} \frac{1}{T} \left( \sum_{s=1}^T e_s^2 x_s x_s' + \sum_{j=1}^L \sum_{t=j+1}^T w_j e_t e_{t-j} (x_t x_{t-j}' + x_{t-j} x_t') \right) (X'X)^{-1}$$

8. Q-статистика для проверки белозумности остатков

- (a) Модель ARMA(p, q)
- (b)

$$\begin{cases} H_0 : \rho_1 = \dots = \rho_m = 0 \\ H_1 : \rho_1^2 + \dots + \rho_m^2 > 0 \end{cases}$$

(с)

$$Q_m = T \sum_{k=1}^m r_k^2$$

(d)  $r_k$  - выборочный коэффициент корреляции остатков  $\varepsilon_t$  и  $\varepsilon_{t-k}$

(е)  $m$  - гиперпараметр

(f)

$$Q \sim \chi^2(m - p - q)$$

(g) Статистика  $Q$  используется и для проверки беломумности исходного ряда, тогда тестовая статистика имеет распределение  $\chi^2(m)$

## 9. Статистика Бокса-Льюнга (для малых выборок)

(a)

$$Q_k = T(T+2) \sum_{k=1}^m \frac{1}{T-k} r_k^2$$

10. Статистики хорошо работают, когда справа стоят экзогенные факторы, для временных рядов достаточно слабы

## 10.9 Моделирование сезонности во временных рядах

### 10.9.1 Модели ARIMA с сезонностью

1. Включение набора дамми-переменных для каждого месяца кроме одного, чтобы избежать dummy trap
2. Использование  $Y(-12)$

### 10.9.2 SARIMA

1. Мультипликативная

(a)

$$(1 - \rho_1 L) \{ \Delta \ln(wpi_t) - \beta_0 \} = (1 + \theta_1 L)(1 + \theta_{4,1} L^4) \varepsilon_t$$

$$\Delta \ln(wpi_t) = \beta_0 + \rho_1 \{ \Delta \ln(wpi_{t-1}) - \beta_0 \} + \theta_1 \varepsilon_{t-1} + \theta_{4,1} \varepsilon_{t-4} + \theta_1 \theta_{4,1} \varepsilon_{t-5} + \varepsilon_t$$

(b) В общем виде SARIMA  $(p, d, q) \times (P, D, Q)_s$ :

$$\rho(L^p) \rho_s(L^P) \Delta^d \Delta_s^D z_t = \theta(L^q) \theta_s(L^Q) \varepsilon_t$$

$$\rho_s(L^P) = (1 - \rho_{s,1} L^s - \rho_{s,2} L^{2s} - \dots \rho_{s,P} L^{Ps})$$

$$\theta_s(L^Q) = (1 - \theta_{s,1} L^s - \theta_{s,2} L^{2s} - \dots \theta_{s,P} L^{Qs})$$

(с) Можно подбирать параметры  $P$  и  $Q$  (сезонные лаги), а не только  $p$  и  $q \rightarrow AIC, BIC$

(d) Оценивается с помощью ММП

2. Аддитивная

(a)

$$\Delta \ln(wpi_t) = \beta_0 + \rho_1 \{\Delta \ln(wpi_{t-1}) - \beta_0\} + \theta_1 \varepsilon_{t-1} + \theta_4 \varepsilon_{t-4} + \varepsilon_t$$

$$(1 - \rho_1 L) \{\Delta \ln(wpi_t) - \beta_0\} = (1 + \theta_1 L + \theta_4 L^4) \varepsilon_t$$

(b) Выше модель для квартальных данных (Добавляется четвертый лаг)

3. В уравнение модели добавляются сезонные лаги

### 10.9.3 Процедуры сглаживания ряда

1. STL Decomposition

2. Экспоненциальное сглаживание

(a)

$$\hat{Y}_{t+1|t} = \alpha Y_t + (1 - \alpha) \hat{Y}_{t|t-1}$$

(b) ETS

$$b_t = b_{t-1} + \beta u_t$$

$$s_t = s_{t-12} + \gamma u_t$$

$$l_t = \ell_{t-1} + b_{t-1} + \alpha u_t$$

$$y_t = \ell_{t-1} + b_{t-1} + s_{t-12} + u_t$$

3. Hodrick-Prescott filter

(a) Ряд разбивается на тренд  $\tau$ , циклическую компоненту  $c_t$ , ошибка  $\varepsilon_t$

(b) Подбирается тренд компонента из

$$\min_{\tau} \left( \sum_{t=1}^T (y_t - \tau_t)^2 + \lambda \sum_{t=2}^{T-1} [(\tau_{t+1} - \tau_t) - (\tau_t - \tau_{t-1})]^2 \right)$$

$$\lambda = \begin{cases} 100, & \text{for annual data} \\ 1600, & \text{for quarterly data} \\ 14400, & \text{for monthly data} \end{cases}$$

(c) Критика: Возникают смещения на концах оцениваемых интервалов

## 10.10 Прогнозирование с помощью временных рядов

### 10.10.1 Прогнозирование по модели ARMA(p, q)

По критерию MSE наилучший прогноз на момент T+1:

$$E(Y_{T+1} | \Omega_T)$$

$\Omega_T$ - вся информация, известная на момент времени T

$$E(\varepsilon_{T+1} | \Omega_T) = 0$$

$$E(\varepsilon_T | \Omega_T) = \varepsilon_T$$

### AR(1)

$$\begin{aligned}Y_t &= \beta_0 + \beta_1 Y_{t-1} + \varepsilon_t \\ \hat{Y}_{T+1} &= E(Y_{T+1} \mid \Omega_T) = \beta_0 + \beta_1 Y_T \\ e_{T+1} &= Y_{T+1} - \hat{Y}_{T+1} = Y_{T+1} - E(Y_{T+1} \mid \Omega_T) = \\ &= \beta_0 + \beta_1 Y_T + \varepsilon_{T+1} - \beta_0 - \beta_1 Y_T = \varepsilon_{T+1} \\ \text{Var}(e_{T+1}) &= \sigma_\varepsilon^2 \\ Y_{T+2} &= \beta_0 + \beta_1 \hat{Y}_{T+1} = \beta_0 + \beta_1(\beta_0 + \beta_1 Y_T) \\ e_{T+2} &= \varepsilon_{T+2} + \beta_1 \varepsilon_{T+1} \\ \text{Var}(e_{T+2}) &= \sigma_\varepsilon^2(1 + \beta_1^2) \\ e_{T+3} &= \varepsilon_{T+3} + \beta_1 \varepsilon_{T+2} + \beta_1^2 \varepsilon_{T+1} \\ \text{Var}(e_{T+3}) &= \sigma_\varepsilon^2(1 + \beta_1^2 + \beta_1^4) \\ \text{Var}(e_{T+s}) &\rightarrow \frac{\sigma_\varepsilon^2}{1 - \beta_1^2}\end{aligned}$$

### MA(1)

$$\begin{aligned}Y_t &= \beta_0 + \varepsilon_t + \alpha_1 \varepsilon_{t-1} \\ \hat{Y}_{T+1} &= E(Y_{T+1} \mid \Omega_T) = \beta_0 + \alpha_1 \varepsilon_T \\ \hat{Y}_{T+s} &= \beta_0, s \geq 2 \\ \text{Var}(e_{T+1}) &= \sigma_\varepsilon^2 \\ \text{Var}(e_{T+s}) &= \sigma_\varepsilon^2(1 + \alpha_1^2), s \geq 2\end{aligned}$$

### ARMA(1, 1)

$$\begin{aligned}e_{T+1} &= \varepsilon_{T+1} \\ \text{Var}(e_{T+1}) &= \sigma_\varepsilon^2 \\ e_{T+2} &= \varepsilon_{T+2} + \alpha_1 \varepsilon_{T+1} + \beta_1 \varepsilon_{T+1} \\ \text{Var}(e_{T+2}) &= \sigma_\varepsilon^2(1 + (\alpha_1 + \beta_1)^2)\end{aligned}$$

## 10.10.2 Коинтеграция временных рядов

Стационарный временной ряд:  $X_t \sim I(0)$

Если только разность порядка  $d$  является стационарной, то этот ряд называется интегрированным порядка  $d$ :  $X_t \sim I(d)$

### Свойства интегрированных временных рядов

1.  $X_t \sim I(0), Y_t \sim I(1) \rightarrow Z_t = X_t + Y_t \sim I(1)$
2.  $X_t \sim I(d) \rightarrow Z_t = a + bX_t \sim I(d)$
3.  $X_t \sim I(d_1), Y_t \sim I(d_2) \rightarrow Z_t = aX_t + bY_t \sim I(\max(d_1, d_2))$
4.  $X_t \sim I(d), Y_t \sim I(d) \rightarrow Z_t = aX_t + bY_t \sim I(d^* \leq d)$

**Определение:** Коинтегрированные временные ряды

Если  $X_t \sim I(d), Y_t \sim I(d)$ , а  $Z_t = aX_t + bY_t \sim I(0)$ , то ряды  $X_t, Y_t$  называются коинтегрированными



## Коинтеграция

Если:

$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$$

$$\varepsilon_t = Y_t - \beta_0 - \beta_1 X_t$$

$Y_t, X_t$  - временные ряды одного порядка, коэффициент  $\beta_1$  является значимым, а ошибки нестационарны, то имеет место *мнимая регрессия*

Если  $\varepsilon_t$  стационарны, то имеет место *коинтеграция*

### Проверка на практике

1. Оцениваем регрессию одного ряда на другой
2. Сохраняем остатки
3. Смотрим на их ACF, PACF
4. Применять тесты DF, ADF нельзя
5. Надо использовать таблицу Маккинона

## 10.11 Модели с распределенными лагами

1. Модели с распределенными лагами - лаги у X
2. Регрессионные динамические модели - лаги у Y
3. ADL - лаги у X и Y

### Проблемы при оценке

1. Модель с лаговыми переменными - вместо текущих значений включаются лаговые значения
2. Если учитывать несколько лагов - возникает проблема мультиколлинеарности
3. Модель геометрических лагов Койка

$$Y_t = \alpha + \beta X_t + \beta \lambda X_{t-1} + \beta \lambda^2 X_{t-2} + \dots + \varepsilon_t$$

$$0 < \lambda < 1$$

Зависимость уже не является линейной - убирает проблему мультиколлинеарности

Сведение к динамической модели:

$$Y_{t-1} = \alpha + \beta X_{t-1} + \dots$$

$$Y_t - \lambda Y_{t-1} = \alpha(1 - \lambda) + \beta X_t + \varepsilon_t - \lambda \varepsilon_{t-1}$$

$$Y_t = \alpha(1 - \lambda) + \beta X_t + \lambda Y_{t-1} + \varepsilon_t - \lambda \varepsilon_{t-1}$$

4. Сильное предположение о экспоненциальном убывании влияния
5. В модели присутствует эндогенность - ее нельзя оценить МНК

## 6. Методы оценивания

### (a) Нелинейный метод оценивания

- i. Вводим переменную

$$Z_t(\lambda) = X_t + \lambda X_{t-1} + \lambda^2 X_{t-2} + \dots$$

- ii. Для каждого значения  $\lambda = 0, 0.1, \dots, 1$  оцениваем

$$Y_t = \alpha + \beta Z_t + \varepsilon_t$$

- iii. Выбираем оценки параметров с минимальным RSS

### (b) ММП

- i.  $\varepsilon \sim \mathcal{N}(0, \Omega)$

### (c) Метод инструментальных переменных

- i. Ищем инструменты для  $Y_{t-1}$

- ii. Исходя из предположения, что X экзогенные

## 7. Модель Ширли-Алмон

$$Y_t = \alpha + \beta_0 X_t + \beta_1 X_{t-1} + \dots + \varepsilon_t$$

$$\beta_i = c_0 + c_1 i + c_2 i^2 + \dots + c_p i^p$$

$$Y_t = \alpha + (c_0 X_t + c_0 + c_1 + c_2 + \dots + c_p) X_{t-1} + \dots$$

$$Y_t = \alpha + c_0(X_t + X_{t-1} + \dots) + c_1(X_{t-1} + 2X_{t-2} + \dots)$$

## 8. Модель адаптивных ожиданий

$$Y_t = \beta_0 + \beta_1 X_{t+1}^e + \varepsilon_t$$

$$X_{t+1}^e - X_t^e = \lambda(X_t - X_t^e)$$